

Metody probabilistyczne w uczeniu maszynowym

Wykład 2: teoria decyzji, metody gradientowe, regresja liniowa

Katarzyna Grygiel

Semestr letni 2025/2026

Funkcja straty

Trzy przestrzenie:

- wejść $\mathcal{X}$,
- predykcji (akcji) $\mathcal{A}$,
- wyjść $\mathcal{Y}$.

Funkcja decyzyjna to funkcja $f: \mathcal{X} \rightarrow \mathcal{A}$.

Funkcja straty (kosztu) to funkcja $\ell: \mathcal{A} \times \mathcal{Y} \rightarrow \mathbb{R}$.

Na wejściu otrzymujemy argument $x \in \mathcal{X}$, dla którego funkcja decyzyjna oblicza $a \in \mathcal{A}$. Funkcja straty opisuje zależność pomiędzy predykcją a oraz wartością wyjściową $y \in \mathcal{Y}$.

Ryzyko

Dane z przestrzeni $\mathcal{X} \times \mathcal{Y}$ generowane są z rozkładem $p_{\mathcal{X} \times \mathcal{Y}}$.

Ryzykiem funkcji decyzyjnej $f: \mathcal{X} \rightarrow \mathcal{A}$ nazywamy oczekiwaną stratę względem nowej instancji, czyli dla zmiennych losowych $(X, Y) \sim p_{\mathcal{X}, \mathcal{Y}}$ definiujemy ryzyko jako

$$R(f) = \mathbb{E}_{X, Y}(\ell(f(X), Y)).$$

Ryzyko

Dane z przestrzeni $\mathcal{X} \times \mathcal{Y}$ generowane są z rozkładem $p_{\mathcal{X} \times \mathcal{Y}}$.

Ryzykiem funkcji decyzyjnej $f: \mathcal{X} \rightarrow \mathcal{A}$ nazywamy oczekiwaną stratę względem nowej instancji, czyli dla zmiennych losowych $(X, Y) \sim p_{\mathcal{X}, \mathcal{Y}}$ definiujemy ryzyko jako

$$R(f) = \mathbb{E}_{X, Y}(\ell(f(X), Y)).$$

Bayesowską funkcją decyzyjną nazywamy funkcję f^* , dla której strata $\ell(f^*(x), y)$ jest możliwie mała:

$$f^* = \arg \min_{f: \mathcal{X} \rightarrow \mathcal{A}} R(f).$$

Ryzyko

Dane z przestrzeni $\mathcal{X} \times \mathcal{Y}$ generowane są z rozkładem $p_{\mathcal{X} \times \mathcal{Y}}$.

Ryzykiem funkcji decyzyjnej $f: \mathcal{X} \rightarrow \mathcal{A}$ nazywamy oczekiwaną stratę względem nowej instancji, czyli dla zmiennych losowych $(X, Y) \sim p_{\mathcal{X}, \mathcal{Y}}$ definiujemy ryzyko jako

$$R(f) = \mathbb{E}_{X, Y}(\ell(f(X), Y)).$$

Bayesowską funkcją decyzyjną nazywamy funkcję f^* , dla której strata $\ell(f^*(x), y)$ jest możliwie mała:

$$f^* = \arg \min_{f: \mathcal{X} \rightarrow \mathcal{A}} R(f).$$

Ryzyko bayesowskie to ryzyko bayesowskiej funkcji decyzyjnej, czyli ograniczenie dolne na wartość oczekiwaną straty po wszystkich funkcjach decyzyjnych:

$$R(f^*) = \inf_f R(f).$$

Przykład 1

Jak wygląda bayesowska funkcja decyzyjna w problemie **regresji**, gdy

$$\mathcal{A} = \mathcal{Y} = \mathbb{R} \text{ oraz } \ell(a, y) = (a - y)^2?$$

Przykład 2

Jak wygląda bayesowska funkcja decyzyjna w problemie **klasyfikacji**, gdy

$$\mathcal{A} = \mathcal{Y} = \{1, \dots, K\} \text{ oraz } \ell(a, y) = \mathbf{1}[a \neq y]?$$

Ryzyko empiryczne

Ryzyko empiryczne funkcji $f: \mathcal{X} \rightarrow \mathcal{A}$ ze względu na dane $\mathcal{D} = \{(x^{(i)}, y^{(i)}): i = 1, \dots, m\}$ to średnia strata na danych $\mathcal{D}$:

$$\hat{R}_m(f) = \frac{1}{m} \sum_{i=1}^m \ell(f(x^{(i)}), y^{(i)}).$$

Ryzyko empiryczne

Ryzyko empiryczne funkcji $f: \mathcal{X} \rightarrow \mathcal{A}$ ze względu na dane $\mathcal{D} = \{(x^{(i)}, y^{(i)}): i = 1, \dots, m\}$ to średnia strata na danych $\mathcal{D}$:

$$\hat{R}_m(f) = \frac{1}{m} \sum_{i=1}^m \ell(f(x^{(i)}), y^{(i)}).$$

Z Silnego Prawa Wielkich Liczb wynika zbieżność prawie na pewno:

$$\hat{R}_m(f) \xrightarrow{m \rightarrow \infty} R(f).$$

Ryzyko empiryczne

Ryzyko empiryczne funkcji $f: \mathcal{X} \rightarrow \mathcal{A}$ ze względu na dane $\mathcal{D} = \{(x^{(i)}, y^{(i)}): i = 1, \dots, m\}$ to średnia strata na danych $\mathcal{D}$:

$$\hat{R}_m(f) = \frac{1}{m} \sum_{i=1}^m \ell(f(x^{(i)}), y^{(i)}).$$

Z Silnego Prawa Wielkich Liczb wynika zbieżność prawie na pewno:

$$\hat{R}_m(f) \xrightarrow{m \rightarrow \infty} R(f).$$

Minimalizacja ryzyka empirycznego polega na wyznaczeniu funkcji $\hat{f}: \mathcal{X} \rightarrow \mathcal{A}$ minimalizującej ryzyko empiryczne:

$$\hat{f} = \arg \min_{f: \mathcal{X} \rightarrow \mathcal{A}} \hat{R}_m(f) = \arg \min_{f: \mathcal{X} \rightarrow \mathcal{A}} \sum_{i=1}^m \ell(f(x^{(i)}), y^{(i)}).$$

Przykład 3


$$X \sim \text{Uni}[0, 1] \quad Y \equiv 1$$

$$\mathcal{D} = \{(0, 1), (1/4, 1), (1/2, 1), (3/4, 1), (1, 1)\}$$

Przykład 3

$$X \sim \text{Uni}[0, 1] \quad Y \equiv 1$$



$$\mathcal{D} = \{(0, 1), (1/4, 1), (1/2, 1), (3/4, 1), (1, 1)\}$$



Przykład 3

$$X \sim \text{Uni}[0, 1] \quad Y \equiv 1$$

$$\mathcal{D} = \{(0, 1), (1/4, 1), (1/2, 1), (3/4, 1), (1, 1)\}$$



Ryzyko empiryczne dla przestrzeni hipotez

Przestrzeń hipotez to podzbiór zbioru funkcji decyzyjnych. Zazwyczaj interesują nas hipotezy, które są (pod pewnymi względami) regularne i z którymi łatwo jest pracować.

Ryzyko empiryczne dla przestrzeni hipotez

Przestrzeń hipotez to podzbiór zbioru funkcji decyzyjnych. Zazwyczaj interesują nas hipotezy, które są (pod pewnymi względami) regularne i z którymi łatwo jest pracować.

Minimalizacja ryzyka empirycznego dla zbioru hipotez $\mathcal{H}$ polega na wyznaczeniu następującej funkcji $\hat{f}_{\mathcal{H}} \in \mathcal{H}$:

$$\hat{f}_{\mathcal{H}} = \arg \min_{f \in \mathcal{H}} \frac{1}{m} \sum_{i=1}^m \ell(f(x^{(i)}), y^{(i)}).$$

Gradient

Problem

Niech $f: \mathbb{R}^d \rightarrow \mathbb{R}$ będzie funkcją różniczkowalną. Szukamy

$$\arg \min_{x \in \mathbb{R}^d} f(x).$$

Gradient

Problem

Niech $f: \mathbb{R}^d \rightarrow \mathbb{R}$ będzie funkcją różniczkowalną. Szukamy

$$\arg \min_{x \in \mathbb{R}^d} f(x).$$

Niech $f: \mathbb{R}^d \rightarrow \mathbb{R}$ będzie funkcją różniczkowalną w punkcie x_0 . *Gradientem* funkcji f w punkcie x_0 nazywamy wektor pochodnych cząstkowych:

$$\nabla f(x_0) = \left[\frac{\partial f(x_0)}{\partial x_1}, \dots, \frac{\partial f(x_0)}{\partial x_d} \right]^T.$$

Gradient w punkcie $x_0 \in \mathbb{R}^d$ wskazuje kierunek największego wzrostu. Im większa norma gradientu, tym szybszy wzrost.

Metoda gradientu prostego

Algorytm spadku wzdłuż gradientu

Inicjalizacja $\theta^{[0]}$;

$k \leftarrow 0$;

while *warunek_stopu* **do**

$\theta^{[k+1]} \leftarrow \theta^{[k]} - \eta \nabla f(\theta^{[k]})$;

$k \leftarrow k + 1$;

end

Metoda gradientu prostego

Algorytm spadku wzdłuż gradientu

Inicjalizacja $\theta^{[0]}$;

$k \leftarrow 0$;

while *warunek_stopu* **do**

$\theta^{[k+1]} \leftarrow \theta^{[k]} - \eta \nabla f(\theta^{[k]})$;
 $k \leftarrow k + 1$;

end

- Czy znajdziemy minimum globalne?
- Jak ustalić warunek stopu?
- Jak wybrać wielkość kroku η ?

Funkcje wypukłe

Dla funkcji różniczkowalnych i wypukłych metoda gradientu prostego zawsze zbiega do minimum globalnego.

Funkcje wypukłe

Dla funkcji różniczkowalnych i wypukłych metoda gradientu prostego zawsze zbiega do minimum globalnego.

Dla funkcji lipschitzowskich wiemy jeszcze więcej.

Twierdzenie

Niech $f: \mathbb{R}^d \rightarrow \mathbb{R}$ będzie funkcją wypukłą i różniczkowalną, której gradient ∇f jest funkcją lipschitzowską ze stałą $L > 0$, czyli

$$\|\nabla f(x) - \nabla f(y)\| \leq L\|x - y\|.$$

Wtedy metoda gradientu prostego zbiega do minimum z krokiem $\eta \leq L^{-1}$. W szczególności

$$f(x^{[k]}) - f(x^*) \leq \frac{\|x^{[0]} - x^*\|^2}{2\eta k}.$$

Kiedy zatrzymać iterację? Jak dobrać długość kroku?

Możliwe warunki stopu:

- $\|\nabla f(x^{[k]})\| \leq \varepsilon$,
- $\|x^{[k]} - x^{[k-1]}\| \leq \varepsilon$,
- osiągnięcie maksymalnej liczby iteracji,
- brak poprawy na zbiorze walidacyjnym.

Kiedy zatrzymać iterację? Jak dobrać długość kroku?

Możliwe warunki stopu:

- $\|\nabla f(x^{[k]})\| \leq \varepsilon$,
- $\|x^{[k]} - x^{[k-1]}\| \leq \varepsilon$,
- osiągnięcie maksymalnej liczby iteracji,
- brak poprawy na zbiorze walidacyjnym.

Wielkość kroku η ma wpływ na zbieżność algorytmu:

- za mały krok powoduje zbyt wolną zbieżność,
- za duży krok może spowodować wzrost wartości funkcji celu.

W praktyce warto próbować wielu różnych wartości.

Gdy mamy dużo danych

Algorytm spadku wzdłuż gradientu w wersji mini-batch

Inicjalizacja $\theta^{[0]}$;

$k \leftarrow 0$;

while *warunek_stopu* **do**

Wybierz losowo N -elementowy podzbiór $\{(x^{(i)}, y^{(i)})\} \subseteq \mathcal{D}$;

$\theta^{[k+1]} \leftarrow \theta^{[k]} - \eta \left(\frac{1}{N} \sum_{i=1}^N \nabla \ell(f_{\theta}(x^{(i)}), y^{(i)}) \right)$;

$k \leftarrow k + 1$;

end

Gdy $N = 1$, to powyższy algorytm nazywamy *metodą stochastycznego gradientu* (SGD).

Modele liniowe dla regresji

Problem regresji

Jak na podstawie obserwacji $\{(x^{(1)}, y^{(1)}), \dots, (x^{(m)}, y^{(m)})\}$ oszacować y dla nowego wejścia x ?

Modele liniowe dla regresji

Problem regresji

Jak na podstawie obserwacji $\{(x^{(1)}, y^{(1)}), \dots, (x^{(m)}, y^{(m)})\}$ oszacować y dla nowego wejścia x ?

Dla $x = [x_1, \dots, x_k]^T$ możemy zdefiniować prosty model

$$f_{\theta}(x) = \theta_0 + \theta_1 x_1 + \dots + \theta_k x_k = \theta_0 + \sum_{j=1}^k \theta_j x_k$$


lub jego uogólnienie

$$f_{\theta}(x) = \theta_0 + \theta_1 \phi_1(x) + \dots + \theta_d \phi_d(x) = \theta_0 + \sum_{j=1}^d \theta_i \phi_j(x).$$


Funkcje $\phi_j(x)$ nazywamy *funkcjami bazowymi*. Liczba parametrów w tym modelu wynosi $d + 1$.

Przykładowe funkcje bazowe $\phi_j(x)$


$$x^j$$



$$\exp\left(-\frac{(x - \mu_j)^2}{2s^2}\right)$$



$$\sigma\left(\frac{x - \mu_j}{s}\right)$$



$\sigma(a) = \frac{1}{1+\exp(-a)}$ to funkcja logistyczna

Metoda najmniejszych kwadratów

Rozważmy model $h_{\theta}(x) = \theta_0 + \theta_1 x_1 + \dots + \theta_k x_k$ oraz funkcję kosztu

$$J(\theta) = \frac{1}{2} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2.$$

Metoda najmniejszych kwadratów

Rozważmy model $h_{\theta}(x) = \theta_0 + \theta_1 x_1 + \dots + \theta_k x_k$ oraz funkcję kosztu

$$J(\theta) = \frac{1}{2} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2.$$

Tworzymy *macierz planowania* X oraz wektor *zmiennej objaśnianej* y :

$$X = \begin{bmatrix} 1 & -x^{(1)T} - \\ 1 & \vdots \\ 1 & -x^{(m)T} - \end{bmatrix} = \begin{bmatrix} 1 & x_1^{(1)} & x_2^{(1)} & \dots & x_k^{(1)} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_1^{(m)} & x_2^{(m)} & \dots & x_k^{(m)} \end{bmatrix}$$
$$y = \begin{bmatrix} y^{(1)} \\ \vdots \\ y^{(m)} \end{bmatrix}.$$

Metoda najmniejszych kwadratów

W zapisie macierzowym mamy

$$J(\theta) = \frac{1}{2}(X\theta - y)^T(X\theta - y).$$

W jaki sposób wybrać θ , aby zminimalizować błąd?

Metoda najmniejszych kwadratów

W zapisie macierzowym mamy

$$J(\theta) = \frac{1}{2}(X\theta - y)^T(X\theta - y).$$

W jaki sposób wybrać θ , aby zminimalizować błąd?

- Algorytm spadku wzdłuż gradientu:
Powtarzaj aż do zbieżności

$$\theta \leftarrow \theta - \eta \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})x^{(i)}$$

Metoda najmniejszych kwadratów

W zapisie macierzowym mamy

$$J(\theta) = \frac{1}{2}(X\theta - y)^T(X\theta - y).$$

W jaki sposób wybrać θ , aby zminimalizować błąd?

- Algorytm spadku wzdłuż gradientu:
Powtarzaj aż do zbieżności

$$\theta \leftarrow \theta - \eta \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})x^{(i)}$$

- Rozwiązanie analityczne:

$$\theta = (X^T X)^{-1} X^T y.$$

Dlaczego taka funkcja kosztu?

Niech $y^{(i)} = \theta^T x^{(i)} + \varepsilon^{(i)}$, gdzie $\varepsilon^{(i)} \sim \mathcal{N}(0, \sigma^2)$ jest *szumem gaussowskim*. Zakładając, że zmienne $\varepsilon^{(i)}$ są niezależne, mamy

$$p_{\theta}(y^{(i)}|x^{(i)}) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(y^{(i)} - \theta^T x^{(i)})^2}{2\sigma^2}\right).$$

Dlaczego taka funkcja kosztu?

Niech $y^{(i)} = \theta^T x^{(i)} + \varepsilon^{(i)}$, gdzie $\varepsilon^{(i)} \sim \mathcal{N}(0, \sigma^2)$ jest *szumem gaussowskim*. Zakładając, że zmienne $\varepsilon^{(i)}$ są niezależne, mamy

$$p_{\theta}(y^{(i)}|x^{(i)}) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(y^{(i)} - \theta^T x^{(i)})^2}{2\sigma^2}\right).$$

Metodą największej wiarygodności możemy pokazać, że maksymalizacja funkcji wiarygodności jest równoważna minimalizacji

$$\frac{1}{2} \sum_{i=1}^m (y^{(i)} - \theta^T x^{(i)})^2,$$

czyli minimalizacji funkcji błędu kwadratowego.

Uwaga: W powyższym $x^{(i)} = [1, x_1^{(i)}, \dots, x_k^{(i)}]^T$.

Lokalnie ważona regresja

W problemie regresji ważonej celem jest minimalizacja następującej funkcji błędu:

$$\mathcal{J}(\theta) = \sum_{i=1}^m w^{(i)} \ell(\theta^T x^{(i)}, y^{(i)}).$$

W powyższym zapisie $w^{(i)}$ są nieujemnymi *wagami*.

Częstym wyborem wag jest następująca funkcja:

$$w^{(i)} = \exp \left(-\frac{(x^{(i)} - x)^2}{2\tau^2} \right),$$

gdzie x jest ustalonym punktem, dla którego chcemy wyznaczyć odpowiednią wartość wyjściową, natomiast τ jest pewną stałą, która kontroluje zakres, dla którego istniejące obserwacje są istotne.

Funkcje straty

W ogólności funkcja straty może być dowolną funkcją postaci

$$(\hat{y}, y) \mapsto \ell(\hat{y}, y) \in \mathbb{R}.$$

Zazwyczaj strata zależy od różnicy $r := y - \hat{y}$.

Funkcje straty

W ogólności funkcja straty może być dowolną funkcją postaci

$$(\hat{y}, y) \mapsto \ell(\hat{y}, y) \in \mathbb{R}.$$

Zazwyczaj strata zależy od różnicy $r := y - \hat{y}$.

Przykłady

- kwadratowa funkcja straty: $\ell(r) = r^2$ (nieodporna na obserwacje odstające),

Funkcje straty

W ogólności funkcja straty może być dowolną funkcją postaci

$$(\hat{y}, y) \mapsto \ell(\hat{y}, y) \in \mathbb{R}.$$

Zazwyczaj strata zależy od różnicy $r := y - \hat{y}$.

Przykłady

- kwadratowa funkcja straty: $\ell(r) = r^2$ (nieodporna na obserwacje odstające),
- bezwzględna funkcja straty: $\ell(r) = |r|$ (nieróżniczkowalna),

Funkcje straty

W ogólności funkcja straty może być dowolną funkcją postaci

$$(\hat{y}, y) \mapsto \ell(\hat{y}, y) \in \mathbb{R}.$$

Zazwyczaj strata zależy od różnicy $r := y - \hat{y}$.

Przykłady

- kwadratowa funkcja straty: $\ell(r) = r^2$ (nieodporna na obserwacje odstające),
- bezwzględna funkcja straty: $\ell(r) = |r|$ (nieróżniczkowalna),
- funkcja Hubera (odporna na obserwacje odstające i różniczkowalna):

$$\ell_{\delta}(r) = \begin{cases} \frac{1}{2}r^2, & \text{gdy } r \leq \delta, \\ \delta(|r| - \frac{1}{2}\delta), & \text{gdy } r > \delta. \end{cases}$$