

Metody probabilistyczne w uczeniu maszynowym

Wykład 3: regularyzacja, bayesowska regresja liniowa

Katarzyna Grygiel

Semestr letni 2025/2026

sad Laff

-Regression
to the
Meaning-



© 2014

Problem regresji: przypomnienie

Problem regresji polega na znalezieniu jak najlepszego dopasowania zmiennej wyjściowej y dla nowej danej wejściowej x na podstawie istniejących obserwacji $\{(x^{(i)}, y^{(i)}) : i = 1, \dots, m\}$.

Problem regresji: przypomnienie

Problem regresji polega na znalezieniu jak najlepszego dopasowania zmiennej wyjściowej y dla nowej danej wejściowej x na podstawie istniejących obserwacji $\{(x^{(i)}, y^{(i)}) : i = 1, \dots, m\}$.

Powyższy problem najczęściej sprowadza się do problemu minimalizacji ryzyka empirycznego:

$$\min_{h \in \mathcal{H}} \sum_{i=1}^m \ell(h(x^{(i)}), y^{(i)}),$$

gdzie $\mathcal{H}$ jest zbiorem hipotez.

Problem regresji: przypomnienie

Problem regresji polega na znalezieniu jak najlepszego dopasowania zmiennej wyjściowej y dla nowej danej wejściowej x na podstawie istniejących obserwacji $\{(x^{(i)}, y^{(i)}) : i = 1, \dots, m\}$.

Powyższy problem najczęściej sprowadza się do problemu minimalizacji ryzyka empirycznego:

$$\min_{h \in \mathcal{H}} \sum_{i=1}^m \ell(h(x^{(i)}), y^{(i)}),$$

gdzie $\mathcal{H}$ jest zbiorem hipotez.

W wielu przypadkach mamy do czynienia ze zjawiskiem przeuczenia. Co zrobić, aby go uniknąć?

Złożoność hipotezy

Na przestrzeni hipotez definiujemy *miarę złożoności* jako funkcję

$$\Omega: \mathcal{H} \rightarrow [0, \infty).$$

Złożoność hipotezy

Na przestrzeni hipotez definiujemy *miarę złożoności* jako funkcję

$$\Omega: \mathcal{H} \rightarrow [0, \infty).$$

Przykładowe miary złożoności:

- liczba cech,
- stopień wielomianu,
- głębokość drzewa decyzyjnego...

Złożoność hipotezy

Na przestrzeni hipotez definiujemy *miarę złożoności* jako funkcję

$$\Omega: \mathcal{H} \rightarrow [0, \infty).$$

Przykładowe miary złożoności:

- liczba cech,
- stopień wielomianu,
- głębokość drzewa decyzyjnego...

Dla hipotezy $h_{\theta}(x) = \theta_0 + \theta_1 x_1 + \dots + \theta_k x_k$ mogą to być na przykład miary:

- $\ell_0(h_{\theta}) = \#\{\theta_j: \theta_j \neq 0, j = 1, \dots, k\},$
- $\ell_1(h_{\theta}) = \sum_{j=1}^k |\theta_j|,$
- $\ell_2(h_{\theta}) = \sum_{j=1}^k \theta_j^2.$

Regularyzacja

Niech dane będą $\lambda, \omega \geq 0$, zbiór hipotez $\mathcal{H}$ oraz miara złożoności $\Omega: \mathcal{H} \rightarrow [0, \infty)$.

Regularyzacja Tichonowa

$$\min_{h \in \mathcal{H}} \frac{1}{m} \sum_{i=1}^m \ell(h(x^{(i)}), y^{(i)}) + \lambda \Omega(h)$$

Regularyzacja Iwanowa

$$\min_{h \in \mathcal{H}} \frac{1}{m} \sum_{i=1}^m \ell(h(x^{(i)}), y^{(i)}) \quad \text{pod warunkiem} \quad \Omega(h) \leq \omega$$

Równoważność regularyzacji

Regularyzacje lwanowa i Tichonowa są równoważne, gdy zachodzą oba poniższe warunki.

1. Dla dowolnego wyboru parametru złożoności $\omega > 0$ każde rozwiązanie problemu z regularyzacją lwanowa

$$h_{\omega}^* \in \arg \min_{h \in \mathcal{H}} \mathcal{J}(h) \text{ pod warunkiem } \Omega(h) \leq \omega$$

jest również rozwiązaniem dla problemu z regularyzacją Tichonowa z pewnym parametrem $\lambda > 0$.

2. Dla dowolnego wyboru parametru regularyzacji $\lambda > 0$ każde rozwiązanie problemu z regularyzacją Tichonowa

$$h_{\lambda}^* \in \arg \min_{h \in \mathcal{H}} \mathcal{J}(h) + \lambda \Omega(h)$$


jest również rozwiązaniem dla problemu z regularyzacją lwanowa z pewnym parametrem złożoności $\omega > 0$.

Regularyzacja ℓ_q

Dodanie składnika regularyzującego do funkcji błędu pomaga kontrolować przeuczenie.

Najczęściej stosuje się regularyzację ℓ_q , czyli dla modeli liniowych $h_\theta(x) = \theta^T x$ złożoność jest postaci

$$\Omega(h_\theta) = \sum_{j=1}^k |\theta_j|^q.$$



Regresja grzbietowa

Postać Tichonowa

Problem regresji grzbietowej z parametrem regularyzacji $\lambda \geq 0$ polega na wyznaczeniu

$$\hat{\theta} = \arg \min_{\theta \in \mathbb{R}^k} \frac{1}{m} \sum_{i=1}^m (\theta^T x^{(i)} - y^{(i)})^2 + \lambda \|\theta\|_2^2.$$

Postać Iwanowa

Problem regresji grzbietowej z parametrem złożoności $\omega \geq 0$ polega na wyznaczeniu

$$\hat{\theta} = \arg \min_{\|\theta\|_2^2 \leq \omega^2} \frac{1}{m} \sum_{i=1}^m (\theta^T x^{(i)} - y^{(i)})^2.$$

Regresja grzbietowa

Postać Tichonowa

Problem regresji grzbietowej z parametrem regularyzacji $\lambda \geq 0$ polega na wyznaczeniu

$$\hat{\theta} = \arg \min_{\theta \in \mathbb{R}^k} \frac{1}{m} \sum_{i=1}^m (\theta^T x^{(i)} - y^{(i)})^2 + \lambda \|\theta\|_2^2.$$

Postać Iwanowa

Problem regresji grzbietowej z parametrem złożoności $\omega \geq 0$ polega na wyznaczeniu

$$\hat{\theta} = \arg \min_{\|\theta\|_2^2 \leq \omega^2} \frac{1}{m} \sum_{i=1}^m (\theta^T x^{(i)} - y^{(i)})^2.$$

Powyższe problemy są równoważne.

Rozwiązanie analityczne dla regresji grzbietowej

Rozwiązując problem minimalizacji funkcji błędu z regularyzacją ℓ_2 o współczynniku λ możemy postępować analogicznie jak przy problemie regresji bez regularyzacji. Przyrównując gradient funkcji błędu do zera i rozwiązując odpowiednie równania, otrzymujemy

$$\hat{\theta}_{\lambda}^r = (\lambda \mathbf{I} + X^T X)^{-1} X^T y.$$

Rozwiązanie analityczne dla regresji grzbietowej

Rozwiązując problem minimalizacji funkcji błędu z regularyzacją ℓ_2 o współczynniku λ możemy postępować analogicznie jak przy problemie regresji bez regularyzacji. Przyrównując gradient funkcji błędu do zera i rozwiązując odpowiednie równania, otrzymujemy


$$\hat{\theta}_{\lambda}^r = (\lambda \mathbf{I} + X^T X)^{-1} X^T y.$$

W szczególnym przypadku gdy wektory cech x_i w macierzy planowania X są ortonormalne oraz $\hat{\theta}$ jest rozwiązaniem problemu regresji bez regularyzacji, to

$$\hat{\theta}_{\lambda}^r = \frac{1}{1 + \lambda} \hat{\theta}.$$

Ścieżka regularyzacji dla regresji grzbietowej

Niech $\hat{\theta}$ będzie rozwiązaniem problemu regresji bez regularyzacji oraz niech $\hat{\theta}_\omega$ będzie rozwiązaniem z ograniczeniem $\|\theta\|_2^2 \leq \omega$ (regularyzacja Iwanowa).



Gdy $\omega = 0$, to $\|\hat{\theta}_\omega\|_2 / \|\hat{\theta}\|_2 = 0$ (regularyzacja zeruje θ)

Gdy $\omega = \infty$, to $\|\hat{\theta}_\omega\|_2 / \|\hat{\theta}\|_2 = 1$ (brak regularyzacji)

Regresja lasso

Postać Tichonowa

Problem regresji lasso z parametrem regularyzacji $\lambda \geq 0$ polega na wyznaczeniu

$$\hat{\theta} = \arg \min_{\theta \in \mathbb{R}^k} \frac{1}{m} \sum_{i=1}^m (\theta^T x^{(i)} - y^{(i)})^2 + \lambda \|\theta\|_1.$$

Postać Iwanowa

Problem regresji lasso z parametrem złożoności $\omega \geq 0$ polega na wyznaczeniu

$$\hat{\theta} = \arg \min_{\|\theta\|_1 \leq \omega} \frac{1}{m} \sum_{i=1}^m (\theta^T x^{(i)} - y^{(i)})^2.$$

Regresja lasso

Postać Tichonowa

Problem regresji lasso z parametrem regularyzacji $\lambda \geq 0$ polega na wyznaczeniu

$$\hat{\theta} = \arg \min_{\theta \in \mathbb{R}^k} \frac{1}{m} \sum_{i=1}^m (\theta^T x^{(i)} - y^{(i)})^2 + \lambda \|\theta\|_1.$$

Postać Iwanowa


Problem regresji lasso z parametrem złożoności $\omega \geq 0$ polega na wyznaczeniu

$$\hat{\theta} = \arg \min_{\|\theta\|_1 \leq \omega} \frac{1}{m} \sum_{i=1}^m (\theta^T x^{(i)} - y^{(i)})^2.$$

Powyższe problemy są równoważne.

Ścieżka regularyzacji dla regresji lasso

Niech $\hat{\theta}$ będzie rozwiązaniem problemu regresji bez regularyzacji oraz niech $\hat{\theta}_\omega$ będzie rozwiązaniem z ograniczeniem $\|\theta\|_1 \leq \omega$ (regularyzacja Lwanowa).



Gdy $\omega = 0$, to $\|\hat{\theta}_\omega\|_1 / \|\hat{\theta}\|_1 = 0$
(regularyzacja zeruje θ).

Gdy $\omega = \infty$, to $\|\hat{\theta}_\omega\|_1 / \|\hat{\theta}\|_1 = 1$
(brak regularyzacji).

Metoda spadku względem współrzędnych

Jak znaleźć argument $\theta \in \mathbb{R}^d$ minimalizujący funkcję $\mathcal{J}: \mathbb{R}^d \rightarrow \mathbb{R}$, która nie wszędzie jest różniczkowalna?

Algorytm spadku względem współrzędnych

Inicjalizacja $\theta^{[0]}$;

$k \leftarrow 0$;

while *warunek_stopu* **do**

 Wybierz $j \in \{1, \dots, d\}$;

$\theta_j^* \leftarrow \arg \min_{\theta_j} \mathcal{J}(\theta_1^{[k]}, \dots, \theta_{j-1}^{[k]}, \theta_j, \theta_{j+1}^{[k]}, \dots, \theta_d^{[k]})$;

$\theta_j^{[k+1]} \leftarrow \theta_j^*$;

$\theta^{[k+1]} \leftarrow \theta^{[k]}$;

$k \leftarrow k + 1$;

end

Metoda spadku względem współrzędnych

Jeśli funkcja jest wypukła ze względu na każdą ze współrzędnych oraz klasy $\mathcal{C}^1$, to ten algorytm zwraca minimum globalne.

Funkcja błędu z regularyzacją ℓ_1 taka nie jest. Ratuje nas jednak silniejsze twierdzenie.

Twierdzenie

Jeśli $f: \mathbb{R}^d \rightarrow \mathbb{R}$ jest postaci

$$f(\theta_1, \dots, \theta_d) = g(\theta_1, \dots, \theta_d) + \sum_{j=1}^d h_j(\theta_j),$$

gdzie $g: \mathbb{R}^d \rightarrow \mathbb{R}$ jest różniczkowalna i wypukła oraz $h_j: \mathbb{R} \rightarrow \mathbb{R}$ jest wypukła dla każdego $j = 1, \dots, d$, to metoda spadku względem współrzędnych zbiega do globalnego minimum f .

Minimalizacja po współrzędnych

W algorytmie spadku względem współrzędnych chcemy wyznaczyć

$$\hat{\theta}_j = \arg \min_{\theta_j \in \mathbb{R}} \sum_{i=1}^m (\theta^T x^{(i)} - y^{(i)})^2 + \lambda \|\theta\|_1.$$

Wtedy


$$\hat{\theta}_j = \begin{cases} (c_j + \lambda)/a_j & \text{dla } c_j < -\lambda, \\ 0 & \text{dla } c_j \in [-\lambda, \lambda], \\ (c_j - \lambda)/a_j & \text{dla } c_j > \lambda, \end{cases}$$

gdzie


$$a_j = 2 \sum_{i=1}^m (x_j^{(i)})^2, \quad c_j = 2 \sum_{i=1}^m x_j^{(i)} (y^{(i)} - \theta_{-j}^T x_{-j}^{(i)})$$

natomiast θ_{-j} oznacza wektor θ z usuniętą j -tą współrzędną (analogicznie $x_{-j}^{(i)}$).

Regularyzacje ℓ_1 i ℓ_2



regresja lasso



regresja grzbietowa

Regularyzacja z siecią elastyczną

Kwadratowa funkcja błędu z regularyzacją łączącą cechy regularyzacji lasso i grzbietowej ma następującą postać:

$$\mathcal{J}(\theta) = \frac{1}{m} \|X\theta - y\|_2^2 + \lambda_2 \|\theta\|_2^2 + \lambda_1 \|\theta\|_1.$$

Regularyzacja z siecią elastyczną

Kwadratowa funkcja błędu z regularyzacją łączącą cechy regularyzacji lasso i grzbietowej ma następującą postać:

$$\mathcal{J}(\theta) = \frac{1}{m} \|X\theta - y\|_2^2 + \lambda_2 \|\theta\|_2^2 + \lambda_1 \|\theta\|_1.$$

Twierdzenie

Niech $\bar{x}_j = 0$ oraz $\sigma(x_j) = 1$ dla każdego $j = 1, \dots, d$ oraz niech $\rho_{ij} := \frac{1}{m} x_i^T x_j$. Jeżeli $\hat{\theta}_i \cdot \hat{\theta}_j > 0$, to

$$|\hat{\theta}_i - \hat{\theta}_j| \leq \frac{\|y\|_2 \sqrt{2}}{\sqrt{m\lambda_2}} \sqrt{1 - \rho_{ij}}.$$

Dekompozycja błędu na obciążenie i wariancję modelu

Mamy dane D , które pochodzą z rozkładu o pewnym nieznanym parametrze θ^* . Niech $\hat{\theta} = \hat{\theta}(D)$ będzie estymatorem θ^* otrzymanym na podstawie danych D . Wtedy

$$\mathbb{E}((\hat{\theta} - \theta^*)^2) = \mathbb{E}((\hat{\theta} - \mathbb{E}(\hat{\theta}))^2) + (\mathbb{E}(\hat{\theta}) - \theta^*)^2,$$

gdzie wartość oczekiwana jest brana ze względu na prawdziwy rozkład $p(D|\theta^*)$.

średni błąd kwadratowy = wariancja + (obciążenie)²

Model z funkcjami bazowymi

Rozważmy model liniowy

$$h_{\theta}(x) = \theta^T \phi(x) + \varepsilon,$$

gdzie $x \in \mathbb{R}^k$, $\theta \in \mathbb{R}^d$, $\phi(x) = [\phi_1(x), \dots, \phi_d(x)]^T$ oraz $\varepsilon \sim \mathcal{N}(0, \sigma^2)$.

Model z funkcjami bazowymi

Rozważmy model liniowy

$$h_{\theta}(x) = \theta^T \phi(x) + \varepsilon,$$

gdzie $x \in \mathbb{R}^k$, $\theta \in \mathbb{R}^d$, $\phi(x) = [\phi_1(x), \dots, \phi_d(x)]^T$ oraz $\varepsilon \sim \mathcal{N}(0, \sigma^2)$.

Niech $D = \{(x^{(i)}, y^{(i)}) : x^{(i)} \in \mathbb{R}^k, y^{(i)} \in \mathbb{R}, i = 1, \dots, m\}$. Macierz planowania wygląda teraz następująco:

$$\Phi = \begin{bmatrix} \phi_1(x^{(1)}) & \phi_2(x^{(1)}) & \cdots & \phi_d(x^{(1)}) \\ \phi_1(x^{(2)}) & \phi_2(x^{(2)}) & \cdots & \phi_d(x^{(2)}) \\ \vdots & \vdots & \ddots & \vdots \\ \phi_1(x^{(m)}) & \phi_2(x^{(m)}) & \cdots & \phi_d(x^{(m)}) \end{bmatrix}.$$

Model z funkcjami bazowymi

Rozważmy model liniowy

$$h_{\theta}(x) = \theta^T \phi(x) + \varepsilon,$$

gdzie $x \in \mathbb{R}^k$, $\theta \in \mathbb{R}^d$, $\phi(x) = [\phi_1(x), \dots, \phi_d(x)]^T$ oraz $\varepsilon \sim \mathcal{N}(0, \sigma^2)$.

Niech $D = \{(x^{(i)}, y^{(i)}) : x^{(i)} \in \mathbb{R}^k, y^{(i)} \in \mathbb{R}, i = 1, \dots, m\}$. Macierz planowania wygląda teraz następująco:

$$\Phi = \begin{bmatrix} \phi_1(x^{(1)}) & \phi_2(x^{(1)}) & \dots & \phi_d(x^{(1)}) \\ \phi_1(x^{(2)}) & \phi_2(x^{(2)}) & \dots & \phi_d(x^{(2)}) \\ \vdots & \vdots & \ddots & \vdots \\ \phi_1(x^{(m)}) & \phi_2(x^{(m)}) & \dots & \phi_d(x^{(m)}) \end{bmatrix}.$$

Metoda najmniejszych kwadratów zwraca estymator

$$\hat{\theta} = (\Phi^T \Phi)^{-1} \Phi^T y.$$

Bayesowska regresja liniowa

Dla niezależnych obserwacji ze zbioru D oraz ustalonej wartości σ funkcja wiarygodności jest postaci

$$p(y|X, \theta) = \prod_{i=1}^m \mathcal{N}(y^{(i)} | \theta^T \phi(x^{(i)}), \sigma^2).$$

Bayesowska regresja liniowa

Dla niezależnych obserwacji ze zbioru D oraz ustalonej wartości σ funkcja wiarygodności jest postaci

$$p(y|X, \theta) = \prod_{i=1}^m \mathcal{N}(y^{(i)} | \theta^T \phi(x^{(i)}), \sigma^2).$$

Zdefiniujmy rozkład prawdopodobieństwa a priori dla parametru θ sprzężony z powyższym rozkładem jako

$$p(\theta) = \mathcal{N}(\theta | \mu_0, S_0)$$

dla pewnej średniej μ_0 oraz macierzy kowariancji S_0 .

Bayesowska regresja liniowa

Mamy

$$p(\theta) = \mathcal{N}(\theta | \mu_0, S_0),$$
$$p(y|X, \theta) = \prod_{i=1}^m \mathcal{N}(y^{(i)} | \theta^T \phi(x^{(i)}), \sigma^2).$$

Ponieważ rozkład a posteriori jest proporcjonalny do iloczynu wiarygodności i rozkładu a priori, jest on również rozkładem normalnym:

$$p(\theta|y, X) = \mathcal{N}(\theta | \mu_m, S_m),$$

gdzie

$$\mu_m = S_m(S_0^{-1}\mu_0 + \sigma^{-2}\Phi^T y),$$
$$S_m^{-1} = S_0^{-1} + \sigma^{-2}\Phi^T \Phi.$$

Bayesowska regresja liniowa

Dla uproszczenia założmy, że $\mu_0 = \vec{0} = [0, \dots, 0]^T$ oraz $S_0 = \tau^2 \mathbf{I}_{d \times d}$ dla pewnego parametru $\tau \neq 0$. Wtedy

$$p(\theta|\tau) = \mathcal{N}(\theta|\vec{0}, \tau^2 \mathbf{I}_{d \times d}),$$

a stąd

$$\begin{aligned}\mu_m &= \sigma^{-2} S_m \Phi^T y, \\ S_m^{-1} &= \tau^{-2} \mathbf{I}_{d \times d} + \sigma^{-2} \Phi^T \Phi.\end{aligned}$$

Bayesowska regresja liniowa

Dla uproszczenia załóżmy, że $\mu_0 = \vec{0} = [0, \dots, 0]^T$ oraz $S_0 = \tau^2 \mathbf{I}_{d \times d}$ dla pewnego parametru $\tau \neq 0$. Wtedy

$$p(\theta|\tau) = \mathcal{N}(\theta|\vec{0}, \tau^2 \mathbf{I}_{d \times d}),$$

a stąd

$$\begin{aligned}\mu_m &= \sigma^{-2} S_m \Phi^T y, \\ S_m^{-1} &= \tau^{-2} \mathbf{I}_{d \times d} + \sigma^{-2} \Phi^T \Phi.\end{aligned}$$

Można pokazać, że problem maksymalizacji rozkładu a posteriori dla parametru θ jest równoważny problemowi minimalizacji kwadratowej funkcji błędu z regularyzacją ℓ_2 o parametrze $\lambda = \sigma^2 / \tau^2$.

Bayesowska regresja liniowa: wizualizacja

Rozważmy prosty model liniowy:



$$h_{\theta}(x) = \theta_0 + \theta_1 x, \quad x \in \mathbb{R}.$$

Generujemy dane w następujący sposób ($i = 1, \dots, m$):



- losujemy $x^{(i)}$ z rozkładu jednostajnego $\text{Uni}[-1, 1]$,
- wyznaczamy wartość $h(x) = -0.3 + 0.5x$ na każdym $x^{(i)}$,
- dodajemy szum o rozkładzie normalnym $\mathcal{N}(0, 0.2)$.

W ten sposób otrzymujemy zbiór $\{y^{(i)} : i = 1, \dots, m\}$.



Bayesowska regresja liniowa: wizualizacja





Bayesowska regresja liniowa: wizualizacja



Bayesowska regresja liniowa: wizualizacja



Bayesowska regresja liniowa: wizualizacja



Rozkład predykcyjny

Bardziej niż przewidywaniem parametru θ jesteśmy zainteresowani przewidywaniem nieznanej wartości $y^{(m+1)}$ dla nowej danej $x^{(m+1)}$. W tym celu wprowadzamy *rozkład predykcyjny*:

$$p(y^{(m+1)} | y, \tau, \sigma) = \int p(y^{(m+1)} | \theta, \sigma) p(\theta | y, \tau, \sigma) d\theta.$$

Dla każdej wartości θ obliczamy prawdopodobieństwo $y^{(m+1)}$ pod warunkiem θ i przemnażamy je przez prawdopodobieństwo wystąpienia konkretnej wartości θ .

Dla uproszczenia notacji pomijamy warunki $x^{(m+1)}$ i X .

Rozkład predykcyjny

W rozważanym przez nas modelu

$$\begin{aligned}p(y^{(m+1)} | x^{(m+1)}, \theta, \sigma) &= \mathcal{N}(y^{(m+1)} | \theta^T \phi(x^{(m+1)}), \sigma^2) \\p(\theta | y, \tau, \sigma) &= \mathcal{N}(\theta | \mu_m, S_m).\end{aligned}$$

Na tej podstawie rozkład predykcyjny ma postać

$$\begin{aligned}p(y^{(m+1)} | y, X, x^{(m+1)}, \tau, \sigma) \\= \mathcal{N}(y^{(m+1)} | \mu_m^T \phi(x^{(m+1)}), \sigma_m^2(x^{(m+1)})),\end{aligned}$$

gdzie

$$\sigma_m^2(x) = \sigma^2 + \phi(x)^T S_m \phi(x).$$

Rozkład predykcyjny

W rozważanym przez nas modelu

$$\begin{aligned}p(y^{(m+1)} | x^{(m+1)}, \theta, \sigma) &= \mathcal{N}(y^{(m+1)} | \theta^T \phi(x^{(m+1)}), \sigma^2) \\p(\theta | y, \tau, \sigma) &= \mathcal{N}(\theta | \mu_m, S_m).\end{aligned}$$

Na tej podstawie rozkład predykcyjny ma postać


$$\begin{aligned}p(y^{(m+1)} | y, X, x^{(m+1)}, \tau, \sigma) \\= \mathcal{N}(y^{(m+1)} | \mu_m^T \phi(x^{(m+1)}), \sigma_m^2(x^{(m+1)})),\end{aligned}$$

gdzie



$$\sigma_m^2(x) = \sigma^2 + \phi(x)^T S_m \phi(x).$$

Można pokazać, że $\sigma_{m+1}^2(x) \leq \sigma_m^2(x)$. Ponadto $\sigma_m^2(x) \xrightarrow{m \rightarrow \infty} \sigma^2$, zatem wariancja rozkładu predykcyjnego zbiega do σ^2 .




Rozkład predykcyjny: wizualizacja



Rozkład predykcyjny: wizualizacja



Rozkład predykcyjny: wizualizacja



Rozkład predykcyjny: wizualizacja

