

Metody probabilistyczne w uczeniu maszynowym


Wykład 4: funkcje straty dla klasyfikacji, regresja logistyczna,
wykładnicza rodzina rozkładów, uogólnione modele liniowe

Katarzyna Grygiel

Semestr letni 2025/2026


Klasyfikacja

Klasyfikacja polega na przypisaniu odpowiedniej klasy (kategorii, etykiety) dla zadanych danych. W zadaniach klasyfikacji szukamy funkcji, która dobrze aproksymuje poprawne przyporządkowanie danych wejściowych danym wyjściowym.



Rodzaje klasyfikacji


**klasyfikatory
generatywne**



algorytm uczy się $p(x|y)$ i $p(y)$


Rodzaje klasyfikacji

klasyfikatory generatywne



algorytm uczy się $p(x|y)$ i $p(y)$

klasyfikatory dyskryminatywne



algorytm uczy się $p(y|x)$

Rodzaje klasyfikacji

klasyfikatory generatywne

- tworzymy model probabilistyczny dla każdej klasy
- dla nowego wejścia wybieramy najbardziej prawdopodobną klasę
- ten model klasyfikacji sprawdza się również w przypadku uczeniu bez nadzoru

Rodzaje klasyfikacji

klasyfikatory generatywne

- tworzymy model probabilistyczny dla każdej klasy
- dla nowego wejścia wybieramy najbardziej prawdopodobną klasę
- ten model klasyfikacji sprawdza się również w przypadku uczeniu bez nadzoru

klasyfikatory dyskryminatywne

- tworzymy granicę rozdzielającą klasy
- decyzję dla nowego wejścia podejmujemy na podstawie wyznaczonej granicy
- istotna jest tylko granica decyzyjna, a punkty, które są od niej oddalone, nie mają znaczenia w procesie decyzyjnym
- podejście to jest efektywne przy licznych danych treningowych
- ten model sprawdza się tylko w przypadku uczenia nadzorowanego

Pies czy kot: podejście generatywne i dyskryminatywne

Rozważmy problem klasyfikacji zwierząt na psy i koty.

Podejście generatywne:

- na podstawie danych ze zbioru treningowego odpowiadającym kotom budujemy model opisujący cechy charakteryzujące koty i analogicznie modelujemy cechy psów;
- klasyfikując nowe zwierzę, porównujemy je z oboma modelami i sprawdzamy, który z nich jest bardziej odpowiedni.

Podejście dyskryminatywne:

- wykorzystując zbiór treningowy, tworzymy granicę decyzyjną na przestrzeni danych wejściowych dzieląc ją na podprzestrzeń kotów i podprzestrzeń psów;
- dla nowego zwierzęcia przewidujemy, czy jest kotem czy psem, bazując na tym, do której podprzestrzeni należy.

Przykłady klasyfikatorów

klasyfikatory generatywne

- naiwny klasyfikator bayesowski
- sieci bayesowskie
- pola Markowa
- generatywne sieci przeciwstawne (GAN)

Przykłady klasyfikatorów

klasyfikatory generatywne

- naiwny klasyfikator bayesowski
- sieci bayesowskie
- pola Markowa
- generatywne sieci przeciwstawne (GAN)

klasyfikatory dyskryminatywne

- regresja logistyczna
- maszyny wektorów nośnych (SVM)
- sieci neuronowe
- metoda najbliższych sąsiadów
- drzewa decyzyjne

Funkcje straty dla klasyfikacji

Rozważmy przestrzeń wyjściową $\mathcal{Y} = \{-1, 1\}$.

Dla przestrzeni akcji $\mathcal{A} = \{-1, 1\}$ zero-jedynkowa funkcja straty dla $f: \mathcal{X} \rightarrow \{-1, 1\}$ dana będzie przez

$$\ell_{0/1}(f(x), y) = \mathbf{1}[f(x) \neq y].$$

Funkcje straty dla klasyfikacji

Rozważmy przestrzeń wyjściową $\mathcal{Y} = \{-1, 1\}$.

Dla przestrzeni akcji $\mathcal{A} = \{-1, 1\}$ zero-jedynkowa funkcja straty dla $f: \mathcal{X} \rightarrow \{-1, 1\}$ dana będzie przez

$$\ell_{0/1}(f(x), y) = \mathbf{1}[f(x) \neq y].$$

Rozszerzając przestrzeń akcji do całego zbioru liczb rzeczywistych rozważamy funkcje decyzyjne postaci $f: \mathcal{X} \rightarrow \mathbb{R}$. Wtedy

- jeżeli $f(x) > 0$, to przewidujemy 1,
- jeżeli $f(x) < 0$, to przewidujemy -1 .

Margines

Jak zminimalizować ryzyko empiryczne dla straty zero-jedynkowej

$$\hat{R}_m(h) = \frac{1}{m} \sum_{i=1}^m \mathbf{1}[y^{(i)} \cdot h(x^{(i)}) \leq 0]?$$

Powyższa funkcja nie jest ani wypukła, ani różniczkowalna, ani nawet ciągła.

Margines

Jak zminimalizować ryzyko empiryczne dla straty zero-jedynkowej

$$\hat{R}_m(h) = \frac{1}{m} \sum_{i=1}^m \mathbf{1}[y^{(i)} \cdot h(x^{(i)}) \leq 0]?$$

Powyższa funkcja nie jest ani wypukła, ani różniczkowalna, ani nawet ciągła.

Marginesem dla przewidywanego wyniku $\hat{y}$ i prawdziwego wyjścia $y \in \{-1, 1\}$ nazywamy iloczyn $\hat{y} \cdot y$.

Margines

Jak zminimalizować ryzyko empiryczne dla straty zero-jedynkowej

$$\widehat{R}_m(h) = \frac{1}{m} \sum_{i=1}^m \mathbf{1}[y^{(i)} \cdot h(x^{(i)}) \leq 0]?$$

Powyższa funkcja nie jest ani wypukła, ani różniczkowalna, ani nawet ciągła.

Marginesem dla przewidywanego wyniku $\widehat{y}$ i prawdziwego wyjścia $y \in \{-1, 1\}$ nazywamy iloczyn $\widehat{y} \cdot y$.

Zależy nam na tym, aby:

- margines był dodatni (klasyfikacja jest poprawna),
- margines miał dużą wartość (nasze przekonanie o poprawnej klasyfikacji jest większe).

Większość funkcji straty dla klasyfikacji zależy tylko od marginesu. Naszym celem jest maksymalizacja marginesu.

Różne funkcje straty

Przykładowe funkcje straty bazujące na marginesie m :

- strata zawiasowa $\ell_z(m) = \max(1 - m, 0) =: (1 - m)_+$.
- strata Savage'a $\ell_s(m) = \frac{1}{(1+e^m)^2}$,
- strata logistyczna $\ell_l(m) = \ln(1 + e^{-m})$,
- strata wykładnicza $\ell_b(m) = e^{-m}$,
- strata kwadratowa $\ell_s(m) = (1 - m)^2$.

Różne funkcje straty


Przykładowe funkcje straty bazujące na marginesie m :

- strata zawiasowa $\ell_z(m) = \max(1 - m, 0) =: (1 - m)_+$.
- strata Savage'a $\ell_s(m) = \frac{1}{(1 + e^m)^2}$,
- strata logistyczna $\ell_l(m) = \ln(1 + e^{-m})$,
- strata wykładnicza $\ell_b(m) = e^{-m}$,
- strata kwadratowa $\ell_s(m) = (1 - m)^2$.

Na przykład dla przestrzeni hipotez $\mathcal{H} = \{h_\theta : h_\theta(x) = \theta^T x\}$ oraz dla zawiasowej funkcji straty i regularyzacji ℓ_2 problem klasyfikacji można sprowadzić do problemu optymalizacyjnego


$$\arg \min_{\theta \in \mathbb{R}^k} \sum_{i=1}^m (1 - y^{(i)} h_\theta(x^{(i)}))_+ + \lambda \|\theta\|_2^2.$$

Funkcje straty




Regresja liniowa jako klasyfikator

Klasyfikacja dla $y \in \{0, 1\}$: stosujemy regresję liniową i ustalamy próg w $1/2$.



Regresja liniowa jako klasyfikator


Klasyfikacja dla $y \in \{0, 1\}$: stosujemy regresję liniową i ustalamy próg w $1/2$.



Czasami działa dobrze.


Regresja liniowa jako klasyfikator

Klasyfikacja dla $y \in \{0, 1\}$: stosujemy regresję liniową i ustalamy próg w $1/2$.



Regresja liniowa jako klasyfikator

Klasyfikacja dla $y \in \{0, 1\}$: stosujemy regresję liniową i ustalamy próg w $1/2$.



Najczęściej jednak nie.

Regresja logistyczna


Klasyfikacja dla $y \in \{0, 1\}$. Definiujemy liniowy model

$$h_{\theta}(x) = \text{sig}(\theta^T x) = \frac{1}{1 + e^{-\theta^T x}}.$$

Regresja logistyczna

Klasyfikacja dla $y \in \{0, 1\}$. Definiujemy liniowy model

$$h_{\theta}(x) = \text{sig}(\theta^T x) = \frac{1}{1 + e^{-\theta^T x}}.$$



Regresja logistyczna

Wartości funkcji sig interpretujemy jako prawdopodobieństwa

$$p(y = 1|x, \theta) = h_{\theta}(x),$$

$$p(y = 0|x, \theta) = 1 - h_{\theta}(x),$$

Regresja logistyczna

Wartości funkcji sig interpretujemy jako prawdopodobieństwa

$$p(y = 1|x, \theta) = h_{\theta}(x),$$

$$p(y = 0|x, \theta) = 1 - h_{\theta}(x),$$

co możemy zapisać w zwartej postaci:

$$p(y|x, \theta) = (h_{\theta}(x))^y (1 - h_{\theta}(x))^{1-y}.$$

Regresja logistyczna

Wartości funkcji sig interpretujemy jako prawdopodobieństwa

$$p(y = 1|x, \theta) = h_{\theta}(x),$$

$$p(y = 0|x, \theta) = 1 - h_{\theta}(x),$$

co możemy zapisać w zwartej postaci:

$$p(y|x, \theta) = (h_{\theta}(x))^y (1 - h_{\theta}(x))^{1-y}.$$

Maksymalizacja funkcji wiarygodności

$$L(\theta) = \prod_{i=1}^m p(y^{(i)}|x^{(i)}, \theta)$$

proceedzi do następnego kroku w metodzie stochastycznego gradientu:

$$\theta_j \leftarrow \theta_j + \alpha (y^{(i)} - h_{\theta}(x^{(i)})) x_j^{(i)}.$$

Metoda Newtona–Raphsona

Rozwiązując problem maksymalizacji funkcji wiarygodności, możemy skorzystać z metody Newtona–Raphsona, pozwalającej na wyznaczenie przybliżonej wartości zera zadanej funkcji.

Metoda Newtona–Raphsona

Rozwiązując problem maksymalizacji funkcji wiarygodności, możemy skorzystać z metody Newtona–Raphsona, pozwalającej na wyznaczenie przybliżonej wartości zera zadanej funkcji.

Stosując metodę Newtona–Raphsona do gradientu funkcji log-wiarygodności $\nabla_{\theta}\ell$, otrzymujemy następujący wzór na kolejne przybliżenie:

$$\theta \leftarrow \theta - H^{-1}\nabla_{\theta}\ell(\theta),$$

gdzie H to hesjan dla $\ell(\theta)$, czyli

$$H_{ij} = \frac{\partial^2 \ell(\theta)}{\partial \theta_i \partial \theta_j}.$$

Wykładnicza rodzina rozkładów

Rozważmy parametryczną rodzinę rozkładów

$$\mathcal{P}_\Theta = \{p(y|\theta) : \theta \in \Theta\}.$$

Jeżeli dla każdego $\theta \in \Theta$ istnieją stała η (*parametr naturalny*) oraz funkcje $a(\eta)$, $b(y)$ i $T(y)$ takie, że

$$(*) \quad p(y|\eta) = b(y) \exp(\eta^T T(y) - a(\eta)),$$

to rodzinę $\mathcal{P}_\Theta$ nazywamy *wykładniczą rodziną rozkładów*.

Wykładnicza rodzina rozkładów

Rozważmy parametryczną rodzinę rozkładów

$$\mathcal{P}_\Theta = \{p(y|\theta): \theta \in \Theta\}.$$

Jeżeli dla każdego $\theta \in \Theta$ istnieją stała η (*parametr naturalny*) oraz funkcje $a(\eta)$, $b(y)$ i $T(y)$ takie, że

$$(*) \quad p(y|\eta) = b(y) \exp(\eta^T T(y) - a(\eta)),$$

to rodzinę $\mathcal{P}_\Theta$ nazywamy *wykładniczą rodziną rozkładów*.

Funkcja $T(y)$ we wzorze $(*)$ jest statystyką dostateczną, ponadto często $T(y) = y$.

Wykładnicza rodzina rozkładów

Rozważmy parametryczną rodzinę rozkładów

$$\mathcal{P}_\Theta = \{p(y|\theta) : \theta \in \Theta\}.$$

Jeżeli dla każdego $\theta \in \Theta$ istnieją stała η (*parametr naturalny*) oraz funkcje $a(\eta)$, $b(y)$ i $T(y)$ takie, że

$$(*) \quad p(y|\eta) = b(y) \exp(\eta^T T(y) - a(\eta)),$$

to rodzinę $\mathcal{P}_\Theta$ nazywamy *wykładniczą rodziną rozkładów*.

Funkcja $T(y)$ we wzorze $(*)$ jest statystyką dostateczną, ponadto często $T(y) = y$.

Dla obserwacji $X_1, \dots, X_n$ funkcję $T(X_1, \dots, X_n)$ nazywamy *statystyką dostateczną*, jeśli funkcja $p(x|T(X_1, \dots, X_n) = t, \theta)$ jest zależna od t , ale niezależna od parametru θ .

Wykładnicza rodzina rozkładów: rozkład zero-jedynkowy

Rozważmy rodzinę rozkładów zero-jedynkowych parametryzowanych $\phi \in (0, 1)$:

$$p(y = 1|\phi) = \phi, \quad p(y = 0|\phi) = 1 - \phi,$$

czyli

$$p(y|\phi) = \phi^y(1 - \phi)^{1-y}.$$

Wykładnicza rodzina rozkładów: rozkład zero-jedynkowy

Rozważmy rodzinę rozkładów zero-jedynkowych parametryzowanych $\phi \in (0, 1)$:

$$p(y = 1|\phi) = \phi, \quad p(y = 0|\phi) = 1 - \phi,$$

czyli

$$p(y|\phi) = \phi^y(1 - \phi)^{1-y}.$$

Rodzina ta jest wykładniczą rodziną rozkładów:

$$\eta = \ln(\phi/(1 - \phi)),$$

$$T(y) = y,$$

$$a(\eta) = \ln(1 + e^\eta),$$

$$b(y) = 1.$$

Wykładnicza rodzina rozkładów: rozkład normalny

Rozważmy rodzinę jednowymiarowych rozkładów normalnych takich, że $\sigma^2 = 1$. Wtedy jedynym parametrem jest μ :

$$p(y|\mu) = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{(y-\mu)^2}{2}\right).$$

Wykładnicza rodzina rozkładów: rozkład normalny

Rozważmy rodzinę jednowymiarowych rozkładów normalnych takich, że $\sigma^2 = 1$. Wtedy jedynym parametrem jest μ :

$$p(y|\mu) = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{(y-\mu)^2}{2}\right).$$

Również i ta rodzina jest wykładniczą rodziną rozkładów:

$$\begin{aligned}\eta &= \mu, \\ T(y) &= y, \\ a(\eta) &= \eta^2/2, \\ b(y) &= 1/\sqrt{2\pi} \exp(-y^2/2).\end{aligned}$$

Inne wykładnicze rodziny rozkładów

Wiele innych rodzin parametrycznych tworzy wykładnicze rodziny rozkładów:

- rozkłady wielomianowe,
- rozkłady Poissona,
- rozkłady gamma,
- rozkłady wykładnicze,
- rozkłady geometryczne.

Inne wykładnicze rodziny rozkładów

Wiele innych rodzin parametrycznych tworzy wykładnicze rodziny rozkładów:

- rozkłady wielomianowe,
- rozkłady Poissona,
- rozkłady gamma,
- rozkłady wykładnicze,
- rozkłady geometryczne.

Ale nie wszystkie, jak na przykład rozkłady jednostajne lub rozkłady t-Studenta.

Uogólnione modele liniowe

Rozważmy ogólny problem przewidywania wartości y na podstawie obserwacji x w pewnej przestrzeni $\mathcal{X} \times \mathcal{Y}$.

Konstruujemy model spełniający następujące założenia:

- dla danej wejściowej x i parametru θ zmienna $y|x, \theta$ podlega rozkładowi z wykładniczej rodziny rozkładów o parametrze η ,
- parametr η i dane wejściowe x są zależne liniowo: $\eta = \theta^T x$,
- na podstawie obserwacji x celem jest oszacowanie wartości oczekiwanej $T(y)$, czyli $h_\theta(x) = \mathbb{E}(T(y)|x, \theta)$.

Uogólnione modele liniowe

Rozważmy ogólny problem przewidywania wartości y na podstawie obserwacji x w pewnej przestrzeni $\mathcal{X} \times \mathcal{Y}$.

Konstruujemy model spełniający następujące założenia:

- dla danej wejściowej x i parametru θ zmienna $y|x, \theta$ podlega rozkładowi z wykładniczej rodziny rozkładów o parametrze η ,
- parametr η i dane wejściowe x są zależne liniowo: $\eta = \theta^T x$,
- na podstawie obserwacji x celem jest oszacowanie wartości oczekiwanej $T(y)$, czyli $h_\theta(x) = \mathbb{E}(T(y)|x, \theta)$.

Funkcję $g(\eta) := \mathbb{E}(T(y)|\eta)$, zależną od parametru naturalnego η , nazywamy *kanoniczną funkcją odpowiedzi*, natomiast funkcję do niej odwrotną, g^{-1} , *kanoniczną funkcją łączącą*.

Regresja liniowa jako uogólniony model liniowy

W problemie regresji liniowej z szumem gaussowskim o wariancji σ^2 zmienna $y|x$ modelowana jest rozkładem normalnym $\mathcal{N}(\mu, \sigma^2)$.

Regresja liniowa jako uogólniony model liniowy

W problemie regresji liniowej z szumem gaussowskim o wariancji σ^2 zmienna $y|x$ modelowana jest rozkładem normalnym $\mathcal{N}(\mu, \sigma^2)$.

Rozkłady normalne o zadanej wariancji tworzą rodzinę wykładniczą.

Regresja liniowa jako uogólniony model liniowy

W problemie regresji liniowej z szumem gaussowskim o wariancji σ^2 zmienna $y|x$ modelowana jest rozkładem normalnym $\mathcal{N}(\mu, \sigma^2)$.

Rozkłady normalne o zadanej wariancji tworzą rodzinę wykładniczą.

Mamy $\eta = \mu$ oraz $\mathbb{E}(y|x, \theta) = \mu$. Ponieważ $\eta = \theta^T x$, to

$$h_{\theta}(x) = \theta^T x.$$

Regresja logistyczna jako uogólniony model liniowy

W przypadku regresji logistycznej $y \in \{0, 1\}$, zatem rozkład warunkowy $y|x$ modelujemy rozkładem zero-jedynkowym z parametrem ϕ .

Regresja logistyczna jako uogólniony model liniowy

W przypadku regresji logistycznej $y \in \{0, 1\}$, zatem rozkład warunkowy $y|x$ modelujemy rozkładem zero-jedynkowym z parametrem ϕ .

Pokazaliśmy wcześniej, że rozkłady zero-jedynkowe tworzą rodzinę wykładniczą.

Regresja logistyczna jako uogólniony model liniowy

W przypadku regresji logistycznej $y \in \{0, 1\}$, zatem rozkład warunkowy $y|x$ modelujemy rozkładem zero-jedynkowym z parametrem ϕ .

Pokazaliśmy wcześniej, że rozkłady zero-jedynkowe tworzą rodzinę wykładniczą.

Wtedy $\phi = \frac{1}{1+\exp(-\eta)}$. Ponadto $\mathbb{E}[y|x, \theta] = \phi$. Zatem

$$h_{\theta}(x) = \frac{1}{1 + \exp(-\theta^T x)}.$$

Regresja wieloklasowa (softmax)

Niech $\mathcal{Y} = \{1, \dots, K\}$. Rozważmy uogólniony model liniowy dla rozkładu wielomianowego z parametrem $\phi = [\phi_1, \dots, \phi_K]^T$ takim, że $\sum_{i=1}^K \phi_i = 1$. Mamy

$$p(Y = i) = \phi_i = \prod_{i=1}^K \phi_i^{\mathbf{1}[Y=i]}.$$

Regresja wieloklasowa (softmax)

Niech $\mathcal{Y} = \{1, \dots, K\}$. Rozważmy uogólniony model liniowy dla rozkładu wielomianowego z parametrem $\phi = [\phi_1, \dots, \phi_K]^T$ takim, że $\sum_{i=1}^K \phi_i = 1$. Mamy

$$p(Y = i) = \phi_i = \prod_{i=1}^K \phi_i^{\mathbf{1}_{[Y=i]}}.$$

Wtedy

$$a(\eta) = -\ln \phi_K, \quad b(y) = 1, \quad \eta_i = \ln(\phi_i/\phi_K)$$

oraz

$$T(1) = \begin{bmatrix} 1 \\ 0 \\ \vdots \\ 0 \end{bmatrix}, \dots, T(K-1) = \begin{bmatrix} 0 \\ 0 \\ \vdots \\ 1 \end{bmatrix}, T(K) = \begin{bmatrix} 0 \\ 0 \\ \vdots \\ 0 \end{bmatrix}.$$

Regresja wieloklasowa (softmax)

Ostatecznie

$$h_{\theta}(x) = \begin{bmatrix} \frac{\exp(\theta_1^T x)}{\sum_{j=1}^K \exp(\theta_j^T x)} \\ \vdots \\ \frac{\exp(\theta_{K-1}^T x)}{\sum_{j=1}^K \exp(\theta_j^T x)} \end{bmatrix}.$$

Regresja wieloklasowa (softmax)

Ostatecznie

$$h_{\theta}(x) = \begin{bmatrix} \frac{\exp(\theta_1^T x)}{\sum_{j=1}^K \exp(\theta_j^T x)} \\ \vdots \\ \frac{\exp(\theta_{K-1}^T x)}{\sum_{j=1}^K \exp(\theta_j^T x)} \end{bmatrix}.$$

Dla obserwacji

$$\{(x^{(i)}, y^{(i)}) : i = 1, \dots, m\} \subset \mathbb{R}^k \times \{1, \dots, K\}$$

parametr $\theta = [\theta_1, \dots, \theta_K]$, gdzie $\theta_j \in \mathbb{R}^k$ dla $j = 1, \dots, K$, wyznaczamy maksymalizując funkcję log-wiarygodności

$$\ell(\theta) = \sum_{i=1}^m \sum_{\ell=1}^K \mathbf{1}[y^{(i)} = \ell] \ln \left(\frac{\exp(\theta_{\ell}^T x^{(i)})}{\sum_{j=1}^K \exp(\theta_j^T x^{(i)})} \right).$$