

Metody probabilistyczne w uczeniu maszynowym

Wykład 5: miary oceny klasyfikatora, gaussowska analiza dyskryminacyjna,
naiwny klasyfikator bayesowski

Katarzyna Grygiel

Semestr letni 2025/2026

Mierzenie jakości przewidywań

przewidywania {

		stan faktyczny	
		1	0
1	<i>TP</i>	<i>FP</i>	
0	<i>FN</i>	<i>TN</i>	

$$\text{dokładność} = \frac{TP + TN}{TP + TN + FN + FP}$$


$$\text{precyzja} = \frac{TP}{TP + FP}$$

$$\text{czułość} = \frac{TP}{TP + FN}$$

- wysoka precyzja $\rightarrow$ niski poziom fałszywych alarmów
- wysoka czułość $\rightarrow$ wysoki poziom detekcji pozytywnych przypadków

Rodzaje błędów

Type I error
(false positive)



Type II error
(false negative)



Mierzenie jakości przewidywań

- TP: Ostrzegliśmy wioskę przed wilkiem. Wilk przyszedł.
- FP: Ostrzegliśmy wioskę przed wilkiem. Wilk nie przyszedł.
- FN: Nie ostrzegliśmy wioski przed wilkiem. Wilk przyszedł.
- TN: Nie ostrzegliśmy wioski przed wilkiem. Wilk nie przyszedł.

Mierzenie jakości przewidywań

- TP: Ostrzegliśmy wioskę przed wilkiem. Wilk przyszedł.
- FP: Ostrzegliśmy wioskę przed wilkiem. Wilk nie przyszedł.
- FN: Nie ostrzegliśmy wioski przed wilkiem. Wilk przyszedł.
- TN: Nie ostrzegliśmy wioski przed wilkiem. Wilk nie przyszedł.

W ciągu 100 dni wilk przyszedł do wioski 10 razy.

Mierzenie jakości przewidywań

- TP: Ostrzeżliśmy wioskę przed wilkiem. Wilk przyszedł.
- FP: Ostrzeżliśmy wioskę przed wilkiem. Wilk nie przyszedł.
- FN: Nie ostrzeżliśmy wioski przed wilkiem. Wilk przyszedł.
- TN: Nie ostrzeżliśmy wioski przed wilkiem. Wilk nie przyszedł.

W ciągu 100 dni wilk przyszedł do wioski 10 razy.

strategia I

	1	0
1	TP = 0	FP = 0
0	FN = 10	TN = 90

dokładność = 0.90 czułość = 0 precyzja niezdefiniowana

Mierzenie jakości przewidywań

- TP: Ostrzegliśmy wioskę przed wilkiem. Wilk przyszedł.
- FP: Ostrzegliśmy wioskę przed wilkiem. Wilk nie przyszedł.
- FN: Nie ostrzegliśmy wioski przed wilkiem. Wilk przyszedł.
- TN: Nie ostrzegliśmy wioski przed wilkiem. Wilk nie przyszedł.

W ciągu 100 dni wilk przyszedł do wioski 10 razy.

strategia II

	1	0
1	TP = 5	FP = 10
0	FN = 5	TN = 80

dokładność = 0.85 czułość = 0.5 precyzja = 0.33

Mierzenie jakości przewidywań

- TP: Ostrzegliśmy wioskę przed wilkiem. Wilk przyszedł.
- FP: Ostrzegliśmy wioskę przed wilkiem. Wilk nie przyszedł.
- FN: Nie ostrzegliśmy wioski przed wilkiem. Wilk przyszedł.
- TN: Nie ostrzegliśmy wioski przed wilkiem. Wilk nie przyszedł.

W ciągu 100 dni wilk przyszedł do wioski 10 razy.

strategia III

	1	0
1	TP = 7	FP = 5
0	FN = 3	TN = 85

dokładność = 0.92 czułość = 0.70 precyzja = 0.58

Mierzenie jakości przewidywań

- TP: Ostrzegliśmy wioskę przed wilkiem. Wilk przyszedł.
- FP: Ostrzegliśmy wioskę przed wilkiem. Wilk nie przyszedł.
- FN: Nie ostrzegliśmy wioski przed wilkiem. Wilk przyszedł.
- TN: Nie ostrzegliśmy wioski przed wilkiem. Wilk nie przyszedł.

W ciągu 100 dni wilk przyszedł do wioski 10 razy.

strategia IV

	1	0
1	TP = 9	FP = 9
0	FN = 1	TN = 81

dokładność = 0.90 czułość = 0.90 precyzja = 0.5


Miara F_1

Chcemy osiągnąć wysoką precyzję oraz wysoką czułość.

Aby móc porównywać różne modele, definiujemy miarę F_1 :

$$F_1 = 2 \cdot \frac{1}{\frac{1}{\text{czułość}} + \frac{1}{\text{precyzja}}} = 2 \cdot \frac{\text{precyzja} \cdot \text{czułość}}{\text{precyzja} + \text{czułość}} \in [0, 1].$$

nr	czułość	precyzja	F_1
1	0.01	0.99	0.02
	0.20	0.80	0.32
	0.40	0.90	0.55
	0.50	0.33	0.40
	0.70	0.58	0.63
2	0.80	0.61	0.69
	0.90	0.50	0.64
	0.90	0.95	0.92



Miara F_β

Czasami stosujemy ważoną miarę F_β . Ma ona postać

$$F_\beta = (1 + \beta^2) \frac{\text{precyzja} \cdot \text{czułość}}{\beta^2 \cdot \text{precyzja} + \text{czułość}}.$$

- $\beta > 1$ premiuje czułość (np. automatyczne wykrywanie podejrzanych transakcji finansowych),
- $\beta < 1$ premiuje precyzję (np. informowanie pacjenta o pozytywnym wyniku badania przesiewowego na raka).

nr	precyzja	czułość	F_1	$F_{0,5}$	F_2
	0,01	0,99	0,02	0,01	0,05
	0,20	0,80	0,32	0,24	0,50
	0,40	0,90	0,55	0,45	0,72
2	0,50	0,33	0,40	0,45	0,35
3	0,70	0,58	0,63	0,67	0,60
4	0,80	0,61	0,69	0,72	0,64
	0,90	0,50	0,64	0,77	0,55
	0,90	0,95	0,92	0,91	0,94

Próg klasyfikacji

nr	wynik	predykcja	prawda
1	-5.2	-	-
2	-3.8	-	-
3	-2.5	-	-
4	-1.4	-	-
5	-0.5	-	+
6	-0.3	-	+
7	0.2	+	-
8	0.8	+	-
9	1.2	+	+
10	2.5	+	+
11	3.3	+	+
12	4.8	+	+


$$f(x) > \text{próg} \implies +$$

$$f(x) < \text{próg} \implies -$$

- Jak zmienia się precyzja, gdy obniżamy próg od $+\infty$ do $-\infty$?
- Jak zmienia się czułość, gdy obniżamy próg od $+\infty$ do $-\infty$?

Krzywa ROC (Receiver Operating Characteristic)

Krzywa ROC reprezentuje efektywność modelu predykcyjnego. Wykres krzywej ilustruje zależność czułości, czyli poziomu wyników prawdziwie dodatnich $TP/(TP+FN)$, od poziomu wyników fałszywie pozytywnych $FP/(FP+TN)$.




Każdy punkt krzywej odpowiada innej macierzy błędów.

Klasyfikatory dyskryminatywne i generatywne

Klasyfikator generatywny: uczy się $p(x|y)$ (czyli skupia się na cechach danych w zależności od klasy) i $p(y)$.

Klasyfikator dyskryminatywny: uczy się $p(y|x)$.

**klasyfikatory
generatywne**




Klasyfikatory dyskryminatywne i generatywne


Klasyfikator generatywny: uczy się $p(x|y)$ (czyli skupia się na cechach danych w zależności od klasy) i $p(y)$.

Klasyfikator dyskryminatywny: uczy się $p(y|x)$.

**klasyfikatory
generatywne**



**klasyfikatory
dyskryminatywne**



Gaussowska analiza dyskryminacyjna

Niech $x \in \mathbb{R}^k$ oraz niech $y \in \{0, 1\}$. Zakładamy, że zmienna $x|y$ ma rozkład normalny:

$$y \sim \text{Bern}(\phi),$$

$$x|y = 0 \sim \mathcal{N}(\mu_0, \Sigma),$$

$$x|y = 1 \sim \mathcal{N}(\mu_1, \Sigma).$$

Gaussowska analiza dyskryminacyjna

Niech $x \in \mathbb{R}^k$ oraz niech $y \in \{0, 1\}$. Zakładamy, że zmienna $x|y$ ma rozkład normalny:

$$\begin{aligned}y &\sim \text{Bern}(\phi), \\x|y = 0 &\sim \mathcal{N}(\mu_0, \Sigma), \\x|y = 1 &\sim \mathcal{N}(\mu_1, \Sigma).\end{aligned}$$

Stąd

$$\begin{aligned}p(y) &= \phi^y(1 - \phi)^{1-y}, \\p(x|y = 0) &= \frac{1}{(2\pi)^{k/2}|\Sigma|^{1/2}} \exp\left(-\frac{(x - \mu_0)^T \Sigma^{-1}(x - \mu_0)}{2}\right), \\p(x|y = 1) &= \frac{1}{(2\pi)^{k/2}|\Sigma|^{1/2}} \exp\left(-\frac{(x - \mu_1)^T \Sigma^{-1}(x - \mu_1)}{2}\right).\end{aligned}$$

Powyższy model ma cztery parametry: ϕ , μ_0 , μ_1 i Σ .

Log-wiarygodność

Dla danych $\{(x^{(i)}, y^{(i)}): i = 1, \dots, m\}$ log-wiarygodność jest postaci

$$\ell(\phi, \mu_0, \mu_1, \Sigma) = \ln \prod_{i=1}^m p(x^{(i)}, y^{(i)}) = \ln \prod_{i=1}^m p(x^{(i)}|y^{(i)})p(y^{(i)}).$$

Log-wiarygodność

Dla danych $\{(x^{(i)}, y^{(i)}): i = 1, \dots, m\}$ log-wiarygodność jest postaci

$$\ell(\phi, \mu_0, \mu_1, \Sigma) = \ln \prod_{i=1}^m p(x^{(i)}, y^{(i)}) = \ln \prod_{i=1}^m p(x^{(i)}|y^{(i)})p(y^{(i)}).$$

Maksymalizując, dostajemy:


$$\phi = \frac{1}{m} \sum_{i=1}^m \mathbf{1}[y^{(i)} = 1],$$

$$\mu_0 = \frac{\sum_{i=1}^m \mathbf{1}[y^{(i)} = 0]x^{(i)}}{\sum_{i=1}^m \mathbf{1}[y^{(i)} = 0]},$$

$$\mu_1 = \frac{\sum_{i=1}^m \mathbf{1}[y^{(i)} = 1]x^{(i)}}{\sum_{i=1}^m \mathbf{1}[y^{(i)} = 1]},$$

$$\Sigma = \frac{1}{m} \sum_{i=1}^m (x^{(i)} - \mu_{y^{(i)}})^T (x^{(i)} - \mu_{y^{(i)}}).$$

Analiza dyskryminacyjna a regresja logistyczna




$$p(x|y = 1)$$

$$p(x|y = 0)$$

Dopasowujemy rozkłady normalne do danych treningowych.
Jak wygląda wykres $p(y = 1|x)$?

Analiza dyskryminacyjna a regresja logistyczna



Analiza dyskryminacyjna a regresja logistyczna

Otrzymujemy

$$p(y = 1|x, \phi, \Sigma, \mu_0, \mu_1) = \frac{1}{1 + \exp(-\theta^T x)},$$

gdzie θ jest zależna od parametrów $\phi, \Sigma, \mu_0, \mu_1$.

Analiza dyskryminacyjna a regresja logistyczna

Otrzymujemy

$$p(y = 1|x, \phi, \Sigma, \mu_0, \mu_1) = \frac{1}{1 + \exp(-\theta^T x)},$$

gdzie θ jest zależna od parametrów $\phi, \Sigma, \mu_0, \mu_1$.

Jeżeli $x|y$ ma rozkład normalny, to funkcja gęstości prawdopodobieństwa a posteriori $p(y = 1|x)$ jest funkcją logistyczną. Implikacji nie można odwrócić.

Analiza dyskryminacyjna a regresja logistyczna

Otrzymujemy

$$p(y = 1|x, \phi, \Sigma, \mu_0, \mu_1) = \frac{1}{1 + \exp(-\theta^T x)},$$

gdzie θ jest zależna od parametrów $\phi, \Sigma, \mu_0, \mu_1$.

Jeżeli $x|y$ ma rozkład normalny, to funkcja gęstości prawdopodobieństwa a posteriori $p(y = 1|x)$ jest funkcją logistyczną. Implikacji nie można odwrócić.

Gaussowska analiza dyskryminacyjna oparta jest zatem na silniejszym założeniu: jeśli rzeczywiście $x|y$ ma rozkład normalny, to otrzymamy najczęściej lepszy wynik niż stosując regresję logistyczną. Jeśli jednak rozkład w rzeczywistości jest inny, to regresja logistyczna da lepszy wynik.

E – miało miejsce trzęsienie ziemi

R – w radiu podano komunikat o trzęsieniu ziemi

B – miało miejsce włamanie

A – włączył się alarm

E – miało miejsce trzęsienie ziemi

R – w radiu podano komunikat o trzęsieniu ziemi

B – miało miejsce włamanie

A – włączył się alarm

$$P(A, E, B, R) = P(B) \cdot P(E) \cdot P(R|E) \cdot P(A|E, B)$$

E – miało miejsce trzęsienie ziemi

R – w radiu podano komunikat o trzęsieniu ziemi

B – miało miejsce włamanie

A – włączył się alarm

$$P(A, E, B, R) = P(B) \cdot P(E) \cdot P(R|E) \cdot P(A|E, B)$$

$$P(B = 1) = 10^{-3}$$

$$P(B = 0) = 1 - 10^{-3}$$

$$P(E = 1) = 10^{-3}$$

$$P(E = 0) = 1 - 10^{-3}$$

$$P(R = 1|E = 1) = 1$$

$$P(R = 1|E = 0) = 0$$

$$P(A = 0|B = 0, E = 0) = (1 - f)$$

$$P(A = 1|B = 0, E = 0) = 10^{-3}$$

$$P(A = 0|B = 1, E = 0) = (1 - f)(1 - a_B)$$

$$P(A = 1|B = 1, E = 0) = 1 - (1 - f)(1 - a_B)$$

$$P(A = 0|B = 0, E = 1) = (1 - f)(1 - a_E)$$

$$P(A = 1|B = 0, E = 1) = 1 - (1 - f)(1 - a_E)$$

$$P(A = 0|B = 1, E = 1) = (1 - f)(1 - a_B)(1 - a_E) \quad P(A = 1|B = 1, E = 1) = 1 - (1 - f)(1 - a_B)(1 - a_E)$$

$f = 0.001$ (fałszywy alarm), $a_E = 0.001$ (alarm przy trzęsieniu), $a_B = 0.999$ (alarm przy włamaniu)

Jakie jest prawdopodobieństwo, że miało miejsce włamanie lub trzęsienie ziemi, jeśli włączył się alarm?

Jakie jest prawdopodobieństwo, że miało miejsce włamanie lub trzęsienie ziemi, jeśli włączył się alarm?

$$P(B, E|A = 1) = \frac{P(A = 1|B, E) \cdot P(B) \cdot P(E)}{P(A = 1)}$$

$$P(A = 1) = \dots = 0.002$$

Jakie jest prawdopodobieństwo, że miało miejsce włamanie lub trzęsienie ziemi, jeśli włączył się alarm?

$$P(B, E|A = 1) = \frac{P(A = 1|B, E) \cdot P(B) \cdot P(E)}{P(A = 1)}$$

$$P(A = 1) = \dots = 0.002$$

$$\begin{array}{ll} P(B = 0, E = 0|A = 1) = 0.4993 & P(B = 1, E = 0|A = 1) = 0.4947 \\ P(B = 0, E = 1|A = 1) = 0.0055 & P(B = 1, E = 1|A = 1) = 0.0005 \end{array}$$

Jakie jest prawdopodobieństwo, że miało miejsce włamanie lub trzęsienie ziemi, jeśli włączył się alarm?

$$P(B, E|A = 1) = \frac{P(A = 1|B, E) \cdot P(B) \cdot P(E)}{P(A = 1)}$$

$$P(A = 1) = \dots = 0.002$$

$$P(B = 0, E = 0|A = 1) = 0.4993 \quad P(B = 1, E = 0|A = 1) = 0.4947$$

$$P(B = 0, E = 1|A = 1) = 0.0055 \quad P(B = 1, E = 1|A = 1) = 0.0005$$

$$P(B = 0|A = 1) = 0.505$$

$$P(B = 1|A = 1) = 0.495$$

Jakie jest prawdopodobieństwo, że miało miejsce włamanie lub trzęsienie ziemi, jeśli włączył się alarm?

$$P(B, E|A = 1) = \frac{P(A = 1|B, E) \cdot P(B) \cdot P(E)}{P(A = 1)}$$

$$P(A = 1) = \dots = 0.002$$

$$P(B = 0, E = 0|A = 1) = 0.4993 \quad P(B = 1, E = 0|A = 1) = 0.4947$$

$$P(B = 0, E = 1|A = 1) = 0.0055 \quad P(B = 1, E = 1|A = 1) = 0.0005$$

$$P(B = 0|A = 1) = 0.505$$

$$P(B = 1|A = 1) = 0.495$$

Uwaga: $B \perp E$, ale $B \not\perp E|A$!

Jakie jest prawdopodobieństwo włamania, jeśli włączył się alarm i w radiu poinformowano o trzęsieniu ziemi?

$$P(B = 0|E = 1, A = 1) = \frac{P(B = 0, E = 1|A = 1)}{P(E = 1|A = 1)} = 0.92$$

$$P(B = 1|E = 1, A = 1) = \frac{P(B = 1, E = 1|A = 1)}{P(E = 1|A = 1)} = 0.08$$

Warunkowa niezależność cech

Rozważmy wektor $x = [x_1, \dots, x_k]^T$ oraz daną wyjściową y . Wtedy

$$\begin{aligned} p(x|y) &= p(x_1, \dots, x_k|y) \\ &= p(x_1|y) \cdot p(x_2|y, x_1) \cdot \dots \cdot p(x_k|y, x_1, \dots, x_{k-1}). \end{aligned}$$

Warunkowa niezależność cech

Rozważmy wektor $x = [x_1, \dots, x_k]^T$ oraz daną wyjściową y . Wtedy

$$\begin{aligned} p(x|y) &= p(x_1, \dots, x_k|y) \\ &= p(x_1|y) \cdot p(x_2|y, x_1) \cdot \dots \cdot p(x_k|y, x_1, \dots, x_{k-1}). \end{aligned}$$

Założmy, że wszystkie x_j są warunkowo niezależne, czyli

$$p(x_1, \dots, x_k|y) = p(x_1|y) \cdot p(x_2|y) \cdot \dots \cdot p(x_k|y) = \prod_{j=1}^k p(x_j|y).$$


Warunkowa niezależność cech

Rozważmy wektor $x = [x_1, \dots, x_k]^T$ oraz daną wyjściową y . Wtedy

$$\begin{aligned} p(x|y) &= p(x_1, \dots, x_k|y) \\ &= p(x_1|y) \cdot p(x_2|y, x_1) \cdot \dots \cdot p(x_k|y, x_1, \dots, x_{k-1}). \end{aligned}$$

Założmy, że wszystkie x_j są warunkowo niezależne, czyli

$$p(x_1, \dots, x_k|y) = p(x_1|y) \cdot p(x_2|y) \cdot \dots \cdot p(x_k|y) = \prod_{j=1}^k p(x_j|y).$$



Przykład: spam czy nie spam?

Rozważmy słownik zawierający k słów. Otrzymany e-mail reprezentujemy jako wektor binarny $[x_1, \dots, x_k]^T$, gdzie $x_j = 1$ wtedy i tylko wtedy, gdy j -te słowo ze słownika znajduje się w mailu.

$$x = \begin{bmatrix} 1 \\ 0 \\ \vdots \\ 1 \\ \vdots \\ 1 \\ \vdots \\ 0 \end{bmatrix} \begin{array}{l} \text{a} \\ \text{Aachen} \\ \vdots \\ \text{ale} \\ \vdots \\ \text{wakacje} \\ \vdots \\ \text{żyźniejszy} \end{array}$$

Założenie o niezależności występowania poszczególnych słów jest bardzo silne (i fałszywe), pozwala jednak na istotną redukcję parametrów.

Naiwny klasyfikator bayesowski

Jeśli $y, x_1, \dots, x_k \in \{0, 1\}$, to naiwny klasyfikator bayesowski ma $2k + 1$ parametrów:

$$\phi_{j|y=0} = p(x_j = 1|y = 0),$$

$$\phi_{j|y=1} = p(x_j = 1|y = 1),$$

$$\phi_y = p(y = 1).$$

Naiwny klasyfikator bayesowski

Jeśli $y, x_1, \dots, x_k \in \{0, 1\}$, to naiwny klasyfikator bayesowski ma $2k + 1$ parametrów:

$$\phi_{j|y=0} = p(x_j = 1|y = 0),$$

$$\phi_{j|y=1} = p(x_j = 1|y = 1),$$

$$\phi_y = p(y = 1).$$

Wtedy funkcja łącznej wiarygodności ma postać

$$L(\phi_y, \phi_{j|y=0}, \phi_{j|y=1}) = \prod_{i=1}^m p(x^{(i)}, y^{(i)}).$$

Naiwny klasyfikator bayesowski

Jeśli $y, x_1, \dots, x_k \in \{0, 1\}$, to naiwny klasyfikator bayesowski ma $2k + 1$ parametrów:

$$\phi_{j|y=0} = p(x_j = 1|y = 0),$$

$$\phi_{j|y=1} = p(x_j = 1|y = 1),$$

$$\phi_y = p(y = 1).$$

Wtedy funkcja łącznej wiarygodności ma postać

$$L(\phi_y, \phi_{j|y=0}, \phi_{j|y=1}) = \prod_{i=1}^m p(x^{(i)}, y^{(i)}).$$

Wówczas, stosując metodę największej wiarygodności, dostajemy

$$\phi_{j|y=c} = \frac{\sum_{i=1}^m \mathbf{1}[x_j^{(i)} = 1, y^{(i)} = c]}{\sum_{i=1}^m \mathbf{1}[y^{(i)} = c]}, \quad \phi_y = \frac{1}{m} \sum_{i=1}^m \mathbf{1}[y^{(i)} = 1].$$

Naiwny klasyfikator bayesowski

Na podstawie otrzymanych parametrów obliczamy

$$\begin{aligned} p(y = 1|x) &= \frac{p(x|y = 1)p(y = 1)}{p(x)} \\ &= \frac{p(y = 1) \prod_{j=1}^k p(x_j|y = 1)}{p(y = 1) \prod_{j=1}^k p(x_j|y = 1) + p(y = 0) \prod_{j=1}^k p(x_j|y = 0)} \end{aligned}$$

i wybieramy klasę, 0 lub 1, dla której prawdopodobieństwo a posteriori jest wyższe.

Naiwny klasyfikator bayesowski

Na podstawie otrzymanych parametrów obliczamy

$$\begin{aligned} p(y = 1|x) &= \frac{p(x|y = 1)p(y = 1)}{p(x)} \\ &= \frac{p(y = 1) \prod_{j=1}^k p(x_j|y = 1)}{p(y = 1) \prod_{j=1}^k p(x_j|y = 1) + p(y = 0) \prod_{j=1}^k p(x_j|y = 0)} \end{aligned}$$

i wybieramy klasę, 0 lub 1, dla której prawdopodobieństwo a posteriori jest wyższe.

Powyższe rozważania dotyczą cech binarnych ($x_j \in \{0, 1\}$), można je jednak rozszerzyć na cechy o większej liczbie wartości. W przypadku cech ciągłych można dokonać ich dyskretyzacji, czyli podziału zbioru wartości na skończoną liczbę przedziałów.

Coś tu nie gra

Na egzamin przychodzi student, który do tej pory w pierwszym terminie otrzymywał następujące oceny z poszczególnych przedmiotów:

Coś tu nie gra

Na egzamin przychodzi student, który do tej pory w pierwszym terminie otrzymywał następujące oceny z poszczególnych przedmiotów:

przedmiot	ocena	zdał?
Metody formalne informatyki		

Coś tu nie gra

Na egzamin przychodzi student, który do tej pory w pierwszym terminie otrzymywał następujące oceny z poszczególnych przedmiotów:

przedmiot	ocena	zdał?
Metody formalne informatyki	2	0
Programowanie obiektowe		

Coś tu nie gra

Na egzamin przychodzi student, który do tej pory w pierwszym terminie otrzymywał następujące oceny z poszczególnych przedmiotów:

przedmiot	ocena	zdał?
Metody formalne informatyki	2	0
Programowanie obiektowe	2	0
Matematyka dyskretna		

Coś tu nie gra

Na egzamin przychodzi student, który do tej pory w pierwszym terminie otrzymywał następujące oceny z poszczególnych przedmiotów:

przedmiot	ocena	zdał?
Metody formalne informatyki	2	0
Programowanie obiektowe	2	0
Matematyka dyskretna	2	0
Metody probabilistyczne		

Coś tu nie gra

Na egzamin przychodzi student, który do tej pory w pierwszym terminie otrzymywał następujące oceny z poszczególnych przedmiotów:

przedmiot	ocena	zdał?
Metody formalne informatyki	2	0
Programowanie obiektowe	2	0
Matematyka dyskretna	2	0
Metody probabilistyczne	2	0
MPUM	?	?

Jakie jest prawdopodobieństwo, że student zda egzamin z MPUM w pierwszym terminie?

Wykładzenie Laplace'a

Na podstawie wcześniejszych wzorów mamy

$$p(y = 1) = \frac{\sum_{i=1}^4 \mathbf{1}[y^{(i)} = 1]}{\sum_{i=1}^4 \mathbf{1}[y^{(i)} = 1] + \sum_{i=1}^4 \mathbf{1}[y^{(i)} = 0]} = \frac{0}{4} = 0.$$

Ale to przecież nieprawda. Dlatego dodajemy *wygładzenie Laplace'a*. W ogólnym przypadku dla $y \in \{1, \dots, k\}$ estymujemy

$$p(y = j) = \frac{1 + \sum_{i=1}^m \mathbf{1}[y^{(i)} = j]}{m + k}.$$

Parametry w naiwnym klasyfikatorze bayesowskim są postaci:

$$\begin{aligned}\phi_{j|y=1} &= \frac{1 + \sum_{i=1}^m \mathbf{1}[x_j^{(i)} = 1 \wedge y^{(i)} = 1]}{2 + \sum_{i=1}^m \mathbf{1}[y^{(i)} = 1]}, \\ \phi_{j|y=0} &= \frac{1 + \sum_{i=1}^m \mathbf{1}[x_j^{(i)} = 1 \wedge y^{(i)} = 0]}{2 + \sum_{i=1}^m \mathbf{1}[y^{(i)} = 0]}.\end{aligned}$$

Wariant naiwnego klasyfikatora bayesowskiego

Zamiast reprezentować e-mail jako wektor cech binarnych o długości k możemy reprezentować go jako wektor o długości równej liczbie słów w mailu, w którym na każdej pozycji znajduje się indeks odpowiadający pozycji danego słowa w słowniku:

$$x = \begin{bmatrix} 15034 \\ 13987 \\ \vdots \\ 1 \\ \vdots \\ 49831 \\ \vdots \\ 36745 \end{bmatrix} \begin{array}{l} \text{Dzień} \\ \text{dobry} \\ \vdots \\ \text{a} \\ \vdots \\ \text{wakacje} \\ \vdots \\ \text{pozdrawiam} \end{array}$$

W ogólności:

$$p(x, y) = p(y) \prod_{j=1}^n p(x_j | y),$$

gdzie $x_j \in \{1, \dots, k\}$.

Wariant naiwnego klasyfikatora bayesowskiego

Zakładamy, że mamy m obserwacji $\{(x^{(i)}, y^{(i)}): i = 1, \dots, m\}$ takich, że długość wektora $x^{(i)}$ wynosi n_i oraz $x_j^{(i)} \in \{1, \dots, n\}$ i $y^{(i)} \in \{0, 1\}$ dla wszystkich i .

Wtedy (po zastosowaniu wygładzenia Laplace'a) parametry modelu są następujące:

$$\begin{aligned}\phi_{k|y=1} &= \frac{1 + \sum_{i=1}^m \mathbf{1}[y^{(i)} = 1] \sum_{j=1}^{n_i} \mathbf{1}[x_j^{(i)} = k]}{n + \sum_{i=1}^m \mathbf{1}[y^{(i)} = 1] n_i}, \\ \phi_{k|y=0} &= \frac{1 + \sum_{i=1}^m \mathbf{1}[y^{(i)} = 0] \sum_{j=1}^{n_i} \mathbf{1}[x_j^{(i)} = k]}{n + \sum_{i=1}^m \mathbf{1}[y^{(i)} = 0] n_i}, \\ \phi_y &= \frac{1 + \sum_{i=1}^m \mathbf{1}[y^{(i)} = 1] n_i}{2 + \sum_{i=1}^m n_i}.\end{aligned}$$

Naiwny klasyfikator bayesowski: podsumowanie

Zalety

- prostota
- niewielkie wymagania względem liczności zbioru treningowego
- szybkość
- liniowa skalowalność względem liczby cech i liczności zbioru treningowego
- możliwość zastosowania w problemach klasyfikacji binarnej i wieloklasowej

Wady

- naiwność wynikająca z silnego założenia warunkowej niezależności cech
- możliwość zwracania złych wyników w następstwie założenia niezależności cech