

Metody probabilistyczne w uczeniu maszynowym

Wykład 6: perceptron, podstawy teorii optymalizacji,
maszyny wektorów nośnych

Katarzyna Grygiel


Semestr letni 2025/2026

Zbiory liniowo separowalne

Zbiory A i B będące podzbiorami $\mathbb{R}^k$ są *liniowo separowalne*, gdy istnieją $b \in \mathbb{R}$ i $w \in \mathbb{R}^k$ takie, że $w^T x + b < 0$ dla każdego $x \in A$ oraz $w^T x + b > 0$ dla każdego $x \in B$.


Zbiory liniowo separowalne

Zbiory A i B będące podzbiórami $\mathbb{R}^k$ są *liniowo separowalne*, gdy istnieją $b \in \mathbb{R}$ i $w \in \mathbb{R}^k$ takie, że $w^T x + b < 0$ dla każdego $x \in A$ oraz $w^T x + b > 0$ dla każdego $x \in B$.



Zbiory liniowo separowalne

Zbiory A i B będące podzbiórami $\mathbb{R}^k$ są *liniowo separowalne*, gdy istnieją $b \in \mathbb{R}$ i $w \in \mathbb{R}^k$ takie, że $w^T x + b < 0$ dla każdego $x \in A$ oraz $w^T x + b > 0$ dla każdego $x \in B$.



Klasyfikacja dla danych liniowo separowalnych

Rozważmy problem klasyfikacji danych liniowo separowalnych z przestrzenią wejść $\mathcal{X} = \mathbb{R}^k$ i wyjść $\mathcal{Y} = \{-1, 1\}$.

W celu poprawnej klasyfikacji wystarczy wyznaczyć hiperpłaszczyznę $w^T x + b$, gdzie $w \in \mathbb{R}^k$ i $b \in \mathbb{R}$, taką, że

$$w^T x + b > 0 \text{ wtedy i tylko wtedy, gdy } y = 1$$

oraz

$$w^T x + b < 0 \text{ wtedy i tylko wtedy, gdy } y = -1.$$

Klasyfikacja dla danych liniowo separowalnych

Rozważmy problem klasyfikacji danych liniowo separowalnych z przestrzenią wejść $\mathcal{X} = \mathbb{R}^k$ i wyjść $\mathcal{Y} = \{-1, 1\}$.

W celu poprawnej klasyfikacji wystarczy wyznaczyć hiperpłaszczyznę $w^T x + b$, gdzie $w \in \mathbb{R}^k$ i $b \in \mathbb{R}$, taką, że

$$w^T x + b > 0 \text{ wtedy i tylko wtedy, gdy } y = 1$$

oraz

$$w^T x + b < 0 \text{ wtedy i tylko wtedy, gdy } y = -1.$$

Wtedy funkcja decyzyjna jest postaci

$$h_{w,b}(x) = \begin{cases} 1, & \text{gdzie } w^T x + b > 0, \\ -1, & \text{gdzie } w^T x + b < 0. \end{cases}$$

Perceptron

Algorytm uczący perceptron

$w \leftarrow \vec{0}$;

while istnieje $i \in \{1, \dots, m\}$ takie, że $y^{(i)}(w^T x^{(i)}) \leq 0$ **do**
 wybierz dowolny $j \in \{1, \dots, m\}$, dla którego $y^{(j)}(w^T x^{(j)}) \leq 0$;
 $w \leftarrow w + y^{(j)} x^{(j)}$;


end

return w ;


W powyższym przyjmujemy

$$w \leftarrow \begin{bmatrix} b \\ w \end{bmatrix}$$



$$x^{(i)} \leftarrow \begin{bmatrix} 1 \\ x^{(i)} \end{bmatrix}$$






Przykład działania







Przykład działania



Przykład działania



Przykład działania



Zbieżność perceptronu

Twierdzenie (Block, Novikoff; 1962)

Niech dany będzie zbiór treningowy


$$D = \{(x^{(i)}, y^{(i)}) : i = 1, \dots, m\} \subset \mathbb{R}^k \times \{-1, 1\}$$

taki, że istnieją $R, \gamma > 0$ oraz $w^ \in \mathbb{R}^{k+1}$ takie, że $\|w^*\| = 1$ oraz dla wszystkich $i \in \{1, \dots, m\}$ zachodzą nierówności*


$$y^{(i)} ((w^*)^T [1; x^{(i)}]) > \gamma \quad \text{oraz} \quad \|[1; x^{(i)}]\| \leq R.$$

Wtedy algorytm uczący perceptron dla D wykonuje co najwyżej R^2/γ^2 zmian wartości wektora w .


Optymalne dopasowanie




Optymalne dopasowanie




Optymalne dopasowanie



Optymalne dopasowanie



Optymalne dopasowanie



Margines

Zauważmy, że dla hiperpłaszczyzny $w^T x + b$ dobrze separującej dane oraz dla obserwacji $(x^{(i)}, y^{(i)})$ margines

$$\hat{\gamma}^{(i)} := (w^T x^{(i)} + b) y^{(i)}$$

jest zawsze dodatni. Margines dla zbioru D to $\hat{\gamma} := \min_i \hat{\gamma}^{(i)}$.

Margines

Zauważmy, że dla hiperpłaszczyzny $w^T x + b$ dobrze separującej dane oraz dla obserwacji $(x^{(i)}, y^{(i)})$ margines

$$\hat{\gamma}^{(i)} := (w^T x^{(i)} + b) y^{(i)}$$

jest zawsze dodatni. Margines dla zbioru D to $\hat{\gamma} := \min_i \hat{\gamma}^{(i)}$.

Czy warto szukać w i b maksymalizujących $\hat{\gamma}$?

Margines

Zauważmy, że dla hiperpłaszczyzny $w^T x + b$ dobrze separującej dane oraz dla obserwacji $(x^{(i)}, y^{(i)})$ margines

$$\hat{\gamma}^{(i)} := (w^T x^{(i)} + b)y^{(i)}$$

jest zawsze dodatni. Margines dla zbioru D to $\hat{\gamma} := \min_i \hat{\gamma}^{(i)}$.

Czy warto szukać w i b maksymalizujących $\hat{\gamma}$? Nie bardzo.

Możemy zawsze przeskalować $(w, b) \mapsto (C \cdot w, C \cdot b)$ dla dowolnej stałej $C > 0$ — wtedy wartość $\hat{\gamma}$ może być dowolnie duża, natomiast hiperpłaszczyzna się nie zmienia.

Margines

Zauważmy, że dla hiperpłaszczyzny $w^T x + b$ dobrze separującej dane oraz dla obserwacji $(x^{(i)}, y^{(i)})$ margines

$$\hat{\gamma}^{(i)} := (w^T x^{(i)} + b) y^{(i)}$$

jest zawsze dodatni. Margines dla zbioru D to $\hat{\gamma} := \min_i \hat{\gamma}^{(i)}$.


Czy warto szukać w i b maksymalizujących $\hat{\gamma}$? Nie bardzo.

Możemy zawsze przeskalować $(w, b) \mapsto (C \cdot w, C \cdot b)$ dla dowolnej stałej $C > 0$ – wtedy wartość $\hat{\gamma}$ może być dowolnie duża, natomiast hiperpłaszczyzna się nie zmienia.


Dlatego wprowadzamy pojęcie *marginesu geometrycznego*:

$$\gamma^{(i)} := \frac{\hat{\gamma}^{(i)}}{\|w\|}, \quad \gamma := \frac{\hat{\gamma}}{\|w\|}.$$


Margines geometryczny



Margines geometryczny




Jak znaleźć wartość $\gamma^{(i)}$?



Wektor $w/\|w\|$ jest wektorem normalnym do hiperpłaszczyzny.


Jak znaleźć wartość $\gamma^{(i)}$?



Wektor $w/\|w\|$ jest wektorem normalnym do hiperpłaszczyzny.

Rzut punktu $x^{(i)}$ na $w^T x + b$ wyznacza punkt $x^{(i)} \pm \gamma^{(i)} w/\|w\|$.

Jak znaleźć wartość $\gamma^{(i)}$?




Wektor $w/\|w\|$ jest wektorem normalnym do hiperpłaszczyzny.

Rzut punktu $x^{(i)}$ na $w^T x + b$ wyznacza punkt $x^{(i)} \pm \gamma^{(i)} w/\|w\|$.

Ten punkt leży na granicy decyzyjnej, zatem

$$w^T(x^{(i)} \pm \gamma^{(i)} w/\|w\|) + b = 0.$$

Jak znaleźć wartość $\gamma^{(i)}$?



Wektor $w/\|w\|$ jest wektorem normalnym do hiperpłaszczyzny.

Rzut punktu $x^{(i)}$ na $w^T x + b$ wyznacza punkt $x^{(i)} \pm \gamma^{(i)} w/\|w\|$.

Ten punkt leży na granicy decyzyjnej, zatem

$$w^T (x^{(i)} \pm \gamma^{(i)} w/\|w\|) + b = 0.$$

Ostatecznie otrzymujemy, że margines geometryczny dla hiperpłaszczyzny $w^T x + b$ i punktu $(x^{(i)}, y^{(i)})$ to

$$\gamma^{(i)} = y^{(i)} \left(\frac{w^T}{\|w\|} x^{(i)} + \frac{b}{\|w\|} \right).$$

Klasyfikator optymalizujący marginesy

Mamy zatem taki problem optymalizacyjny:

$$\begin{array}{ll} \text{zmaksymalizować} & \gamma \\ \text{pod warunkiem} & y^{(i)} (\mathbf{w}^T \mathbf{x}^{(i)} + b) \geq \gamma, \quad i = 1, \dots, m, \\ & \|\mathbf{w}\| = 1. \end{array}$$

Klasyfikator optymalizujący marginesy

Mamy zatem taki problem optymalizacyjny:

$$\begin{array}{ll} \text{zmaksymalizować} & \gamma \\ \text{pod warunkiem} & y^{(i)} (\mathbf{w}^T \mathbf{x}^{(i)} + b) \geq \gamma, \quad i = 1, \dots, m, \\ & \|\mathbf{w}\| = 1. \end{array}$$

Możemy go zapisać równoważnie następująco:

$$\begin{array}{ll} \text{zmaksymalizować} & \hat{\gamma} / \|\mathbf{w}\| \\ \text{pod warunkiem} & y^{(i)} (\mathbf{w}^T \mathbf{x}^{(i)} + b) \geq \hat{\gamma}, \quad i = 1, \dots, m. \end{array}$$

Klasyfikator optymalizujący marginesy

Mamy zatem taki problem optymalizacyjny:

$$\begin{array}{ll}\text{zmaksymalizować} & \gamma \\ \text{pod warunkiem} & y^{(i)} (\mathbf{w}^T \mathbf{x}^{(i)} + b) \geq \gamma, \quad i = 1, \dots, m, \\ & \|\mathbf{w}\| = 1.\end{array}$$

Możemy go zapisać równoważnie następująco:

$$\begin{array}{ll}\text{zmaksymalizować} & \hat{\gamma} / \|\mathbf{w}\| \\ \text{pod warunkiem} & y^{(i)} (\mathbf{w}^T \mathbf{x}^{(i)} + b) \geq \hat{\gamma}, \quad i = 1, \dots, m.\end{array}$$

Przyjmując $\hat{\gamma} = 1$ zapisujemy powyższy problem tak:

$$\begin{array}{ll}\text{zminimalizować} & \frac{1}{2} \|\mathbf{w}\|^2 \\ \text{pod warunkiem} & y^{(i)} (\mathbf{w}^T \mathbf{x}^{(i)} + b) \geq 1, \quad i = 1, \dots, m.\end{array}$$

Ale nie zawsze jest tak pięknie


Co zrobić, jeśli dane nie są separowalne?

I co w przypadku, gdy mamy obserwacje odstające?

Ale nie zawsze jest tak pięknie

Co zrobić, jeśli dane nie są separowalne?


I co w przypadku, gdy mamy obserwacje odstające?



Ale nie zawsze jest tak pięknie

Co zrobić, jeśli dane nie są separowalne?

I co w przypadku, gdy mamy obserwacje odstające?



Regularyzacja

Zmieniamy problem optymalizacyjny dodając regularyzację:

zminimalizować $\frac{1}{2} \|w\|^2 + \frac{C}{m} \sum_{i=1}^m \xi_i$

pod warunkiem $y^{(i)} (w^T x^{(i)} + b) \geq 1 - \xi_i, \quad i = 1, \dots, m,$
 $\xi_i \geq 0, \quad i = 1, \dots, m.$

Regularyzacja

Zmieniamy problem optymalizacyjny dodając regularyzację:

$$\text{zminimalizować} \quad \frac{1}{2} \|w\|^2 + \frac{C}{m} \sum_{i=1}^m \xi_i$$

$$\text{pod warunkiem} \quad y^{(i)} (w^T x^{(i)} + b) \geq 1 - \xi_i, \quad i = 1, \dots, m,$$
$$\xi_i \geq 0, \quad i = 1, \dots, m.$$

Oznacza to, że jeśli i -ta obserwacja będzie miała margines $1 - \xi_i$, to poniesiemy dodatkowy koszt zwiększając funkcję celu o $\frac{C\xi_i}{m}$.

Regularyzacja

Zmieniamy problem optymalizacyjny dodając regularyzację:

$$\text{zminimalizować} \quad \frac{1}{2} \|w\|^2 + \frac{C}{m} \sum_{i=1}^m \xi_i$$

$$\text{pod warunkiem} \quad y^{(i)} (w^T x^{(i)} + b) \geq 1 - \xi_i, \quad i = 1, \dots, m, \\ \xi_i \geq 0, \quad i = 1, \dots, m.$$

Oznacza to, że jeśli i -ta obserwacja będzie miała margines $1 - \xi_i$, to poniesiemy dodatkowy koszt zwiększając funkcję celu o $\frac{C\xi_i}{m}$.

Zauważmy, że powyższy problem jest równoważny problemowi

$$\min_{w,b} \frac{1}{2} \|w\|^2 + \frac{C}{m} \sum_{i=1}^m \max \left\{ 0, 1 - y^{(i)} (w^T x^{(i)} + b) \right\}.$$

Regularyzacja

Zmieniamy problem optymalizacyjny dodając regularyzację:

$$\begin{aligned} \text{zminimalizować} \quad & \frac{1}{2} \|w\|^2 + \frac{C}{m} \sum_{i=1}^m \xi_i \\ \text{pod warunkiem} \quad & y^{(i)} (w^T x^{(i)} + b) \geq 1 - \xi_i, \quad i = 1, \dots, m, \\ & \xi_i \geq 0, \quad i = 1, \dots, m. \end{aligned}$$

Oznacza to, że jeśli i -ta obserwacja będzie miała margines $1 - \xi_i$, to poniesiemy dodatkowy koszt zwiększając funkcję celu o $\frac{C\xi_i}{m}$.

Zauważmy, że powyższy problem jest równoważny problemowi

$$\min_{w,b} \frac{1}{2} \|w\|^2 + \frac{C}{m} \sum_{i=1}^m \max \left\{ 0, 1 - y^{(i)} (w^T x^{(i)} + b) \right\}.$$

Czyli minimalizujemy funkcję błędu z zawiasową funkcją straty i regularyzacją ℓ^2 o parametrze $1/C$.

Problemy optymalizacyjne

Rozważmy problem optymalizacyjny postaci:

$$\begin{aligned} &\text{zminimalizować} && f_0(x) \\ &\text{pod warunkiem} && f_i(x) \leq 0, \quad i = 1, \dots, n_1, \\ & && h_i(x) = 0, \quad i = 1, \dots, n_2, \end{aligned}$$

dla zmiennych optymalizacyjnych $x \in \mathbb{R}^k$.

Punkt x spełniający ograniczenia nazywamy *dopuszczalnym*.

Jeśli x jest punktem dopuszczalnym i $f_i(x) = 0$, to warunek $f_i(x) \leq 0$ jest *aktywny* w x .

Punkt x^* jest rozwiązaniem problemu, gdy x^* jest dopuszczalny oraz

$$f_0(x^*) = \inf\{f_0(x) : x \text{ spełnia wszystkie ograniczenia}\}.$$

Wartość $f_0(x^*)$ nazywamy *optymalną* i często oznaczamy przez p^* .

Mnożniki Lagrange'a

Ponieważ warunek $h_i(x) = 0$ możemy zapisać równoważnie jako $h_i(x) \leq 0$ oraz $-h_i(x) \leq 0$, problemy optymalizacyjne będą postaci

$$\begin{array}{ll} \text{zminimalizować} & f_0(x) \\ \text{pod warunkiem} & f_i(x) \leq 0, \quad i = 1, \dots, n. \end{array}$$

Funkcję Lagrange'a dla powyższego problemu nazywamy funkcję

$$L(x, \lambda) = f_0(x) + \sum_{i=1}^n \lambda_i f_i(x).$$

Zmienne λ_i nazywamy *mnożnikami Lagrange'a*.

Problem pierwotny i dualny

Zauważmy, że

$$\sup_{\lambda \geq 0} L(x, \lambda) = \begin{cases} f_0(x), & \text{gdy } f_i(x) \leq 0 \text{ dla każdego } i = 1, \dots, n, \\ \infty & \text{w przeciwnym przypadku.} \end{cases}$$

Problem pierwotny i dualny

Zauważmy, że

$$\sup_{\lambda \geq 0} L(x, \lambda) = \begin{cases} f_0(x), & \text{gdy } f_i(x) \leq 0 \text{ dla każdego } i = 1, \dots, n, \\ \infty & \text{w przeciwnym przypadku.} \end{cases}$$

Zatem rozwiązanie problemu optymalizacyjnego możemy zapisać następująco:

$$p^* := \inf_x \sup_{\lambda \geq 0} L(x, \lambda).$$

Problem pierwotny i dualny

Zauważmy, że

$$\sup_{\lambda \geq 0} L(x, \lambda) = \begin{cases} f_0(x), & \text{gdy } f_i(x) \leq 0 \text{ dla każdego } i = 1, \dots, n, \\ \infty & \text{w przeciwnym przypadku.} \end{cases}$$

Zatem rozwiązanie problemu optymalizacyjnego możemy zapisać następująco:

$$p^* := \inf_x \sup_{\lambda \geq 0} L(x, \lambda).$$

Dualna funkcja Lagrange'a to funkcja

$$g(\lambda) = \inf_x L(x, \lambda) = \inf_x \left(f_0(x) + \sum_{i=1}^n \lambda_i f_i(x) \right).$$

Problem dualny polega na wyznaczeniu

$$d^* := \sup_{\lambda \geq 0} \inf_x L(x, \lambda).$$

Problemy wypukłe i silna dualność

Słaba dualność

Dla dowolnego problemu optymalizacyjnego zachodzi $p^* \geq d^*$.

Problemy wypukłe i silna dualność

Słaba dualność

Dla dowolnego problemu optymalizacyjnego zachodzi $p^* \geq d^*$.

Zatem dla dowolnego $\lambda \geq 0$ funkcja dualna Lagrange'a wyznacza ograniczenie dolne na rozwiązanie oryginalnego problemu:

$$p^* \geq \sup_{\lambda \geq 0} g(\lambda).$$

Problemy wypukłe i silna dualność

Słaba dualność

Dla dowolnego problemu optymalizacyjnego zachodzi $p^* \geq d^*$.

Zatem dla dowolnego $\lambda \geq 0$ funkcja dualna Lagrange'a wyznacza ograniczenie dolne na rozwiązanie oryginalnego problemu:

$$p^* \geq \sup_{\lambda \geq 0} g(\lambda).$$

Problem dualny Lagrange'a polega na wyznaczeniu najlepszego ograniczenia dolnego na p^* :

$$\begin{array}{ll} \text{zmaksymalizować} & g(\lambda) \\ \text{pod warunkiem} & \lambda \geq 0. \end{array}$$

Problemy wypukłe

Jeśli wszystkie funkcje f_i w problemie optymalizacyjnym są wypukłe, to problem nazywamy *wypukłym*.

W przypadku problemów wypukłych często zachodzi *silna dualność*, czyli równość $p^* = d^*$.

Problemy wypukłe

Jeśli wszystkie funkcje f_i w problemie optymalizacyjnym są wypukłe, to problem nazywamy *wypukłym*.

W przypadku problemów wypukłych często zachodzi *silna dualność*, czyli równość $p^* = d^*$.

Twierdzenie

Jeżeli dziedzina wszystkich funkcji $f_0, f_1, \dots, f_n$ jest otwartym podzbiorem $\mathbb{R}^k$, to dla silnej dualności wystarcza istnienie punktu silnie dopuszczalnego, czyli $x \in \mathbb{R}^k$ takiego, że $f_i(x) < 0$ dla wszystkich $i = 1, \dots, n$.

Ponadto jeśli funkcje f_i dla wszystkich $i = 1, \dots, n$ są afiniczne, to wystarczy istnienie punktu dopuszczalnego.

Mnożniki i nierówności

Twierdzenie (Complementary slackness)

W przypadku silnej dualności dla problemu optymalizacyjnego (niekoniecznie wypukłego) zachodzi następująca zależność pomiędzy optymalnym mnożnikiem Lagrange'a λ_i^ oraz funkcją f_i w punkcie optymalnym x^* :*

$$\lambda_i^* f_i(x^*) = 0.$$

Mnożniki i nierówności

Twierdzenie (Complementary slackness)

W przypadku silnej dualności dla problemu optymalizacyjnego (niekoniecznie wypukłego) zachodzi następująca zależność pomiędzy optymalnym mnożnikiem Lagrange'a λ_i^ oraz funkcją f_i w punkcie optymalnym x^* :*

$$\lambda_i^* f_i(x^*) = 0.$$

Dowód.

Dla x^* będącego punktem optymalnym i λ^* będącego optymalnym punktem dla problemu dualnego mamy:

$$\begin{aligned} f_0(x^*) &= g(\lambda^*) = \inf_x L(x, \lambda^*) \leq L(x^*, \lambda^*) \\ &= f_0(x^*) + \sum_{i=1}^n \lambda_i^* f_i(x^*) \leq f_0(x^*). \end{aligned}$$

Stąd $\sum_{i=1}^n \lambda_i^* f_i(x^*) = 0$, czyli $\lambda_i^* f_i(x^*) = 0$ dla $i = 1, \dots, n$.

Problem wyznaczenia optymalnego marginesu

Teraz jesteśmy gotowi zaatakować problem:

$$\text{zminimalizować} \quad \frac{1}{2} \|w\|^2 + \frac{C}{m} \sum_{i=1}^m \xi_i$$

$$\text{pod warunkiem} \quad \begin{aligned} 1 - y^{(i)} (w^T x^{(i)} + b) - \xi_i &\leq 0, & i = 1, \dots, m, \\ -\xi_i &\leq 0, & i = 1, \dots, m. \end{aligned}$$

Problem wyznaczenia optymalnego marginesu

Teraz jesteśmy gotowi zaatakować problem:

$$\text{zminimalizować} \quad \frac{1}{2} \|w\|^2 + \frac{C}{m} \sum_{i=1}^m \xi_i$$

$$\text{pod warunkiem} \quad \begin{aligned} 1 - y^{(i)} (w^T x^{(i)} + b) - \xi_i &\leq 0, & i = 1, \dots, m, \\ -\xi_i &\leq 0, & i = 1, \dots, m. \end{aligned}$$

Funkcja Lagrange'a dla tego problemu to

$$\begin{aligned} L(w, b, \xi, \alpha, \lambda) = & \frac{1}{2} \|w\|^2 + \frac{C}{m} \sum_{i=1}^m \xi_i + \sum_{i=1}^m \lambda_i (-\xi_i) \\ & + \sum_{i=1}^m \alpha_i \left(1 - y^{(i)} (w^T x^{(i)} + b) - \xi_i \right). \end{aligned}$$

Problem pierwotny i dualny

$$\text{zminimalizować} \quad \frac{1}{2} \|w\|^2 + \frac{C}{m} \sum_{i=1}^m \xi_i$$

$$\text{pod warunkiem} \quad \begin{aligned} 1 - y^{(i)} (w^T x^{(i)} + b) - \xi_i &\leq 0, \quad i = 1, \dots, m, \\ -\xi_i &\leq 0, \quad i = 1, \dots, m. \end{aligned}$$

Na mocy słabej dualności mamy

$$p^* = \inf_{w, b, \xi} \sup_{\alpha, \lambda \geq 0} L(w, b, \xi, \alpha, \lambda) \geq \sup_{\alpha, \lambda \geq 0} \inf_{w, b, \xi} L(w, b, \xi, \alpha, \lambda) = d^*.$$

Problem pierwotny i dualny

$$\text{zminimalizować} \quad \frac{1}{2} \|w\|^2 + \frac{C}{m} \sum_{i=1}^m \xi_i$$

$$\text{pod warunkiem} \quad \begin{aligned} 1 - y^{(i)} (w^T x^{(i)} + b) - \xi_i &\leq 0, \quad i = 1, \dots, m, \\ -\xi_i &\leq 0, \quad i = 1, \dots, m. \end{aligned}$$

Na mocy słabej dualności mamy

$$p^* = \inf_{w, b, \xi} \sup_{\alpha, \lambda \geq 0} L(w, b, \xi, \alpha, \lambda) \geq \sup_{\alpha, \lambda \geq 0} \inf_{w, b, \xi} L(w, b, \xi, \alpha, \lambda) = d^*.$$

Czy zachodzi równość $p^* = d^*$?

Problem pierwotny i dualny

$$\text{zminimalizować} \quad \frac{1}{2} \|w\|^2 + \frac{C}{m} \sum_{i=1}^m \xi_i$$

$$\text{pod warunkiem} \quad \begin{aligned} 1 - y^{(i)} (w^T x^{(i)} + b) - \xi_i &\leq 0, \quad i = 1, \dots, m, \\ -\xi_i &\leq 0, \quad i = 1, \dots, m. \end{aligned}$$

Na mocy słabej dualności mamy

$$p^* = \inf_{w, b, \xi} \sup_{\alpha, \lambda \geq 0} L(w, b, \xi, \alpha, \lambda) \geq \sup_{\alpha, \lambda \geq 0} \inf_{w, b, \xi} L(w, b, \xi, \alpha, \lambda) = d^*.$$

Czy zachodzi równość $p^* = d^*$?

Problem jest wypukły, a funkcje z warunków afiniczne (względem b , w i ξ), wystarczy zatem istnienie punktu dopuszczalnego.

Problem pierwotny i dualny

$$\text{zminimalizować} \quad \frac{1}{2} \|w\|^2 + \frac{C}{m} \sum_{i=1}^m \xi_i$$

$$\text{pod warunkiem} \quad 1 - y^{(i)} (w^T x^{(i)} + b) - \xi_i \leq 0, \quad i = 1, \dots, m, \\ -\xi_i \leq 0, \quad i = 1, \dots, m.$$

Na mocy słabej dualności mamy

$$p^* = \inf_{w, b, \xi} \sup_{\alpha, \lambda \geq 0} L(w, b, \xi, \alpha, \lambda) \geq \sup_{\alpha, \lambda \geq 0} \inf_{w, b, \xi} L(w, b, \xi, \alpha, \lambda) = d^*.$$

Czy zachodzi równość $p^* = d^*$?

Problem jest wypukły, a funkcje z warunków afiniczne (względem b , w i ξ), wystarczy zatem istnienie punktu dopuszczalnego.

Dla $w = \vec{0}$, $b = 0$ oraz $\xi = \vec{1}$ warunki zachodzą, czyli $p^* = d^*$.

Dualna funkcja Lagrange'a

Na mocy silnej dualności chcemy wyznaczyć

$$\begin{aligned} g(\alpha, \lambda) &= \inf_{w, b, \xi} L(w, b, \xi, \alpha, \lambda) \\ &= \inf_{w, b, \xi} \frac{w^T w}{2} + \sum_{i=1}^m \xi_i \left(\frac{C}{m} - \alpha_i - \lambda_i \right) + \sum_{i=1}^m \alpha_i \left(1 - y^{(i)} (w^T x^{(i)} + b) \right). \end{aligned}$$

Poszukujemy infimum funkcji wypukłej i różniczkowalnej względem w , b i ξ . Jest ona ponadto kwadratowa ze względu na w i liniowa względem b i ξ . Wystarczy znaleźć punkt zerujący pochodne cząstkowe. Otrzymujemy warunki:

$$w = \sum_{i=1}^m \alpha_i y^{(i)} x^{(i)}, \quad \sum_{i=1}^m \alpha_i y^{(i)} = 0, \quad \frac{C}{m} = \alpha_i + \lambda_i.$$

Nowa postać dualnego problemu

Korzystając z otrzymanych warunków, dostajemy

$$g(\alpha, \lambda) = -\frac{1}{2} \sum_{i,j=1}^m \alpha_i \alpha_j y^{(i)} y^{(j)} (x^{(j)})^T x^{(i)} + \sum_{i=1}^m \alpha_i.$$

Nowa postać dualnego problemu

Korzystając z otrzymanych warunków, dostajemy

$$g(\alpha, \lambda) = -\frac{1}{2} \sum_{i,j=1}^m \alpha_i \alpha_j y^{(i)} y^{(j)} (x^{(j)})^T x^{(i)} + \sum_{i=1}^m \alpha_i.$$

Sprowadziliśmy oryginalny problem do problemu dualnego postaci

zmaksymalizować $g(\alpha, \lambda)$

pod warunkiem $\sum_{i=1}^m \alpha_i y^{(i)} = 0,$

$$\alpha_i \in \left[0, \frac{C}{m}\right], \quad i = 1, \dots, m.$$

Gdy znajdziemy rozwiązanie α^* dla powyższego problemu, to rozwiązanie problemu pierwotnego będzie zadane przez $w^* = \sum_{i=1}^m \alpha_i^* y^{(i)} x^{(i)}.$

Optymalizacja osiowa

Najpierw przyjrzyjmy się ogólnemu problemowi optymalizacji bez ograniczeń postaci

$$\text{zmaksymalizować } f(\alpha_1, \dots, \alpha_m).$$

Jeśli funkcja f jest wklęsła, to możemy skorzystać z algorytmu *optymalizacji osiowej*:

inicjalizacja α ;

while warunek zbieżności **do**

for $i = 1, \dots, n$ **do**

$\alpha_i \leftarrow \arg \max_{\tilde{\alpha}_i} f(\alpha_1, \dots, \alpha_{i-1}, \tilde{\alpha}_i, \alpha_{i+1}, \dots, \alpha_m)$

end

end

Algorytm kolejno optymalizuje po jednym argumencie α_i .

Ze względu na wklęsłość funkcji f , algorytm ten jest zbieżny.

Algorytm sekwencyjnej minimalnej optymalizacji

Wracamy do problemu

$$\text{zmaksymalizować} \quad \sum_{i=1}^m \alpha_i - \frac{1}{2} \sum_{i,j=1}^m \alpha_i \alpha_j y^{(i)} y^{(j)} (x^{(j)})^T x^{(i)}$$

$$\text{pod warunkiem} \quad \sum_{i=1}^m \alpha_i y^{(i)} = 0,$$

$$\alpha_i \in \left[0, \frac{C}{m}\right], \quad i = 1, \dots, m.$$

Funkcja celu, będąca funkcją kwadratową ze względu na α , jest wklęsła.

Nie możemy jednak zastosować optymalizacji osiowej ze względu na warunek

$$\alpha_j y^{(j)} = - \sum_{i=1}^m \alpha_i y^{(i)} \mathbf{1}[i \neq j].$$

Algorytm sekwencyjnej minimalnej optymalizacji

Skorzystamy z algorytmu sekwencyjnej minimalnej optymalizacji (SMO), który w dużym skrócie wygląda następująco:

$\alpha \leftarrow \vec{0}$;

while *warunek zbieżności* **do**

 wybierz parę (α_i, α_j) ;

 zmaksymalizuj $f(\alpha)$ ze względu na α_i i α_j ;

end


Jak działa powyższy algorytm? Załóżmy, że wybraliśmy parę (α_1, α_2) . Wtedy

$$\alpha_1 y^{(1)} + \alpha_2 y^{(2)} = - \sum_{i=3}^m \alpha_i y^{(i)} =: \zeta,$$

gdzie ζ jest pewną stałą.

Algorytm sekwencyjnej minimalnej optymalizacji

Punkt (α_1, α_2) leży na prostej $\alpha_1 y^{(1)} + \alpha_2 y^{(2)} = \zeta$ oraz nie wychodzi poza kwadrat $[C/m, C/m]$.



Algorytm sekwencyjnej minimalnej optymalizacji

Punkt (α_1, α_2) leży na prostej $\alpha_1 y^{(1)} + \alpha_2 y^{(2)} = \zeta$ oraz nie wychodzi poza kwadrat $[C/m, C/m]$.

Oznacza to, że α_2 należy do przedziału $[L, H]$, gdzie L i H są wyznaczone przez wzajemne położenie prostej i kwadratu.

Ponieważ

$$\alpha_1 = (\zeta - \alpha_2 y^{(2)}) y^{(1)},$$

to maksymalizowaną funkcję możemy zapisać następująco:

$$f(\alpha_1, \alpha_2, \dots, \alpha_m) = f\left((\zeta - \alpha_2 y^{(2)}) y^{(1)}, \alpha_2, \dots, \alpha_m\right).$$

Jest to funkcja kwadratowa względem α_2 , czyli możemy zapisać

$$\bar{f}(\alpha_2) := f\left((\zeta - \alpha_2 y^{(2)}) y^{(1)}, \alpha_2, \dots, \alpha_m\right) = a\alpha_2^2 + b\alpha_2 + c,$$

dla pewnych $a, b, c \in \mathbb{R}$.

Algorytm sekwencyjnej minimalnej optymalizacji

Wyznaczamy teraz maksimum funkcji kwadratowej $\bar{f}(\alpha_2) = a\alpha_2^2 + b\alpha_2 + c$:

$$\bar{\alpha}_2 := \arg \max \bar{f}(\alpha_2).$$

Ostatecznie modyfikujemy wartość α_2 na podstawie wzoru

$$\alpha_2 \leftarrow \begin{cases} H, & \text{jeżeli } \bar{\alpha}_2 > H, \\ \bar{\alpha}_2, & \text{jeżeli } \bar{\alpha}_2 \in [L, H], \\ L, & \text{jeżeli } \bar{\alpha}_2 < L. \end{cases}$$

Na koniec odpowiednio zmieniamy wartość α_1 .

Wyznaczenie b^*

Na mocy silnej dualności możemy zastosować twierdzenie *Complementary slackness* dla pierwotnego problemu, otrzymując:

$$\alpha_i^* \left(1 - y^{(i)} \left((w^*)^T x^{(i)} + b^* \right) - \xi_i^* \right) = 0,$$

$$\lambda_i^* \xi_i^* = \left(\frac{C}{m} - \alpha_i^* \right) \xi_i^* = 0.$$

Wyznaczenie b^*

Na mocy silnej dualności możemy zastosować twierdzenie *Complementary slackness* dla pierwotnego problemu, otrzymując:

$$\alpha_i^* \left(1 - y^{(i)} \left((w^*)^T x^{(i)} + b^* \right) - \xi_i^* \right) = 0,$$

$$\lambda_i^* \xi_i^* = \left(\frac{C}{m} - \alpha_i^* \right) \xi_i^* = 0.$$

Jeśli istnieje i takie, że $\alpha_i^* \in (0, C/m)$, to $\xi_i^* = 0$, a stąd

$$y^{(i)} \left((w^*)^T x^{(i)} + b^* \right) = 1.$$

Wyznaczenie b^*

Na mocy silnej dualności możemy zastosować twierdzenie *Complementary slackness* dla pierwotnego problemu, otrzymując:

$$\alpha_i^* \left(1 - y^{(i)} \left((w^*)^T x^{(i)} + b^* \right) - \xi_i^* \right) = 0,$$

$$\lambda_i^* \xi_i^* = \left(\frac{C}{m} - \alpha_i^* \right) \xi_i^* = 0.$$

Jeśli istnieje i takie, że $\alpha_i^* \in (0, C/m)$, to $\xi_i^* = 0$, a stąd

$$y^{(i)} \left((w^*)^T x^{(i)} + b^* \right) = 1.$$

Otrzymujemy ostatecznie

$$b^* = y^{(i)} - (w^*)^T x^{(i)}.$$

Wyznaczenie b^*

Na mocy silnej dualności możemy zastosować twierdzenie *Complementary slackness* dla pierwotnego problemu, otrzymując:

$$\alpha_i^* \left(1 - y^{(i)} \left((w^*)^T x^{(i)} + b^* \right) - \xi_i^* \right) = 0,$$

$$\lambda_i^* \xi_i^* = \left(\frac{C}{m} - \alpha_i^* \right) \xi_i^* = 0.$$

Jeśli istnieje i takie, że $\alpha_i^* \in (0, C/m)$, to $\xi_i^* = 0$, a stąd

$$y^{(i)} \left((w^*)^T x^{(i)} + b^* \right) = 1.$$

Otrzymujemy ostatecznie

$$b^* = y^{(i)} - (w^*)^T x^{(i)}.$$

Zauważmy, że wartość b^* nie zależy od wyboru i takiego, że $\alpha_i^* \in (0, C/m)$.

Margines

Niech $f^*(x) := (w^*)^T x + b^*$.

Dla obserwacji $(x^{(i)}, y^{(i)})$ margines wynosi $y^{(i)} f^*(x^{(i)})$.

Przypomnijmy, że strata zawiasowa $\xi_i^* = \max \{0, 1 - y^{(i)} f^*(x^{(i)})\}$.

Wtedy

- jeżeli $y^{(i)} f^*(x^{(i)}) \leq 0$, to klasyfikacja jest niepoprawna,
- jeżeli $y^{(i)} f^*(x^{(i)}) \in (0, 1)$, to strata zawiasowa ξ_i^* jest dodatnia,
- jeżeli $y^{(i)} f^*(x^{(i)}) = 1$, to punkt jest „na marginesie”,
- jeżeli $y^{(i)} f^*(x^{(i)}) > 1$, to punkt jest „po dobrej stronie marginesu”.

Silna dualność i *complementary slackness*

Ponownie korzystając z własności *Complementary slackness* mamy:

$$\alpha_i^* (1 - y^{(i)} f^*(x^{(i)}) - \xi_i^*) = 0,$$

$$\lambda_i^* \xi_i^* = \left(\frac{C}{m} - \alpha_i^* \right) \xi_i^* = 0.$$

Silna dualność i *complementary slackness*

Ponownie korzystając z własności *Complementary slackness* mamy:

$$\alpha_i^* (1 - y^{(i)} f^*(x^{(i)}) - \xi_i^*) = 0,$$

$$\lambda_i^* \xi_i^* = \left(\frac{C}{m} - \alpha_i^* \right) \xi_i^* = 0.$$

Wtedy

- jeżeli $y^{(i)} f^*(x^{(i)}) > 1$, to $\xi_i^* = 0$, czyli $\alpha_i^* = 0$,
- jeżeli $y^{(i)} f^*(x^{(i)}) < 1$, to $\xi_i^* > 0$, czyli $\alpha_i^* = C/m$,
- jeżeli $\alpha_i^* = 0$, to $\xi_i^* = 0$, czyli $y^{(i)} f^*(x^{(i)}) \geq 1$,
- jeżeli $\alpha_i^* \in (0, C/m)$, to $\xi_i^* = 0$, czyli $y^{(i)} f^*(x^{(i)}) = 1$.

Mnożniki i marginesy

Ostatecznie otrzymujemy

$$\begin{aligned} \text{jeżeli } \alpha_i^* = 0, & \quad \text{to } y^{(i)} f^*(x^{(i)}) \geq 1, \\ \text{jeżeli } \alpha_i^* \in (0, C/m), & \quad \text{to } y^{(i)} f^*(x^{(i)}) = 1, \\ \text{jeżeli } \alpha_i^* = C/m, & \quad \text{to } y^{(i)} f^*(x^{(i)}) \leq 1 \end{aligned}$$

oraz

$$\begin{aligned} \text{jeżeli } y^{(i)} f^*(x^{(i)}) < 1, & \quad \text{to } \alpha_i^* = C/m, \\ \text{jeżeli } y^{(i)} f^*(x^{(i)}) = 1, & \quad \text{to } \alpha_i^* \in (0, C/m), \\ \text{jeżeli } y^{(i)} f^*(x^{(i)}) > 1, & \quad \text{to } \alpha_i^* = 0. \end{aligned}$$

Wektory nośne

Wektory $x^{(i)}$ odpowiadające $\alpha_i^* > 0$ nazywamy *wektorami nośnymi* (lub *wspierającymi*).

