


# Metody probabilistyczne w uczeniu maszynowym

Wykład 7: funkcje jądrowe, twierdzenie o reprezentacji

Katarzyna Grygiel

Semestr letni 2025/2026

## Liniowa (nie)separowalność



Dotychczasowe klasyfikatory dyskryminatywne pozwalały nam na separację liniową. Gołym okiem widać, jak oddzielić plusy i minusy w drugim przykładzie – ale nie znajdziemy granicy liniowej.

# Przykłady problemów z liniowością

## Niemonotoniczność

Chcemy przewidzieć stan zdrowia pacjenta na podstawie pomiaru temperatury.

# Przykłady problemów z liniowością

## Niemonotoniczność

Chcemy przewidzieć stan zdrowia pacjenta na podstawie pomiaru temperatury.

Wybór  $\phi(x) = [1, \text{temperatura}(x)]^T$  jest niedobry, ponieważ stan zdrowia nie jest afiniczną funkcją temperatury: zarówno zbyt duży, jak i zbyt mały wynik pomiaru wskazują na zły stan zdrowia.

# Przykłady problemów z liniowością

## Niemonotoniczność

Chcemy przewidzieć stan zdrowia pacjenta na podstawie pomiaru temperatury.

Wybór  $\phi(x) = [1, \text{temperatura}(x)]^T$  jest niedobry, ponieważ stan zdrowia nie jest afiniczną funkcją temperatury: zarówno zbyt duży, jak i zbyt mały wynik pomiaru wskazują na zły stan zdrowia.

Rozwiązanie 1:  $\phi(x) = [1, (\text{temperatura}(x) - 36.6)^2]^T$ . Dobre, ale mało skalowalne.

# Przykłady problemów z liniowością

## Niemonotoniczność

Chcemy przewidzieć stan zdrowia pacjenta na podstawie pomiaru temperatury.

Wybór  $\phi(x) = [1, \text{temperatura}(x)]^T$  jest niedobry, ponieważ stan zdrowia nie jest afiniczną funkcją temperatury: zarówno zbyt duży, jak i zbyt mały wynik pomiaru wskazują na zły stan zdrowia.

Rozwiązanie 1:  $\phi(x) = [1, (\text{temperatura}(x) - 36.6)^2]^T$ . Dobre, ale mało skalowalne.

Rozwiązanie 2:  $\phi(x) = [1, \text{temperatura}(x), (\text{temperatura}(x))^2]^T$ . Prostsze i bardziej elastyczne.

# Przykłady problemów z liniowością

## Nasycenie

Chcemy polecić produkt nowemu użytkownikowi na podstawie zakupów innych użytkowników.

# Przykłady problemów z liniowością

## Nasycenie

Chcemy polecić produkt nowemu użytkownikowi na podstawie zakupów innych użytkowników.

Wyberzmy  $\phi(x) = [1, N(x)]^T$ , gdzie  $N(x)$  jest liczbą osób, które zakupiły produkt  $x$ .

Jaka jest różnica dla  $N(x) = 10000$  i  $N(y) = 50000$ ?

Jaka dla  $N(x) = 10$  i  $N(y) = 50$ ?



# Przykłady problemów z liniowością

## Nasylenie

Chcemy polecić produkt nowemu użytkownikowi na podstawie zakupów innych użytkowników.

Wyberzmy  $\phi(x) = [1, N(x)]^T$ , gdzie  $N(x)$  jest liczbą osób, które zakupiły produkt  $x$ .

Jaka jest różnica dla  $N(x) = 10000$  i  $N(y) = 50000$ ?

Jaka dla  $N(x) = 10$  i  $N(y) = 50$ ?

Rozwiązanie 1:  $\phi(x) = [1, \ln(1 + N(x))]^T$ .

# Przykłady problemów z liniowością

## Nasylenie

Chcemy polecić produkt nowemu użytkownikowi na podstawie zakupów innych użytkowników.

Wyberzmy  $\phi(x) = [1, N(x)]^T$ , gdzie  $N(x)$  jest liczbą osób, które zakupiły produkt  $x$ .

Jaka jest różnica dla  $N(x) = 10000$  i  $N(y) = 50000$ ?

Jaka dla  $N(x) = 10$  i  $N(y) = 50$ ?

Rozwiązanie 1:  $\phi(x) = [1, \ln(1 + N(x))]^T$ .

Rozwiązanie 2 (dyskretyzacja):

$$\begin{aligned}\phi(x) = & [\mathbf{1}[N(x) \in [0, 10)], \\ & \mathbf{1}[N(x) \in [10, 100)], \\ & \mathbf{1}[N(x) \in [100, 1000)], \dots]^T.\end{aligned}$$

# Przykłady problemów z liniowością

## **Zależności między cechami**

Ponownie oceniamy stan zdrowia, tym razem na podstawie wzrostu i wagi.

# Przykłady problemów z liniowością

## Zależności między cechami

Ponownie oceniamy stan zdrowia, tym razem na podstawie wzrostu i wagi.

Wektor cech  $\phi(x) = [\text{wzrost}(x), \text{waga}(x)]^T$  nie uwzględnia faktu, że istotna jest zależność między wagą i wzrostem.

# Przykłady problemów z liniowością

## Zależności między cechami

Ponownie oceniamy stan zdrowia, tym razem na podstawie wzrostu i wagi.

Wektor cech  $\phi(x) = [\text{wzrost}(x), \text{waga}(x)]^T$  nie uwzględnia faktu, że istotna jest zależność między wagą i wzrostem.

Rozwiązanie 1:  $\phi(x) = \frac{\text{waga}(x)}{\text{wzrost}(x)^2}$ .

# Przykłady problemów z liniowością

## Zależności między cechami

Ponownie oceniamy stan zdrowia, tym razem na podstawie wzrostu i wagi.

Wektor cech  $\phi(x) = [\text{wzrost}(x), \text{waga}(x)]^T$  nie uwzględnia faktu, że istotna jest zależność między wagą i wzrostem.

Rozwiązanie 1:  $\phi(x) = \frac{\text{waga}(x)}{\text{wzrost}(x)^2}$ .

Rozwiązanie 2:


$$\phi(x) = [\text{wzrost}(x), \text{waga}(x), \text{wzrost}(x)^2, \text{wzrost}(x)\text{waga}(x), \text{waga}(x)^2]^T.$$

## Dodatkowe cechy

Dla przestrzeni wejściowej  $\mathcal{X}$  *wektorem cech* nazwiemy odwzorowanie  $\phi: \mathcal{X} \rightarrow \mathbb{R}^d$  ( $d \in \mathbb{N}$  lub  $d = \mathbb{N}$ ). Przestrzeń  $\mathbb{R}^d$  nazwiemy *przestrzenią cech*.

Rozszerzamy liniową (afiniczną) przestrzeń hipotez do funkcji afinicznych na przestrzeni cech:

$$\mathcal{H} = \{h: \mathcal{X} \rightarrow \mathbb{R}: h(x) = w^T \phi(x) + b, w \in \mathbb{R}^d, b \in \mathbb{R}\}.$$



# Klątwa wielowymiarowości

Niech  $x = [x_1, \dots, x_k]^T \in \mathcal{X} = \mathbb{R}^k$ . Dodajmy wszystkie możliwe jednomiany  $x_1^{d_1} \dots x_k^{d_k}$  dla  $d_1 + \dots + d_k = d$ :

$$\phi(x) = [x_1, \dots, x_k, x_1^d, x_1^{d-1}x_2, x_1^{d-1}x_3, \dots, x_{k-1}x_k^{d-1}, x_k^d]^T.$$

Wtedy mamy  $\binom{d+k-1}{d}$  dodatkowych cech. Zdecydowanie za dużo, aby obliczać wartość  $\phi(x)$ ...



# Klątwa wielowymiarowości

Niech  $x = [x_1, \dots, x_k]^T \in \mathcal{X} = \mathbb{R}^k$ . Dodajmy wszystkie możliwe jednomiany  $x_1^{d_1} \dots x_k^{d_k}$  dla  $d_1 + \dots + d_k = d$ :

$$\phi(x) = [x_1, \dots, x_k, x_1^d, x_1^{d-1}x_2, x_1^{d-1}x_3, \dots, x_{k-1}x_k^{d-1}, x_k^d]^T.$$

Wtedy mamy  $\binom{d+k-1}{d}$  dodatkowych cech. Zdecydowanie za dużo, aby obliczać wartość  $\phi(x)$ ...

Problemy z dużymi przestrzeniami cech:

- przeuczenie

# Klątwa wielowymiarowości

Niech  $x = [x_1, \dots, x_k]^T \in \mathcal{X} = \mathbb{R}^k$ . Dodajmy wszystkie możliwe jednomiany  $x_1^{d_1} \dots x_k^{d_k}$  dla  $d_1 + \dots + d_k = d$ :

$$\phi(x) = [x_1, \dots, x_k, x_1^d, x_1^{d-1}x_2, x_1^{d-1}x_3, \dots, x_{k-1}x_k^{d-1}, x_k^d]^T.$$

Wtedy mamy  $\binom{d+k-1}{d}$  dodatkowych cech. Zdecydowanie za dużo, aby obliczać wartość  $\phi(x)$ ...

Problemy z dużymi przestrzeniami cech:

- przeuczenie  $\longrightarrow$  regularyzacja

# Kłątwa wielowymiarowości

Niech  $x = [x_1, \dots, x_k]^T \in \mathcal{X} = \mathbb{R}^k$ . Dodajmy wszystkie możliwe jednomiany  $x_1^{d_1} \dots x_k^{d_k}$  dla  $d_1 + \dots + d_k = d$ :

$$\phi(x) = [x_1, \dots, x_k, x_1^d, x_1^{d-1}x_2, x_1^{d-1}x_3, \dots, x_{k-1}x_k^{d-1}, x_k^d]^T.$$

Wtedy mamy  $\binom{d+k-1}{d}$  dodatkowych cech. Zdecydowanie za dużo, aby obliczać wartość  $\phi(x)$ ...

Problemy z dużymi przestrzeniami cech:

- przeuczenie  $\longrightarrow$  regularyzacja
- wymagania względem pamięci i czasu

# Kłątwa wielowymiarowości

Niech  $x = [x_1, \dots, x_k]^T \in \mathcal{X} = \mathbb{R}^k$ . Dodajmy wszystkie możliwe jednomiany  $x_1^{d_1} \dots x_k^{d_k}$  dla  $d_1 + \dots + d_k = d$ :

$$\phi(x) = [x_1, \dots, x_k, x_1^d, x_1^{d-1}x_2, x_1^{d-1}x_3, \dots, x_{k-1}x_k^{d-1}, x_k^d]^T.$$

Wtedy mamy  $\binom{d+k-1}{d}$  dodatkowych cech. Zdecydowanie za dużo, aby obliczać wartość  $\phi(x)$ ...

Problemy z dużymi przestrzeniami cech:

- przeuczenie  $\longrightarrow$  regularyzacja
- wymagania względem pamięci i czasu  $\longrightarrow$  metody jądrowe

## Metoda wektorów nośnych ponownie

Dodajmy wektor cech  $\phi$  do algorytmu SVM. Wówczas funkcja predykcji wynika z rozwiązania problemu

$$\min_{w \in \mathbb{R}^k, b \in \mathbb{R}} \frac{1}{2} \|w\|^2 + \frac{C}{m} \sum_{i=1}^m \left( 1 - y^{(i)} (w^T \phi(x^{(i)}) + b) \right).$$

Jest on równoważny problemowi

## Metoda wektorów nośnych ponownie

Dodajmy wektor cech  $\phi$  do algorytmu SVM. Wówczas funkcja predykcji wynika z rozwiązania problemu

$$\min_{w \in \mathbb{R}^k, b \in \mathbb{R}} \frac{1}{2} \|w\|^2 + \frac{C}{m} \sum_{i=1}^m \left( 1 - y^{(i)} (w^T \phi(x^{(i)}) + b) \right).$$

Jest on równoważny problemowi

zmaksymalizować 
$$\sum_{i=1}^m \alpha_i - \frac{1}{2} \sum_{i,j=1}^m \alpha_i \alpha_j y^{(i)} y^{(j)} \phi(x^{(i)})^T \phi(x^{(j)})$$

pod warunkiem 
$$\sum_{i,j=1}^m \alpha_i y^{(i)} = 0, \quad i = 1, \dots, m,$$

$$\alpha_i \in [0, C/m], \quad i = 1, \dots, m.$$

## Metoda wektorów nośnych ponownie

Dodajmy wektor cech  $\phi$  do algorytmu SVM. Wówczas funkcja predykcji wynika z rozwiązania problemu

$$\min_{w \in \mathbb{R}^k, b \in \mathbb{R}} \frac{1}{2} \|w\|^2 + \frac{C}{m} \sum_{i=1}^m \left( 1 - y^{(i)} (w^T \phi(x^{(i)}) + b) \right).$$

Jest on równoważny problemowi

zmaksymalizować 
$$\sum_{i=1}^m \alpha_i - \frac{1}{2} \sum_{i,j=1}^m \alpha_i \alpha_j y^{(i)} y^{(j)} \phi(x^{(i)})^T \phi(x^{(j)})$$

pod warunkiem 
$$\sum_{i,j=1}^m \alpha_i y^{(i)} = 0, \quad i = 1, \dots, m,$$

$$\alpha_i \in [0, C/m], \quad i = 1, \dots, m.$$

## Metoda wektorów nośnych ponownie

Dodajmy wektor cech  $\phi$  do algorytmu SVM. Wówczas funkcja predykcji wynika z rozwiązania problemu

$$\min_{w \in \mathbb{R}^k, b \in \mathbb{R}} \frac{1}{2} \|w\|^2 + \frac{C}{m} \sum_{i=1}^m \left( 1 - y^{(i)} (w^T \phi(x^{(i)}) + b) \right).$$

Jest on równoważny problemowi

zmaksymalizować 
$$\sum_{i=1}^m \alpha_i - \frac{1}{2} \sum_{i,j=1}^m \alpha_i \alpha_j y^{(i)} y^{(j)} \langle \phi(x^{(i)}), \phi(x^{(j)}) \rangle$$

pod warunkiem 
$$\sum_{i,j=1}^m \alpha_i y^{(i)} = 0, \quad i = 1, \dots, m,$$

$$\alpha_i \in [0, C/m], \quad i = 1, \dots, m.$$



# Funkcje jądrowe

Funkcję  $\kappa: \mathbb{R}^k \times \mathbb{R}^k \rightarrow \mathbb{R}$  nazywamy *funkcją jądrową* jeżeli istnieją funkcja  $\phi: \mathbb{R}^k \rightarrow \mathbb{R}^d$  ( $d \in \mathbb{N}$  lub  $d = \mathbb{N}$ ) i iloczyn skalarny  $\langle \cdot, \cdot \rangle$  na  $\mathbb{R}^d$  takie, że

$$\kappa(x, z) = \langle \phi(x), \phi(z) \rangle$$

dla dowolnych  $x, z \in \mathbb{R}^k$ .

# Funkcje jądrowe

Funkcję  $\kappa: \mathbb{R}^k \times \mathbb{R}^k \rightarrow \mathbb{R}$  nazywamy *funkcją jądrową* jeżeli istnieją funkcja  $\phi: \mathbb{R}^k \rightarrow \mathbb{R}^d$  ( $d \in \mathbb{N}$  lub  $d = \mathbb{N}$ ) i iloczyn skalarny  $\langle \cdot, \cdot \rangle$  na  $\mathbb{R}^d$  takie, że

$$\kappa(x, z) = \langle \phi(x), \phi(z) \rangle$$

dla dowolnych  $x, z \in \mathbb{R}^k$ .


Często zdarza się tak, że można obliczyć wartość  $\kappa(x, z)$  bez wyznaczania wartości  $\phi(x)$  i  $\phi(z)$ .

W przypadku przestrzeni cech o wysokim wymiarze ( $d \gg m$ ) zastosowanie funkcji jądrowych może być znacznie szybsze od tradycyjnego podejścia.

---

Jeżeli  $d = \mathbb{N}$ , to dodatkowo zakładamy, że  $\sum_{i=0}^{\infty} x_i^2, \sum_{i=0}^{\infty} z_i^2 < \infty$ .

# Konstrukcja jądra z funkcji bazowych



Wykresy  $\kappa(x, z) = \langle \phi(x), \phi(z) \rangle = \sum_{i=1}^M \phi(x)_i \phi(z)_i$  dla trzech różnych wektorów cech (wielomiany, funkcje gaussowskie i sigmoidy) oraz dla  $z = -1/2$  (pierwszy) i  $z = 0$  (drugi i trzeci).

## Przykłady funkcji jądrowych

- Niech  $\kappa(x, z) = \langle x, z \rangle^2$  dla  $x, z \in \mathbb{R}^2$ . Wtedy

$$\begin{aligned}\kappa(x, z) &= (x_1 z_1 + x_2 z_2)^2 = x_1^2 z_1^2 + 2x_1 z_1 x_2 z_2 + x_2^2 z_2^2 \\ &= [x_1^2, \sqrt{2}x_1 x_2, x_2^2][z_1^2, \sqrt{2}z_1 z_2, z_2^2]^T = \langle \phi(x), \phi(z) \rangle,\end{aligned}$$

gdzie  $\phi(x) = [x_1^2, \sqrt{2}x_1 x_2, x_2^2]^T$ .

## Przykłady funkcji jądrowych

- Niech  $\kappa(x, z) = \langle x, z \rangle^2$  dla  $x, z \in \mathbb{R}^2$ . Wtedy

$$\begin{aligned}\kappa(x, z) &= (x_1 z_1 + x_2 z_2)^2 = x_1^2 z_1^2 + 2x_1 z_1 x_2 z_2 + x_2^2 z_2^2 \\ &= [x_1^2, \sqrt{2}x_1 x_2, x_2^2][z_1^2, \sqrt{2}z_1 z_2, z_2^2]^T = \langle \phi(x), \phi(z) \rangle,\end{aligned}$$

gdzie  $\phi(x) = [x_1^2, \sqrt{2}x_1 x_2, x_2^2]^T$ .

- Niech  $\kappa(x, z) = \langle x, z \rangle + \langle x, z \rangle^2$  dla  $x, z \in \mathbb{R}^k$ . Wtedy dla

$$\phi(x) = [x_1, \dots, x_k, x_1^2, \dots, x_k^2, \sqrt{2}x_1 x_2, \dots, \sqrt{2}x_{k-1} x_k]^T$$

mamy, dla dowolnych  $x, z \in \mathbb{R}^k$ ,

$$\kappa(x, z) = \langle x, z \rangle + \langle x, z \rangle^2 = \langle \phi(x), \phi(z) \rangle.$$

Obliczanie wartości  $\kappa(x, z)$  przez pośrednie obliczenie wektorów cech dla  $x$  i  $z$  wymaga  $\mathcal{O}(k^2)$  kroków, podczas gdy można wykonać ich zaledwie  $\mathcal{O}(k)$ .

# Jądro gaussowskie

Jądro gaussowskie z parametrem  $\tau$  definiujemy jako funkcję

$$\kappa(x, z) = \exp \left( - \|x - z\|^2 / 2\tau^2 \right).$$

# Jądro gaussowskie

Jądro gaussowskie z parametrem  $\tau$  definiujemy jako funkcję

$$\kappa(x, z) = \exp\left(-\|x - z\|^2/2\tau^2\right).$$

Dla  $x, z \in \mathbb{R}$  niech

$$\phi(x) = \left( \frac{\exp(-x^2/2\tau^2)}{\sqrt{n!}} \left(\frac{x}{\tau}\right)^n \right)_{n \geq 0}.$$

Wtedy

$$\begin{aligned} \langle \phi(x), \phi(z) \rangle &= \sum_{n=0}^{\infty} \frac{\exp\left(-\frac{x^2+z^2}{2\tau^2}\right)}{n!} \left(\frac{xz}{\tau^2}\right)^n \\ &= \exp\left(-\frac{x^2+z^2}{2\tau^2}\right) \exp\left(\frac{xz}{\tau^2}\right) \\ &= \kappa(x, z). \end{aligned}$$

# Jądro gaussowskie

Jądro gaussowskie z parametrem  $\tau$  definiujemy jako funkcję




$$\kappa(x, z) = \exp\left(-\|x - z\|^2 / 2\tau^2\right).$$

Dla  $x, z \in \mathbb{R}$  niech

$$\phi(x) = \left( \frac{\exp(-x^2/2\tau^2)}{\sqrt{n!}} \left(\frac{x}{\tau}\right)^n \right)_{n \geq 0}.$$

Wtedy

$$\begin{aligned} \langle \phi(x), \phi(z) \rangle &= \sum_{n=0}^{\infty} \frac{\exp\left(-\frac{x^2+z^2}{2\tau^2}\right)}{n!} \left(\frac{xz}{\tau^2}\right)^n \\ &= \exp\left(-\frac{x^2+z^2}{2\tau^2}\right) \exp\left(\frac{xz}{\tau^2}\right) \\ &= \kappa(x, z). \end{aligned}$$





## Dalsze przykłady

- Niech  $D$  będzie skończonym zbiorem. Wtedy

$$\kappa(A_1, A_2) = 2^{|A_1 \cap A_2|}$$

jest jądrem na zbiorze potęgowym  $\mathcal{P}(D)$  zbioru  $D$ .

## Dalsze przykłady

- Niech  $D$  będzie skończonym zbiorem. Wtedy

$$\kappa(A_1, A_2) = 2^{|A_1 \cap A_2|}$$

jest jądrem na zbiorze potęgowym  $\mathcal{P}(D)$  zbioru  $D$ .

- Niech  $p$  będzie rozkładem lub funkcją gęstości prawdopodobieństwa na pewnym zbiorze  $\mathcal{X}$ . Wtedy

$$\kappa(x, z) = p(x)p(z)$$

jest jądrem na  $\mathcal{X}$ .

## Dalsze przykłady

- Niech  $D$  będzie skończonym zbiorem. Wtedy

$$\kappa(A_1, A_2) = 2^{|A_1 \cap A_2|}$$

jest jądrem na zbiorze potęgowym  $\mathcal{P}(D)$  zbioru  $D$ .

- Niech  $p$  będzie rozkładem lub funkcją gęstości prawdopodobieństwa na pewnym zbiorze  $\mathcal{X}$ . Wtedy

$$\kappa(x, z) = p(x)p(z)$$

jest jądrem na  $\mathcal{X}$ .

- Rozważmy rodzinę rozkładów  $\{p_i: i \in \mathbb{N}\}$  na zbiorze  $\mathcal{X}$ . Wtedy jądrem na  $\mathcal{X}$  jest funkcja

$$\kappa(x, z) = \sum_{i \in \mathbb{N}} p_i(x)p_i(z)p(i),$$

gdzie  $p(i)$  jest wagą dla  $i$ -tego rozkładu.

# Konstrukcja nowych funkcji jądrowych

Niech  $\kappa_1, \kappa_2: \mathbb{R}^k \times \mathbb{R}^k \rightarrow \mathbb{R}$  będą funkcjami jądrowymi. Wtedy poniższe funkcje są również funkcjami jądrowymi:

- (a)  $\kappa(x, z) = c\kappa_1(x, z)$  dla stałej  $c > 0$ ,
- (b)  $\kappa(x, z) = f(x)\kappa_1(x, z)f(z)$  dla funkcji  $f: \mathbb{R}^k \rightarrow \mathbb{R}$ ,
- (c)  $\kappa(x, z) = \kappa_1(x, z) + \kappa_2(x, z)$ ,
- (d)  $\kappa(x, z) = \kappa_1(x, z)\kappa_2(x, z)$ ,
- (e)  $\kappa(x, z) = Q(\kappa_1(x, z))$  dla wielomianu  $Q$  o nieujemnych współczynnikach.

## Konstrukcja nowych funkcji jądrowych (cd.)

Niech  $\kappa_1, \kappa_2: \mathbb{R}^k \times \mathbb{R}^k \rightarrow \mathbb{R}$  będą funkcjami jądrowymi. Wtedy poniższe funkcje są również funkcjami jądrowymi:

(f)  $\kappa(x, z) = \exp(\kappa_1(x, z))$ ,

(g)  $\kappa(x, z) = \kappa'(\phi(x), \phi(z))$  dla  $\phi: \mathbb{R}^k \rightarrow \mathbb{R}^d$  i jądra  $\kappa'$  na  $\mathbb{R}^d$ ,

(h)  $\kappa(x, z) = x^T A z$  dla symetrycznej dodatnio półokreślonej  $A$ .

(i)  $\kappa(x, z) = \kappa_a(x_a, z_a) + \kappa_b(x_b, z_b)$ ,

(j)  $\kappa(x, z) = \kappa_a(x_a, z_a) \kappa_b(x_b, z_b)$ ,

gdzie w (i) oraz (j)  $x = (x_a, x_b)$  oraz  $z = (z_a, z_b)$  dla  $x_a, z_a \in \mathbb{R}^{k_a}$ ,  $x_b, z_b \in \mathbb{R}^{k_b}$  i  $k_a + k_b = k$ , natomiast  $\kappa_a, \kappa_b$  są jądrami na  $\mathbb{R}^{k_a}$  i  $\mathbb{R}^{k_b}$ .

## Postać funkcji jądrowych

Macierzą Grama dla funkcji  $\kappa$  na  $\mathcal{X}$  oraz ciągu elementów  $(x^{(i)})_{i=1}^m$  z  $\mathcal{X}$  nazywamy macierz

$$K = \begin{bmatrix} \kappa(x^{(1)}, x^{(1)}) & \cdots & \kappa(x^{(1)}, x^{(m)}) \\ \vdots & \ddots & \vdots \\ \kappa(x^{(m)}, x^{(1)}) & \cdots & \kappa(x^{(m)}, x^{(m)}) \end{bmatrix}.$$

## Postać funkcji jądrowych

Macierz Grama dla funkcji  $\kappa$  na  $\mathcal{X}$  oraz ciągu elementów  $(x^{(i)})_{i=1}^m$  z  $\mathcal{X}$  nazywamy macierz

$$K = \begin{bmatrix} \kappa(x^{(1)}, x^{(1)}) & \cdots & \kappa(x^{(1)}, x^{(m)}) \\ \vdots & \ddots & \vdots \\ \kappa(x^{(m)}, x^{(1)}) & \cdots & \kappa(x^{(m)}, x^{(m)}) \end{bmatrix}.$$

### Twierdzenie Mercera

Niech dana będzie funkcja  $\kappa: \mathbb{R}^k \times \mathbb{R}^k \rightarrow \mathbb{R}$ . Funkcja  $\kappa$  jest funkcją jądrową wtedy i tylko wtedy, gdy dla dowolnej liczby naturalnej  $m \geq 1$  i dowolnego ciągu  $(x^{(i)})_{i=1}^m$  z  $\mathbb{R}^k$  macierz Grama dla  $\kappa$  i tego ciągu jest dodatnio półokreślona.

## Postać funkcji jądrowych

Macierzą Grama dla funkcji  $\kappa$  na  $\mathcal{X}$  oraz ciągu elementów  $(x^{(i)})_{i=1}^m$  z  $\mathcal{X}$  nazywamy macierz

$$K = \begin{bmatrix} \kappa(x^{(1)}, x^{(1)}) & \cdots & \kappa(x^{(1)}, x^{(m)}) \\ \vdots & \ddots & \vdots \\ \kappa(x^{(m)}, x^{(1)}) & \cdots & \kappa(x^{(m)}, x^{(m)}) \end{bmatrix}.$$

### Twierdzenie Mercera

Niech dana będzie funkcja  $\kappa: \mathbb{R}^k \times \mathbb{R}^k \rightarrow \mathbb{R}$ . Funkcja  $\kappa$  jest funkcją jądrową wtedy i tylko wtedy, gdy dla dowolnej liczby naturalnej  $m \geq 1$  i dowolnego ciągu  $(x^{(i)})_{i=1}^m$  z  $\mathbb{R}^k$  macierz Grama dla  $\kappa$  i tego ciągu jest dodatnio półokreślona.

### Twierdzenie

Każdy z poniższych warunków jest konieczny i wystarczający na to, aby macierz  $M$  była dodatnio półokreślona:

- istnieje macierz  $R$  taka, że  $M = R^T R$ ,
- wszystkie wartości własne macierzy  $M$  są nieujemne.



## Jądrowa regresja grzbietowa

Mamy zbiór obserwacji  $\{(x^{(i)}, y^{(i)}): i = 1, \dots, m\} \subset \mathbb{R}^k \times \mathbb{R}$ .

Regresja grzbietowa z wektorem cech  $\phi: \mathbb{R}^k \rightarrow \mathbb{R}^{d+1}$  ( $\phi_0 = 1$ ) polega na wyznaczeniu parametru  $\theta = [\theta_0, \theta_1, \dots, \theta_k]^T$  minimalizującego funkcję kosztu

$$\mathcal{J}(\theta) = \frac{1}{m} \sum_{i=1}^m (\theta^T \phi(x^{(i)}) - y^{(i)})^2 + \lambda \sum_{j=1}^k \theta_j^2.$$

Niech  $\kappa(x, z) := \langle \phi(x), \phi(z) \rangle$  oraz niech  $K$  będzie macierzą Grama dla jądra  $\kappa$  i ciągu wektorów  $(x^{(i)})_{i=1}^m$ . Wtedy dla nowej danej wejściowej  $x$  przewidujemy wartość wyjściową następująco:

$$\theta^T \phi(x) = [\kappa(x, x^{(1)}), \dots, \kappa(x, x^{(m)})] (K + \lambda \mathbf{I}_m)^{-1} y.$$

Zauważmy, że zastosowanie powyższego wzoru ma sens, gdy  $d$  jest istotnie większe od liczby obserwacji  $m$ .

# Postać minimalizatora

## Twierdzenie o reprezentacji

Dany jest zbiór  $\mathcal{X}$  i jego podzbiór  $\{x^{(i)} : i = 1, \dots, m\}$ . Niech  $\psi: \mathcal{X} \rightarrow \mathbb{R}^k$ . Zdefiniujmy funkcję  $\mathcal{J}: \mathbb{R}^k \rightarrow \mathbb{R}$  wzorem

$$\mathcal{J}(w) = R(\|w\|) + L(\langle w, \psi(x^{(1)}) \rangle, \dots, \langle w, \psi(x^{(m)}) \rangle),$$

dla pewnej funkcji  $L: \mathbb{R}^k \rightarrow \mathbb{R}$  i niemalejącej funkcji  $R: \mathbb{R}_{\geq 0} \rightarrow \mathbb{R}$ .

Jeżeli istnieje argument minimalizujący  $\mathcal{J}(w)$ , to istnieje takie  $w^* = \arg \min_w \mathcal{J}(w)$ , że

$$w^* = \sum_{i=1}^m \alpha_i \psi(x^{(i)})$$

dla pewnych  $\alpha_1, \dots, \alpha_m \in \mathbb{R}$ .

Ponadto jeśli funkcja  $R$  jest silnie rosnąca, to wszystkie argumenty minimalizujące  $\mathcal{J}(w)$  są tej postaci.

## Zastosowanie twierdzenia o reprezentacji

Niech  $w = \sum_{i=1}^m \alpha_i \psi(x^{(i)})$ .

Wtedy dla nowej wartości wejściowej  $x \in \mathcal{X}$  przewidujemy wartość wyjściową następująco:

$$\begin{aligned} h_{\alpha}(x) &= \langle w, \psi(x) \rangle = \left\langle \sum_{i=1}^m \alpha_i \psi(x^{(i)}), \psi(x) \right\rangle \\ &= \sum_{i=1}^m \alpha_i \langle \psi(x^{(i)}), \psi(x) \rangle = \sum_{i=1}^m \alpha_i \kappa(x^{(i)}, x). \end{aligned}$$

## Zastosowanie twierdzenia o reprezentacji

Niech  $w = \sum_{i=1}^m \alpha_i \psi(x^{(i)})$ .

Wtedy dla nowej wartości wejściowej  $x \in \mathcal{X}$  przewidujemy wartość wyjściową następująco:

$$\begin{aligned} h_{\alpha}(x) &= \langle w, \psi(x) \rangle = \left\langle \sum_{i=1}^m \alpha_i \psi(x^{(i)}), \psi(x) \right\rangle \\ &= \sum_{i=1}^m \alpha_i \langle \psi(x^{(i)}), \psi(x) \rangle = \sum_{i=1}^m \alpha_i \kappa(x^{(i)}, x). \end{aligned}$$

Predykcje  $h_{\alpha}(x^{(1)}), \dots, h_{\alpha}(x^{(m)})$  (czyli dla danych ze zbioru treningowego) są postaci

$$\begin{bmatrix} \alpha_1 \kappa(x^{(1)}, x^{(1)}) + \dots + \alpha_m \kappa(x^{(1)}, x^{(m)}) \\ \vdots \\ \alpha_1 \kappa(x^{(m)}, x^{(1)}) + \dots + \alpha_m \kappa(x^{(m)}, x^{(m)}) \end{bmatrix} = K\alpha.$$

## Znane problemy raz jeszcze

Ponieważ

$$\|\mathbf{w}\|^2 = \sum_{i,j=1}^m \alpha_i \alpha_j \kappa(x^{(i)}, x^{(j)}) = \alpha^T K \alpha,$$

to

$$R(\|\mathbf{w}\|) = R(\sqrt{\alpha^T K \alpha}).$$

## Znane problemy raz jeszcze

Ponieważ

$$\|w\|^2 = \sum_{i,j=1}^m \alpha_i \alpha_j \kappa(x^{(i)}, x^{(j)}) = \alpha^T K \alpha,$$

to

$$R(\|w\|) = R(\sqrt{\alpha^T K \alpha}).$$

Zatem problem maksymalizacji marginesu geometrycznego (SVM) można zapisać w równoważnej postaci

$$\min_{\alpha \in \mathbb{R}^m} \frac{1}{2} \alpha^T K \alpha + \frac{C}{m} \sum_{i=1}^m \max \{0, 1 - y^{(i)} (K \alpha)_i\}.$$

## Znane problemy raz jeszcze

Ponieważ

$$\|w\|^2 = \sum_{i,j=1}^m \alpha_i \alpha_j \kappa(x^{(i)}, x^{(j)}) = \alpha^T K \alpha,$$

to

$$R(\|w\|) = R(\sqrt{\alpha^T K \alpha}).$$

Zatem problem maksymalizacji marginesu geometrycznego (SVM) można zapisać w równoważnej postaci

$$\min_{\alpha \in \mathbb{R}^m} \frac{1}{2} \alpha^T K \alpha + \frac{C}{m} \sum_{i=1}^m \max \{0, 1 - y^{(i)} (K \alpha)_i\}.$$

Podobnie, problem regresji grzbietowej jest postaci

$$\min_{\alpha \in \mathbb{R}^m} \frac{1}{m} \|K \alpha - y\|^2 + \lambda \alpha^T K \alpha.$$