

Metody probabilistyczne w uczeniu maszynowym

Wykład 8: drzewa decyzyjne, bootstrap i bagging, lasy losowe

Katarzyna Grygiel

Semestr letni 2025/2026

Drzewa decyzyjne

Drzewa decyzyjne

Drzewa decyzyjne mogą być stosowane zarówno dla regresji, jak i dla klasyfikacji.


Niech $(x_1, \dots, x_k) \in \mathcal{X}$ będzie elementem z przestrzeni wejść.

Rozważamy przestrzeń wyjść dwuelementowe (klasyfikacja binarna) albo równe $\mathbb{R}$ (regresja).



Funkcję decyzyjną wyznaczamy na podstawie drzewa decyzyjnego, czyli drzewa binarnego, w którym każdy węzeł wewnętrzny odpowiada warunkowi dotyczącemu dokładnie jednej z d cech. Każdy warunek jest jednej z dwóch postaci:

- $x_i \leq t$, $t \in \mathbb{R}$, gdy i -ta cecha jest ciągła,
- $x_i \in A_0$, gdy i -ta cecha jest dyskretna i przyjmuje wartości ze zbioru A oraz A_0 jest nietrywialnym podzbiorem A .

Drzewo regresji: przykład w $\mathbb{R}^2$



Drzewo regresji: przykład w $\mathbb{R}^2$



Drzewa regresji: funkcja decyzyjna

Każde drzewo decyzyjne wyznacza podział przestrzeni wejściowej $\mathcal{X}$ na pewną liczbę obszarów $R_1, \dots, R_M$:

$$R_1 \cup \dots \cup R_M = \mathcal{X}, \quad \forall_{i \neq j} R_i \cap R_j = \emptyset.$$

Drzewa regresji: funkcja decyzyjna

Każde drzewo decyzyjne wyznacza podział przestrzeni wejściowej $\mathcal{X}$ na pewną liczbę obszarów $R_1, \dots, R_M$:

$$R_1 \cup \dots \cup R_M = \mathcal{X}, \quad \forall_{i \neq j} R_i \cap R_j = \emptyset.$$

Dla M rozłącznych obszarów $R_1, \dots, R_M$ funkcja decyzyjna jest postaci

$$h(x) = \sum_{j=1}^M c_j \mathbf{1}[x \in R_j].$$

Drzewa regresji: funkcja decyzyjna

Każde drzewo decyzyjne wyznacza podział przestrzeni wejściowej $\mathcal{X}$ na pewną liczbę obszarów $R_1, \dots, R_M$:

$$R_1 \cup \dots \cup R_M = \mathcal{X}, \quad \forall_{i \neq j} R_i \cap R_j = \emptyset.$$

Dla M rozłącznych obszarów $R_1, \dots, R_M$ funkcja decyzyjna jest postaci

$$h(x) = \sum_{j=1}^M c_j \mathbf{1}[x \in R_j].$$

Dla kwadratowej funkcji straty $\ell(y, \hat{y}) = (y - \hat{y})^2$ wybieramy

$$\hat{c}_j = \frac{1}{|R_j|} \sum_{i: x^{(i)} \in R_j} y^{(i)},$$

Drzewa regresji: funkcja decyzyjna

Każde drzewo decyzyjne wyznacza podział przestrzeni wejściowej $\mathcal{X}$ na pewną liczbę obszarów $R_1, \dots, R_M$:

$$R_1 \cup \dots \cup R_M = \mathcal{X}, \quad \forall_{i \neq j} R_i \cap R_j = \emptyset.$$

Dla M rozłącznych obszarów $R_1, \dots, R_M$ funkcja decyzyjna jest postaci

$$h(x) = \sum_{j=1}^M c_j \mathbf{1}[x \in R_j].$$

Dla kwadratowej funkcji straty $\ell(y, \hat{y}) = (y - \hat{y})^2$ wybieramy

$$\hat{c}_j = \frac{1}{|R_j|} \sum_{i: x^{(i)} \in R_j} y^{(i)},$$

czyli średnią wartość ze wszystkich danych wyjściowych, dla których odpowiadające im dane wejściowe należą do j -tego obszaru.

Miary złożoności drzewa regresji

Dla odpowiednio dużego drzewa decyzyjnego, każdy ze zbiorów z podziału będzie co najwyżej jednoelementowy. To oznacza przeuczenie.

Miary złożoności drzewa regresji

Dla odpowiednio dużego drzewa decyzyjnego, każdy ze zbiorów z podziału będzie co najwyżej jednoelementowy. To oznacza przeuczenie.

Aby tego uniknąć możemy ograniczyć złożoność drzewa. Jako złożoność możemy przyjąć na przykład jego głębokość lub liczbę wierzchołków.

Miary złożoności drzewa regresji

Dla odpowiednio dużego drzewa decyzyjnego, każdy ze zbiorów z podziału będzie co najwyżej jednoelementowy. To oznacza przeuczenie.

Aby tego uniknąć możemy ograniczyć złożoność drzewa. Jako złożoność możemy przyjąć na przykład jego głębokość lub liczbę wierzchołków.

Dla zadanej złożoności chcielibyśmy znaleźć drzewo, które minimalizuje funkcję błędu (np. dla kwadratowej funkcji straty) na zbiorze treningowym.

Konstrukcja drzewa regresji

Niech $(x_1, \dots, x_k) \in \mathbb{R}^k$. Dla ustalonej cechy $j \in \{1, \dots, k\}$ wybieramy punkt *rozdzielający* $s \in \mathbb{R}$, względem którego tworzymy podział

$$R_1(j, s) = \{x: x_j \leq s\}, \quad R_2(j, s) = \{x: x_j > s\}.$$

Następnie wyznaczamy stałe

$$\hat{c}_1(j, s) = \sum_{x^{(i)} \in R_1(j, s)} \frac{y^{(i)}}{|R_1(j, s)|}, \quad \hat{c}_2(j, s) = \sum_{x^{(i)} \in R_2(j, s)} \frac{y^{(i)}}{|R_2(j, s)|}.$$

Konstrukcja drzewa regresji

Niech $(x_1, \dots, x_k) \in \mathbb{R}^k$. Dla ustalonej cechy $j \in \{1, \dots, k\}$ wybieramy punkt *rozdzielający* $s \in \mathbb{R}$, względem którego tworzymy podział

$$R_1(j, s) = \{x: x_j \leq s\}, \quad R_2(j, s) = \{x: x_j > s\}.$$

Następnie wyznaczamy stałe


$$\hat{c}_1(j, s) = \sum_{x^{(i)} \in R_1(j, s)} \frac{y^{(i)}}{|R_1(j, s)|}, \quad \hat{c}_2(j, s) = \sum_{x^{(i)} \in R_2(j, s)} \frac{y^{(i)}}{|R_2(j, s)|}.$$

Zależy nam na wyznaczeniu j oraz s takich, aby zminimalizować


$$\mathcal{J}(j, s) = \sum_{x^{(i)} \in R_1(j, s)} (y^{(i)} - \hat{c}_1(j, s))^2 + \sum_{x^{(i)} \in R_2(j, s)} (y^{(i)} - \hat{c}_2(j, s))^2.$$

Jak je znaleźć?


Przykład



Przykład



Przykład



Wyznaczanie j i s

Rozważmy m obserwacji.

Dla każdej cechy j wyznaczamy optymalny punkt rozdzielający.

Dla zadanego j sortujemy obserwacje według wartości j -tej cechy, otrzymując ciąg $(x^{(j_1)}, \dots, x^{(j_m)})$.

Wyznaczanie j i s

Rozważmy m obserwacji.

Dla każdej cechy j wyznaczamy optymalny punkt rozdzielający.

Dla zadanego j sortujemy obserwacje według wartości j -tej cechy, otrzymując ciąg $(x^{(j_1)}, \dots, x^{(j_m)})$.

Możliwe punkty podziału dla j wyznaczamy jako średnie arytmetyczne z dwóch sąsiednich wartości powyższego ciągu:

$$s_j \in \left\{ \frac{x^{(j_r)} + x^{(j_{r+1})}}{2} : r = 1, \dots, m-1 \right\}.$$

Wyznaczanie j i s

Rozważmy m obserwacji.

Dla każdej cechy j wyznaczamy optymalny punkt rozdzielający.

Dla zadanego j sortujemy obserwacje według wartości j -tej cechy, otrzymując ciąg $(x^{(j_1)}, \dots, x^{(j_m)})$.

Możliwe punkty podziału dla j wyznaczamy jako średnie arytmetyczne z dwóch sąsiednich wartości powyższego ciągu:

$$s_j \in \left\{ \frac{x^{(j_r)} + x^{(j_{r+1})}}{2} : r = 1, \dots, m-1 \right\}.$$

Dla m obserwacji mamy do rozważenia (co najwyżej) $m-1$ różnych funkcji kawałkami liniowych.

Znajdujemy najlepszy punkt podziału dla każdej cechy i wybieramy cechę i podział minimalizujące funkcję błędu. Dalej postępujemy rekurencyjnie.

Kiedy zakończyć?

Jeśli otrzymane drzewo będzie bardzo duże, to prawdopodobnie dojdzie do przeuczenia.
Jeśli za małe, to możemy przegapić istotny podział.

Kiedy zakończyć budowę drzewa?

Kiedy zakończyć?

Jeśli otrzymane drzewo będzie bardzo duże, to prawdopodobnie dojdzie do przeuczenia. Jeśli za małe, to możemy przegapić istotny podział.

Kiedy zakończyć budowę drzewa? Możliwe ograniczenia:

- maksymalna głębokość,
- minimalna liczba punktów w każdym liściu,
- minimalna liczba punktów w każdym węźle wewnętrznym.

Backward pruning: budujemy bardzo duże drzewo (np. mające w każdym liściu co najwyżej 5 danych), a następnie obcinamy stopniowo jego poddrzewa, sprawdzając działanie drzewa na zbiorze walidacyjnym.

Pruning: kompromis między złożonością a błędem

Rozważmy bardzo duże drzewo decyzyjne T_0 . Dla każdego poddrzewa¹ $T \subseteq T_0$ zachodzi $\widehat{R}(T) \geq \widehat{R}(T_0)$.

Zdefiniujmy *złożoność* $|T|$ drzewa T jako liczbę jego liści.

Dla parametru $\alpha \geq 0$ i drzewa T ustalamy koszt następująco:

$$\mathcal{J}_\alpha(T) = \widehat{R}(T) + \alpha|T|.$$

Naszym celem będzie znalezienie poddrzewa T drzewa T_0 minimalizującego powyższą funkcję. Odpowiada to znalezieniu kompromisu pomiędzy złożonością drzewa a wielkością ryzyka empirycznego.

Wartość parametru α ustalimy na podstawie wyników otrzymanych na danych walidacyjnych.

¹Jako poddrzewo w tym kontekście rozumiemy drzewo otrzymane po usunięciu drzewa zakorzenionego w jednym z węzłów T_0 .

Pruning: możemy obcinać zachłannie

Jak znaleźć drzewo T minimalizujące funkcję $J_\alpha(T)$? Czy musimy rozważać wykładniczo (względem $|T_0|$) wiele poddrzew?

²L. Breiman, J. Friedman, R.A. Olshen, C.J. Stone: *Classification and Regression Trees*. Chapman and Hall/CRC, Nowy Jork 1984.

Pruning: możemy obcinać zachłannie

Jak znaleźć drzewo T minimalizujące funkcję $J_\alpha(T)$? Czy musimy rozważać wykładniczo (względem $|T_0|$) wiele poddrzew?

Na szczęście nie. Okazuje się, że wystarczy co najwyżej $|T_0| - 1$.

Szukamy poddrzewa właściwego $T_1 \subsetneq T_0$, które minimalizuje $\widehat{R}(T_1) - \widehat{R}(T_0)$. Drzewo T_1 ma rozmiar $|T_0| - 1$.

Następnie szukamy drzewa $T_2 \subsetneq T_1$ minimalizującego $\widehat{R}(T_2) - \widehat{R}(T_1)$. Postępujemy tak do momentu, aż „zetniemy” całe drzewo T_0 .

²L. Breiman, J. Friedman, R.A. Olshen, C.J. Stone: *Classification and Regression Trees*. Chapman and Hall/CRC, Nowy Jork 1984.

Pruning: możemy obcinać zachłannie

Jak znaleźć drzewo T minimalizujące funkcję $J_\alpha(T)$? Czy musimy rozważać wykładniczo (względem $|T_0|$) wiele poddrzew?

Na szczęście nie. Okazuje się, że wystarczy co najwyżej $|T_0| - 1$.

Szukamy poddrzewa właściwego $T_1 \subsetneq T_0$, które minimalizuje $\widehat{R}(T_1) - \widehat{R}(T_0)$. Drzewo T_1 ma rozmiar $|T_0| - 1$.

Następnie szukamy drzewa $T_2 \subsetneq T_1$ minimalizującego $\widehat{R}(T_2) - \widehat{R}(T_1)$. Postępujemy tak do momentu, aż „zetniemy” całe drzewo T_0 .

Dostajemy rodzinę drzew $\mathcal{T} = \{T_0, T_1, T_2, \dots, T_{|T_0|-1}\}$. Breiman ze współautorami² udowodnili, że

$$\{\arg \min_{T \subseteq T_0} J_\alpha(T) : \alpha \geq 0\} \subseteq \mathcal{T}.$$

²L. Breiman, J. Friedman, R.A. Olshen, C.J. Stone: *Classification and Regression Trees*. Chapman and Hall/CRC, Nowy Jork 1984.

Drzewa decyzyjne dla klasyfikacji

Rozważamy problemy klasyfikacji z przestrzenią wyjść $\{1, \dots, K\}$.

Każdy liść odpowiada pewnemu obszarowi R_n o m_n obserwacjach.

Dla liścia n oraz klasy $k \in \{1, \dots, K\}$ definiujemy

$$\hat{p}_{nk} = \frac{1}{m_n} \sum_{i: x^{(i)} \in R_n} \mathbf{1}[y^{(i)} = k],$$

czyli stosunek liczby elementów z klasy k do wszystkich punktów z R_n .

Każdemu liściowi odpowiada więc ciąg prawdopodobieństw

$$(\hat{p}_{n1}, \dots, \hat{p}_{nK}).$$

Drzewa decyzyjne dla klasyfikacji

Rozważamy problemy klasyfikacji z przestrzenią wyjść $\{1, \dots, K\}$.

Każdy liść odpowiada pewnemu obszarowi R_n o m_n obserwacjach.

Dla liścia n oraz klasy $k \in \{1, \dots, K\}$ definiujemy

$$\hat{p}_{nk} = \frac{1}{m_n} \sum_{i: x^{(i)} \in R_n} \mathbf{1}[y^{(i)} = k],$$

czyli stosunek liczby elementów z klasy k do wszystkich punktów z R_n .


Każdemu liściowi odpowiada więc ciąg prawdopodobieństw

$$(\hat{p}_{n1}, \dots, \hat{p}_{nK}).$$

Naturalnym wyborem funkcji decyzyjnej jest


$$h(n) = \arg \max_k \hat{p}_{nk}.$$

Jak dzielić?




Błędnie sklasyfikowane są ■ i ●, czyli *błąd klasyfikacji* wynosi $\frac{1}{4}$.

Jak dzielić?




Błędnie sklasyfikowane są ■ i ●, czyli *błąd klasyfikacji* wynosi $\frac{1}{4}$.




Błędnie sklasyfikowane są ■ ■, czyli *błąd klasyfikacji* wynosi $\frac{1}{4}$.

Jak dzielić?




Błędnie sklasyfikowane są ■ i ●, czyli *błąd klasyfikacji* wynosi $\frac{1}{4}$.




Błędnie sklasyfikowane są ■ ■, czyli *błąd klasyfikacji* wynosi $\frac{1}{4}$.

W pierwszym przykładzie potrzebne są jeszcze co najmniej dwa podziały, w drugim być może wystarczy tylko jeden.

Jak dzielić?



Błędnie sklasyfikowane są ■ i ●, czyli *błąd klasyfikacji* wynosi $\frac{1}{4}$.



Błędnie sklasyfikowane są ■ ■, czyli *błąd klasyfikacji* wynosi $\frac{1}{4}$.

W pierwszym przykładzie potrzebne są jeszcze co najmniej dwa podziały, w drugim być może wystarczy tylko jeden.

Chcemy, aby liście były możliwie „czyste”.

Miary nieczystości

- Błąd klasyfikacji


$$1 - \hat{p}_{mh(m)}$$

- Współczynnik Giniego

$$\sum_{k=1}^K \hat{p}_{mk}(1 - \hat{p}_{mk})$$

- Entropia

$$-\sum_{k=1}^K \hat{p}_{mk} \ln \hat{p}_{mk}$$



Miary nieczystości dla klasyfikacji binarnej jako funkcja proporcji p przynależności do klasy 2. W tym przypadku powyższe miary to: $1 - \max(p, 1 - p)$, $2p(1 - p)$ oraz $-p \ln p - (1 - p) \ln(1 - p)$.

Jak konstruować drzewo decyzyjne?

Dla każdego kryterium x_i dzielimy dane na dwa obszary: R_0^i (dane dla $x_i = 0$) oraz R_1^i (dane dla $x_i = 1$).

Niech $|R_0^i| = N_0^i$ oraz $|R_1^i| = N_1^i$.

Liczymy miarę nieczystości Q dla obu obszarów: $Q(R_0)$ i $Q(R_1)$.

Dla każdego kryterium i obliczamy jego ważoną miarę nieczystości:

$$N_0^i Q(R_0^i) + N_1^i Q(R_1^i).$$

Wybieramy takie kryterium podziału, dla którego powyższa wartość jest najmniejsza.

Kolejne kryteria wybieramy rekurencyjnie (niezależnie dla każdej z gałęzi).

Przykład: biegać czy zostać w domu?

Założmy, że mamy ochotę pobiegać. Aktualne warunki atmosferyczne są następujące:

- pada deszcz,
- temperatura wynosi 18°C .

Ponadto zjedliśmy duży obiad przed trzema godzinami. Czy warto teraz wyjść na trening biegowy?

Odwołajmy się do naszych dotychczasowych doświadczeń:

deszcz	temp > 15°C	duży obiad (<2h)	Czy było fajnie?
T	N	T	T
N	T	T	T
T	N	N	N
N	T	T	N
⋮	⋮	⋮	⋮

Istotność cech wyliczamy na podstawie współczynnika Giniego.

Przykład: biegać czy zostać w domu?

Tabelę doświadczeń możemy przedstawić w następujący sposób

deszcz			
T		N	
+	-	+	-
112	26	38	80

temp			
T		N	
+	-	+	-
38	73	112	33

obiad			
T		N	
+	-	+	-
22	78	128	28

$$G_T = 1 - \left(\frac{112}{138}\right)^2 - \left(\frac{26}{138}\right)^2 = 0.306$$

$$G_N = 1 - \left(\frac{38}{118}\right)^2 - \left(\frac{80}{118}\right)^2 = 0.437$$

$$G = 0.306 \cdot \frac{138}{256} + 0.437 \cdot \frac{118}{256} = 0.366$$

$$G_T = 0.450$$

$$G_N = 0.352$$


$$G = 0.394$$

$$G_T = 0.343$$

$$G_N = 0.295$$

$$G = 0.314$$


Przykład: biegać czy zostać w domu?



$$G_T = 0.482$$

$$G_N = 0.198$$

$$G = 0.303$$




$$G_T = 0.350$$

$$G_N = 0.332$$

$$G = 0.343$$


Przykład: biegać czy zostać w domu?



$$G_T = 0.076$$

$$G_N = 0.491$$

$$G = 0.222$$




$$G_T = 0.499$$

$$G_N = 0.055$$

$$G = 0.194$$


Przykład: biegać czy zostać w domu?



$$G_T = 0.255$$

$$G_N = 0.000$$

$$G = 0.182 < 0.482$$




$$G_T = 0.366$$

$$G_N = 0.000$$

$$G = 0.180 < 0.198$$


Przykład: biegać czy zostać w domu?



$$G_T = 0.366$$

$$G_N = 0.334$$

$$G = 0.349 < 0.499$$




$$G_T = 0.024$$

$$G_N = 0.142$$

$$G = 0.052 < 0.055$$

Przykład: biegać czy zostać w domu?



Klasyfikacja binarna: wiele wartości cechy

Założmy, że pewna cecha x_j ma q nieporównywalnych możliwych wartości $A_1, \dots, A_q$.

Mamy wtedy $2^{q-1} - 1$ możliwych podziałów na dwa niepuste podzbiory. Nie chcemy sprawdzać wszystkich w poszukiwaniu optymalnego podziału.

Ustalamy klasę $k \in \{0, 1\}$. Sprawdzamy, jak często obserwacje takie, że $x_j = A_1$ należą do klasy k . Następnie liczymy częstości dla A_2, A_3 , aż do A_q . Porządkujemy rosnąco otrzymane proporcje:

$$(p(A_{r_1}), \dots, p(A_{r_q})).$$

Na podstawie powyższego uporządkowania dzielimy wartości cechy x_j na dwie rozłączne części (mamy $q - 1$ różnych możliwości):

$$\{A_{r_1}, \dots, A_{r_t}\} \quad \text{oraz} \quad \{A_{r_{t+1}}, \dots, A_{r_q}\}.$$

Wady i zalety drzew decyzyjnych

Zalety:

- są intuicyjne z „ludzkiego” punktu widzenia,
- bardzo szybko klasyfikują nowe dane,
- nie wymagają skalowania/normalizacji danych,
- mogą radzić sobie z brakującymi wartościami.

Wady i zalety drzew decyzyjnych

Zalety:

- są intuicyjne z „ludzkiego” punktu widzenia,
- bardzo szybko klasyfikują nowe dane,
- nie wymagają skalowania/normalizacji danych,
- mogą radzić sobie z brakującymi wartościami.

Wady:

- zwracana hipoteza niekoniecznie jest optymalna,
- dla danych o wartościach rzeczywistych podziały są tylko „wzdłuż osi”,
- małe zmiany w danych treningowych mogą całkowicie zmienić strukturę drzewa,
- czas uczenia może być bardzo duży.

Lasy losowe

Bootstrap

Mamy próbkę $S = \{x^{(i)} : i = 1, \dots, m\} \subseteq \mathcal{X}$.

Próbką bootstrapową z próbki S nazywamy m -elementowy (multi)zbiór elementów wybranych z S z jednostajnym prawdopodobieństwem i ze zwracaniem.

Bootstrap

Mamy próbkę $S = \{x^{(i)} : i = 1, \dots, m\} \subseteq \mathcal{X}$.

Próbką bootstrapową z próbki S nazywamy m -elementowy (multi)zbiór elementów wybranych z S z jednostajnym prawdopodobieństwem i ze zwracaniem.

deszcz	temp	obiad	samotnie	wiatr	fajnie?
T	13°	T	T	3m/s	T
N	4°	T	N	10m/s	T
T	25°	N	N	5m/s	N
N	-2°	T	T	12m/s	N
⋮	⋮	⋮	⋮	⋮	⋮

Bootstrap

Mamy próbkę $S = \{x^{(i)} : i = 1, \dots, m\} \subseteq \mathcal{X}$.

Próbką bootstrapową z próbki S nazywamy m -elementowy (multi)zbiór elementów wybranych z S z jednostajnym prawdopodobieństwem i ze zwracaniem.

deszcz	temp	obiad	samotnie	wiatr	fajnie?
T	13°	T	T	3m/s	T
N	4°	T	N	10m/s	T
T	25°	N	N	5m/s	N
N	-2°	T	T	12m/s	N
⋮	⋮	⋮	⋮	⋮	⋮



Bootstrap

Mamy próbkę $S = \{x^{(i)} : i = 1, \dots, m\} \subseteq \mathcal{X}$.

Próbką bootstrapową z próbki S nazywamy m -elementowy (multi)zbiór elementów wybranych z S z jednostajnym prawdopodobieństwem i ze zwracaniem.

deszcz	temp	obiad	samotnie	wiatr	fajnie?
T	13°	T	T	3m/s	T
N	4°	T	N	10m/s	T
T	25°	N	N	5m/s	N
N	-2°	T	T	12m/s	N
⋮	⋮	⋮	⋮	⋮	⋮



Prawdopodobieństwo, że dana obserwacja nie zostanie wybrana do próbki bootstrapowej wynosi

$$\left(1 - \frac{1}{m}\right)^m \sim \frac{1}{e} \approx 37\%.$$

Próbki niezależne vs bootstrapowe



Rozważmy oryginalną próbkę $S = \{x^{(i)} : i = 1, \dots, m\}$ oraz B próbek bootstrapowych $S_1, \dots, S_B$ (każda o m elementach).

Chcąc oszacować pewien parametr ϕ (np. średnią lub wariancję) nieznanego rozkładu, zgodnie z którym wybrane zostały dane do zbioru S , możemy policzyć wartość empiryczną poszukiwanego parametru na każdej próbce bootstrapowej:

$$\phi(S_1), \dots, \phi(S_B),$$

Okazuje się, że często histogram dla powyższych danych oraz histogram dla analogicznie wyznaczonych wartości na B niezależnie wybranych m -elementowych próbkach są do siebie bardzo podobne.

Próbki niezależne vs bootstrapowe



Po lewej: histogram dla 1000 niezależnych próbek.

Po prawej: histogram dla 1000 bootstrapowych próbek.

W każdej próbce 100 elementów.

Dlaczego bootstrap?

W rzeczywistości nie możemy lub nie chcemy generować bardzo wielu próbek z całej populacji. Metoda bootstrap pozwala na symulację tworzenia nowych próbek i ocenę zmienności estymowanych parametrów.

Dlaczego bootstrap?

W rzeczywistości nie możemy lub nie chcemy generować bardzo wielu próbek z całej populacji. Metoda bootstrap pozwala na symulację tworzenia nowych próbek i ocenę zmienności estymowanych parametrów.

Niech $Z_1, \dots, Z_n$ będą niezależnymi zmiennymi losowymi o tym samym rozkładzie takimi, że $\mathbb{E}Z_i = \mu$ oraz $\text{var}(Z_i) = \sigma^2$.

Rozważmy średnią ze wszystkich zmiennych Z_i . Wtedy

$$\mathbb{E}\left[\frac{1}{n} \sum_{i=1}^n Z_i\right] = \mu \quad \text{oraz} \quad \text{var}\left[\frac{1}{n} \sum_{i=1}^n Z_i\right] = \frac{\sigma^2}{n}.$$

Dlaczego bootstrap?

W rzeczywistości nie możemy lub nie chcemy generować bardzo wielu próbek z całej populacji. Metoda bootstrap pozwala na symulację tworzenia nowych próbek i ocenę zmienności estymowanych parametrów.

Niech $Z_1, \dots, Z_n$ będą niezależnymi zmiennymi losowymi o tym samym rozkładzie takimi, że $\mathbb{E}Z_i = \mu$ oraz $\text{var}(Z_i) = \sigma^2$.

Rozważmy średnią ze wszystkich zmiennych Z_i . Wtedy

$$\mathbb{E}\left[\frac{1}{n} \sum_{i=1}^n Z_i\right] = \mu \quad \text{oraz} \quad \text{var}\left[\frac{1}{n} \sum_{i=1}^n Z_i\right] = \frac{\sigma^2}{n}.$$

Dzięki uśrednieniu zmiennych otrzymaliśmy mniejszą wariancję.

Dlaczego bootstrap?

W rzeczywistości nie możemy lub nie chcemy generować bardzo wielu próbek z całej populacji. Metoda bootstrap pozwala na symulację tworzenia nowych próbek i ocenę zmienności estymowanych parametrów.

Niech $Z_1, \dots, Z_n$ będą niezależnymi zmiennymi losowymi o tym samym rozkładzie takimi, że $\mathbb{E}Z_i = \mu$ oraz $\text{var}(Z_i) = \sigma^2$.

Rozważmy średnią ze wszystkich zmiennych Z_i . Wtedy

$$\mathbb{E}\left[\frac{1}{n} \sum_{i=1}^n Z_i\right] = \mu \quad \text{oraz} \quad \text{var}\left[\frac{1}{n} \sum_{i=1}^n Z_i\right] = \frac{\sigma^2}{n}.$$

Dzięki uśrednieniu zmiennych otrzymaliśmy mniejszą wariancję.

Problem: próbki bootstrapowe są warunkowo niezależne pod warunkiem oryginalnej próbki, ale zależne względem całej populacji.

Bagging (*b*ootstrap *a*ggregate)

Niech $S_1, \dots, S_B$ będą niezależnymi m -elementowymi zbiorami treningowymi.
Algorytm uczący zwraca B różnych funkcji decyzyjnych $\hat{h}_1(x), \dots, \hat{h}_B(x)$. Tworzymy nową hipotezę dla problemu regresji:

$$\hat{h}(x) = \frac{1}{B} \sum_{b=1}^B \hat{h}_b(x)$$

lub dla problemu klasyfikacji:

$$\arg \max_{k \in \{1, \dots, K\}} \sum_{b=1}^B \mathbf{1}[\hat{h}_b(x) = k].$$

Bagging (*b*ootstrap *a*ggregate)

Niech $S_1, \dots, S_B$ będą niezależnymi m -elementowymi zbiorami treningowymi.
Algorytm uczący zwraca B różnych funkcji decyzyjnych $\hat{h}_1(x), \dots, \hat{h}_B(x)$. Tworzymy nową hipotezę dla problemu regresji:

$$\hat{h}(x) = \frac{1}{B} \sum_{b=1}^B \hat{h}_b(x)$$

lub dla problemu klasyfikacji:

$$\arg \max_{k \in \{1, \dots, K\}} \sum_{b=1}^B \mathbf{1}[\hat{h}_b(x) = k].$$

W praktyce pomysł uśredniania zmiennych sprawdza się dobrze nawet w przypadku próbek bootstrapowych (pomimo zależności).

Błąd out-of-bag

Niech $S_1, \dots, S_B$ będą m -elementowymi próbkami bootstrapowymi z pewnego oryginalnego zbioru treningowego S , natomiast $\hat{h}_1, \dots, \hat{h}_B$ hipotezami otrzymanymi na podstawie tych próbek.

Jak już zauważyliśmy każda z hipotez jest średnio otrzymana na podstawie ok. 63% danych z S . Pozostałe 37% traktujemy jako dane walidacyjne.

Błąd out-of-bag

Niech $S_1, \dots, S_B$ będą m -elementowymi próbkami bootstrapowymi z pewnego oryginalnego zbioru treningowego S , natomiast $\hat{h}_1, \dots, \hat{h}_B$ hipotezami otrzymanymi na podstawie tych próbek.

Jak już zauważyliśmy każda z hipotez jest średnio otrzymana na podstawie ok. 63% danych z S . Pozostałe 37% traktujemy jako dane walidacyjne.

Zdefiniujmy dla punktu $x^{(i)}$ z S zbiór

$$S^{(i)} = \{b: x^{(i)} \notin S_b\}.$$

Dla punktu $x^{(i)}$ definiujemy *hipotezę out-of-bag* następująco:

$$\hat{h}_{\text{OOB}}(x^{(i)}) = \frac{1}{|S^{(i)}|} \sum_{b \in S^{(i)}} \hat{h}_b(x^{(i)}).$$

Błąd out-of-bag

Niech $S_1, \dots, S_B$ będą m -elementowymi próbkami bootstrapowymi z pewnego oryginalnego zbioru treningowego S , natomiast $\hat{h}_1, \dots, \hat{h}_B$ hipotezami otrzymanymi na podstawie tych próbek.

Jak już zauważyliśmy każda z hipotez jest średnio otrzymana na podstawie ok. 63% danych z S . Pozostałe 37% traktujemy jako dane walidacyjne.

Zdefiniujmy dla punktu $x^{(i)}$ z S zbiór

$$S^{(i)} = \{b: x^{(i)} \notin S_b\}.$$

Dla punktu $x^{(i)}$ definiujemy *hipotezę out-of-bag* następująco:

$$\hat{h}_{\text{OOB}}(x^{(i)}) = \frac{1}{|S^{(i)}|} \sum_{b \in S^{(i)}} \hat{h}_b(x^{(i)}).$$

Błąd dla powyższego przewidywania nazywamy *błędem out-of-bag*. Jest on dobrym estymatorem błędu dla badanej hipotezy.

Las losowy

Las losowy to zbiór wielu drzew decyzyjnych, przy czym konstruuując drzewa, nie uwzględniamy wszystkich cech: są one wybierane losowo dla każdego nowego węzła w budowanym drzewie.

Częstym wyborem liczby cech użytych na poszczególnych etapach konstrukcji jest $\sqrt{n}$, gdzie n jest liczbą wszystkich cech danych wejściowych. Można ją również dobrać na podstawie wyników na zbiorze walidacyjnym.

Taki losowy wybór cech pozwala na zmniejszenie korelacji (równoważnie: zwiększenie niezależności) między kolejnymi danymi.

Proces uczenia nowych drzew kończymy, gdy zaobserwujemy stabilizację błędu out-of-bag.

Przykład

deszcz	temp	obiad	samotnie	wiatr	fajnie?
T	13°	T	T	3m/s	T
N	4°	T	N	10m/s	T
T	25°	N	N	5m/s	N
N	-2°	T	T	12m/s	N
⋮	⋮	⋮	⋮	⋮	⋮

✓
✗
✓ ✓
✗
...

Przykład

deszcz	temp	obiad	samotnie	wiatr	fajnie?
T	13°	T	T	3m/s	T
N	4°	T	N	10m/s	T
T	25°	N	N	5m/s	N
N	-2°	T	T	12m/s	N
⋮	⋮	⋮	⋮	⋮	⋮

deszcz	temp	obiad	samotnie	wiatr	fajnie?
T	13°	T	T	3m/s	T
T	25°	N	N	5m/s	N
T	25°	N	N	5m/s	N
⋮	⋮	⋮	⋮	⋮	⋮


✓
✗
✓ ✓
✗
...

Przykład

deszcz	temp	obiad	samotnie	wiatr	fajnie?
T	13°	T	T	3m/s	T
N	4°	T	N	10m/s	T
T	25°	N	N	5m/s	N
N	-2°	T	T	12m/s	N
⋮	⋮	⋮	⋮	⋮	⋮

✓
✗
✓ ✓
✗
...

deszcz	temp	obiad	samotnie	wiatr	fajnie?
T	13°	T	T	3m/s	T
T	25°	N	N	5m/s	N
T	25°	N	N	5m/s	N
⋮	⋮	⋮	⋮	⋮	⋮




Przykład


deszcz	temp	obiad	samotnie	wiatr	fajnie?
T	13°	T	T	3m/s	T
N	4°	T	N	10m/s	T
T	25°	N	N	5m/s	N
N	-2°	T	T	12m/s	N
⋮	⋮	⋮	⋮	⋮	⋮

✓
✗
✓ ✓
✗
...



deszcz	temp	obiad	samotnie	wiatr	fajnie?
T	13°	T	T	3m/s	T
T	25°	N	N	5m/s	N
T	25°	N	N	5m/s	N
⋮	⋮	⋮	⋮	⋮	⋮





Przykład



Przykład





Przykład



...


Przykład



...

deszcz	temp	obiad	samotnie	wiatr	fajnie?
N	6°	N	N	7m/s	?

Przykład



deszcz	temp	obiad	samotnie	wiatr	fajnie?
N	16°	N	N	7m/s	T

Wady i zalety lasów losowych

Zalety:

- mają mniejszą wariancję niż drzewa decyzyjne (czyli ograniczają przeuczenie),
- błąd out-of-bag może służyć do szacowania wydajności modelu,
- radzą sobie z brakującymi danymi,
- sprawdzają się dobrze dla dużych wielowymiarowych zbiorów danych,
- nowa obserwacja w zbiorze treningowym nie wpływa istotnie na działanie algorytmu.

Wady i zalety lasów losowych

Zalety:

- mają mniejszą wariancję niż drzewa decyzyjne (czyli ograniczają przeuczenie),
- błąd out-of-bag może służyć do szacowania wydajności modelu,
- radzą sobie z brakującymi danymi,
- sprawdzają się dobrze dla dużych wielowymiarowych zbiorów danych,
- nowa obserwacja w zbiorze treningowym nie wpływa istotnie na działanie algorytmu.

Wady:

- są trudniejsze do zinterpretowania niż drzewa decyzyjne,
- nie zawsze dobrze radzą sobie z problemami regresji,
- mają znacznie większe wymagania obliczeniowe i pamięciowe niż drzewa decyzyjne,
- gdy cechy są silnie skorelowane, to jest spore ryzyko przeuczenia.

Brakujące wartości w danych

Łatanie dziur

Co zrobić, gdy brakuje niektórych cech?

- Nie rozważać takich danych.

Łatanie dziur

Co zrobić, gdy brakuje niektórych cech?

- Nie rozważać takich danych.
- Uzupełnić brakujące dane wartością średnią (lub medianą, dominantą...) cechy (względem danej klasy).

Łatanie dziur

Co zrobić, gdy brakuje niektórych cech?

- Nie rozważać takich danych.
- Uzupełnić brakujące dane wartością średnią (lub medianą, dominantą...) cechy (względem danej klasy).
- Dodać nową wartość (np. NaN).

Łatanie dziur

Co zrobić, gdy brakuje niektórych cech?

- Nie rozważać takich danych.
- Uzupełnić brakujące dane wartością średnią (lub medianą, dominantą...) cechy (względem danej klasy).
- Dodać nową wartość (np. NaN).
- Wybrać średnią wartość danej cechy dla danych najsilniej skorelowanych z badaną obserwacją.

Łatanie dziur

Co zrobić, gdy brakuje niektórych cech?

- Nie rozważać takich danych.
- Uzupełnić brakujące dane wartością średnią (lub medianą, dominantą...) cechy (względem danej klasy).
- Dodać nową wartość (np. NaN).
- Wybrać średnią wartość danej cechy dla danych najsilniej skorelowanych z badaną obserwacją.
- Wybrać średnią wartość danej cechy dla danych kierując się cechą najsilniej skorelowaną z wyjściową cechą (*podział zastępczy*).

Łatanie dziur

Co zrobić, gdy brakuje niektórych cech?

- Nie rozważać takich danych.
- Uzupełnić brakujące dane wartością średnią (lub medianą, dominantą...) cechy (względem danej klasy).
- Dodać nową wartość (np. NaN).
- Wybrać średnią wartość danej cechy dla danych najsilniej skorelowanych z badaną obserwacją.
- Wybrać średnią wartość danej cechy dla danych kierując się cechą najsilniej skorelowaną z wyjściową cechą (*podział zastępczy*).
- Dla brakującej cechy x_j dokonać fragmentacji danej proporcjonalnie do częstotliwości występowania różnych wartości x_j dla danych, dla których x_j jest określone.

Lasy losowe w służbie łatania dziur

Brakujące dane mogą się pojawić:

- w danych treningowych,
- w nowej obserwacji wejściowej do sklasyfikowania.

Lasy losowe w służbie łatania dziur

Brakujące dane mogą się pojawić:

- w danych treningowych,
- w nowej obserwacji wejściowej do sklasyfikowania.

Podzielimy je na dwa rodzaje: ciągłe i kategoryczne.

deszcz	temp	obiad	samotnie	wiatr	fajnie?
T	13°	T	N	20m/s	T
?	?	N	N	21m/s	T
N	14°	N	?	3m/s	N
N	?	T	T	5m/s	N
T	17°	N	N	2m/s	T

Ciągłe: temperatura, wiatr.

Kategoryczne: deszcz, obiad, samotnie, fajnie.

Strategia (cz. 1)

W pierwszym kroku uzupełniamy brakujące dane, wybierając dominantę (dla zmiennych kategoriycznych) lub średnią albo medianę (dla zmiennych ciągłych).

Strategia (cz. 1)

W pierwszym kroku uzupełniamy brakujące dane, wybierając dominantę (dla zmiennych kategoriycznych) lub średnią albo medianę (dla zmiennych ciągłych).

Dla takich „pełnych” danych budujemy las losowy.

Strategia (cz. 1)

W pierwszym kroku uzupełniamy brakujące dane, wybierając dominantę (dla zmiennych kategorycznych) lub średnią albo medianę (dla zmiennych ciągłych).

Dla takich „pełnych” danych budujemy las losowy.

Dla każdej cechy o brakujących wartościach budujemy macierz podobieństwa $P_{m \times m}$ obserwacji w następujący sposób:

- sprawdzamy na podstawie lasu losowego, które z obserwacji są do siebie „podobne”, zliczając dla każdej możliwej pary (i, j) wartość p_{ij} określającą, ile razy obserwacje o indeksach i oraz j trafiły do tego samego liścia;

Strategia (cz. 1)

W pierwszym kroku uzupełniamy brakujące dane, wybierając dominantę (dla zmiennych kategoriycznych) lub średnią albo medianę (dla zmiennych ciągłych).

Dla takich „pełnych” danych budujemy las losowy.

Dla każdej cechy o brakujących wartościach budujemy macierz podobieństwa $P_{m \times m}$ obserwacji w następujący sposób:

- sprawdzamy na podstawie lasu losowego, które z obserwacji są do siebie „podobne”, zliczając dla każdej możliwej pary (i, j) wartość p_{ij} określającą, ile razy obserwacje o indeksach i oraz j trafiły do tego samego liścia;
- dla każdej pary (i, j) wpisujemy do macierzy otrzymaną wartość podzieloną przez liczbę drzew ℓ w lesie:

$$P_{ij} = P_{ji} \leftarrow \frac{p_{ij}}{\ell}, \quad \text{przy czym } P_{ii} \leftarrow 0.$$

Strategia (cz. 2)

Jeżeli rozważana cecha x_k jest kategoryczna, to dla każdej obserwacji $(x^{(i)}, y^{(i)})$ z początkowo brakującą wartością $x_k^{(i)}$ obliczamy ważoną częstotliwość pojawienia się możliwej wartości v :

$$w_v^{(i)} \leftarrow \frac{\sum_{j=1}^m \mathbf{1}[x_k^{(j)} = v, j \neq i]}{m - 1} \cdot \frac{\sum_{j=1}^m P_{ij} \cdot \mathbf{1}[x_k^{(j)} = v]}{\sum_{j=1}^m P_{ij}}.$$

Na koniec modyfikujemy wartość cechy w obserwacji $x^{(i)}$:

$$x_k^{(i)} \leftarrow \arg \max_v \{w_v^{(i)}\}.$$

Strategia (cz. 2)

Jeżeli rozważana cecha x_k jest kategoryczna, to dla każdej obserwacji $(x^{(i)}, y^{(i)})$ z początkowo brakującą wartością $x_k^{(i)}$ obliczamy ważoną częstotliwość pojawienia się możliwej wartości v :

$$w_v^{(i)} \leftarrow \frac{\sum_{j=1}^m \mathbf{1}[x_k^{(j)} = v, j \neq i]}{m - 1} \cdot \frac{\sum_{j=1}^m P_{ij} \cdot \mathbf{1}[x_k^{(j)} = v]}{\sum_{j=1}^m P_{ij}}.$$

Na koniec modyfikujemy wartość cechy w obserwacji $x^{(i)}$:

$$x_k^{(i)} \leftarrow \arg \max_v \{w_v^{(i)}\}.$$

Jeżeli rozważana cecha x_k jest ciągła, to dla każdej obserwacji $(x^{(i)}, y^{(i)})$ z początkowo brakującą wartością $x_k^{(i)}$ modyfikujemy jej wartość według wzoru

$$x_k^{(i)} \leftarrow \sum_{j=1}^m x_k^{(j)} \cdot \frac{P_{ij}}{\sum_{s=1}^m P_{is}}.$$

Strategia (cz. 3) i wybrakowane dane testowe

W powyższy sposób uaktualniliśmy brakujące dane jednokrotnie.

Dla otrzymanych nowych danych postępujemy rekurencyjnie: budujemy nowy las, dla brakujących cech tworzymy nowe macierze podobieństwa, uaktualniamy dane itd.

Powtarzamy powyższe operacje przez określoną liczbę kroków lub do momentu, aż zauważymy stabilizację wyników.

Strategia (cz. 3) i wybrakowane dane testowe

W powyższy sposób uaktualniliśmy brakujące dane jednokrotnie.

Dla otrzymanych nowych danych postępujemy rekurencyjnie: budujemy nowy las, dla brakujących cech tworzymy nowe macierze podobieństwa, uaktualniamy dane itd.

Powtarzamy powyższe operacje przez określoną liczbę kroków lub do momentu, aż zauważymy stabilizację wyników.

Jeżeli brakuje wartości cech w danych testowych, to dla obserwacji, którą chcemy sklasyfikować, tworzymy dwie kopie: jedną z wartością wyjściową $+1$, drugą z wartością wyjściową -1 . W obu przypadkach poszukujemy brakujących wartości tak jak wcześniej. Dla ostatecznie uzupełnionych wartości sprawdzamy standardowym algorytmem, która z dwóch kopii została częściej poprawnie sklasyfikowana.

Przykład działania

deszcz	temp	obiad	samotnie	wiatr	fajnie?
T	13°	T	N	20m/s	T
?	?	N	N	21m/s	T
N	14°	N	?	3m/s	N
N	?	T	T	5m/s	N
T	18°	N	N	2m/s	T

Przykład działania

deszcz	temp	obiad	samotnie	wiatr	fajnie?
T	13°	T	N	20m/s	T
?	15°	N	N	21m/s	T
N	14°	N	N	3m/s	N
N	15°	T	T	5m/s	N
T	18°	N	N	2m/s	T

Przykład działania

deszcz	temp	obiad	samotnie	wiatr	fajnie?
T	13°	T	N	20m/s	T
?	15°	N	N	21m/s	T
N	14°	N	N	3m/s	N
N	15°	T	T	5m/s	N
T	18°	N	N	2m/s	T

Założmy, że pewien las z 10 drzewami da nam dla cechy x_1 , czyli deszcz, następującą macierz podobieństwa:

$$\begin{bmatrix} 0 & 0.2 & 0.3 & 0 & 0.1 \\ 0.2 & 0 & 0.1 & 0.1 & 0.8 \\ 0.3 & 0.1 & 0 & 0.2 & 0.3 \\ 0 & 0.1 & 0.2 & 0 & 0 \\ 0.1 & 0.8 & 0.3 & 0 & 0 \end{bmatrix}.$$

Przykład działania cd.

$$\begin{bmatrix} 0 & \mathbf{0.2} & 0.3 & 0 & 0.1 \\ 0.2 & \mathbf{0} & 0.1 & 0.1 & 0.8 \\ 0.3 & \mathbf{0.1} & 0 & 0.2 & 0.3 \\ 0 & \mathbf{0.1} & 0.2 & 0 & 0 \\ 0.1 & \mathbf{0.8} & 0.3 & 0 & 0 \end{bmatrix}$$

Szukamy ważonych częstotliwości dla $x_1 = T$ oraz $x_1 = N$:

$$w_T^{(2)} = \frac{2}{4} \cdot \frac{0.2 + 0.8}{0.2 + 0.1 + 0.1 + 0.8} = \frac{5}{12},$$
$$w_N^{(2)} = \frac{2}{4} \cdot \frac{0.1 + 0.1}{0.2 + 0.1 + 0.1 + 0.8} = \frac{1}{12}.$$

Ponieważ $w_T^{(2)} > w_N^{(2)}$, to ustalamy $x_1^{(2)} = T$.