

Metody probabilistyczne w uczeniu maszynowym

Wykład 10: model PAC, złożoność próbkowa, funkcja wzrostu,
wymiar Wapnika–Czerwonienkisa

Katarzyna Grygiel

Semestr letni 2024/2025

Pojęcia i hipotezy

Niech $\mathcal{X}$ będzie przestrzenią wejść, a $\mathcal{Y} = \{0, 1\}$ przestrzenią wyjść.

Pojęciem nazywamy funkcję $c: \mathcal{X} \rightarrow \mathcal{Y}$.

Ponieważ $\mathcal{Y} = \{0, 1\}$, to pojęcie c możemy utożsamiać ze zbiorem $\{x \in \mathcal{X}: c(x) = 1\}$.

Pojęcia i hipotezy

Niech $\mathcal{X}$ będzie przestrzenią wejść, a $\mathcal{Y} = \{0, 1\}$ przestrzenią wyjść.

Pojęciem nazywamy funkcję $c: \mathcal{X} \rightarrow \mathcal{Y}$.

Ponieważ $\mathcal{Y} = \{0, 1\}$, to pojęcie c możemy utożsamiać ze zbiorem $\{x \in \mathcal{X}: c(x) = 1\}$.

Klasą pojęć nazywamy podzbiór $\mathcal{C} \subseteq \mathcal{Y}^{\mathcal{X}}$.

Zbiór hipotez $\mathcal{H} \subseteq \mathcal{Y}^{\mathcal{X}}$, które rozważa algorytm uczący, nie musi być tożsamy z klasą $\mathcal{C}$.

Zakładamy, że dana jest próbka $S = \{x^{(i)}: i = 1, \dots, m\}$ wybrana z $\mathcal{X}$ niezależnie z pewnym rozkładem $\mathcal{D}$ oraz zbiór etykiet $\{y^{(i)}: i = 1, \dots, m\}$ takich, że dla pewnego $c \in \mathcal{C}$ zachodzi $c(x^{(i)}) = y^{(i)}$.

Ryzyko i błąd empiryczny: przypomnienie

Dla hipotezy $h \in \mathcal{H}$, pojęcia $c \in \mathcal{C}$ oraz rozkładu $\mathcal{D}$ na przestrzeni wejść *ryzykiem* hipotezy h nazywamy oczekiwany błąd h na nowej danej wejściowej:

$$R(h) = \mathbb{E}_{\mathcal{D}} [\mathbf{1}[h(x) \neq c(x)]].$$

Zadaniem algorytmu uczącego jest wybór takiej hipotezy, która minimalizuje ryzyko dla ustalonego (ale nieznanego) pojęcia c .

Ryzyko i błąd empiryczny: przypomnienie

Dla hipotezy $h \in \mathcal{H}$, pojęcia $c \in \mathcal{C}$ oraz rozkładu $\mathcal{D}$ na przestrzeni wejść *ryzykiem* hipotezy h nazywamy oczekiwany błąd h na nowej danej wejściowej:

$$R(h) = \mathbb{E}_{\mathcal{D}} [\mathbf{1}[h(x) \neq c(x)]].$$

Zadaniem algorytmu uczącego jest wybór takiej hipotezy, która minimalizuje ryzyko dla ustalonego (ale nieznanego) pojęcia c .

Dla hipotezy $h \in \mathcal{H}$, pojęcia $c \in \mathcal{C}$ i próbki $S = \{x^{(i)} : i = 1, \dots, m\}$ *błędem empirycznym* hipotezy h nazywamy średni błąd h na S :

$$\hat{R}(h) = \frac{1}{m} \sum_{i=1}^m \mathbf{1}[h(x^{(i)}) \neq c(x^{(i)})].$$

Ryzyko i błąd empiryczny: przypomnienie

Dla hipotezy $h \in \mathcal{H}$, pojęcia $c \in \mathcal{C}$ oraz rozkładu $\mathcal{D}$ na przestrzeni wejść *ryzykiem* hipotezy h nazywamy oczekiwany błąd h na nowej danej wejściowej:

$$R(h) = \mathbb{E}_{\mathcal{D}} [\mathbf{1}[h(x) \neq c(x)]].$$

Zadaniem algorytmu uczącego jest wybór takiej hipotezy, która minimalizuje ryzyko dla ustalonego (ale nieznanego) pojęcia c .

Dla hipotezy $h \in \mathcal{H}$, pojęcia $c \in \mathcal{C}$ i próbki $S = \{x^{(i)} : i = 1, \dots, m\}$ *błędem empirycznym* hipotezy h nazywamy średni błąd h na S :

$$\hat{R}(h) = \frac{1}{m} \sum_{i=1}^m \mathbf{1}[h(x^{(i)}) \neq c(x^{(i)})].$$

Dla dowolnej hipotezy $h \in \mathcal{H}$ oraz próbki S zachodzi

$$\mathbb{E}_{S \sim \mathcal{D}^m} \hat{R}(h) = R(h).$$

Model PAC (*Probably Approximately Correct*)

Klasa pojęć $\mathcal{C}$ jest *PAC-nauczalna*, gdy istnieją algorytm A oraz funkcja wielomianowa $Q: \mathbb{R}^2 \rightarrow \mathbb{R}$ takie, że dla wszystkich $\varepsilon > 0$ i $\delta > 0$, dowolnego rozkładu $\mathcal{D}$ na $\mathcal{X}$ oraz dowolnego pojęcia $c \in \mathcal{C}$ jeżeli liczność m próbki S spełnia $m \geq Q(1/\varepsilon, 1/\delta)$, to algorytm A zwraca hipotezę h_S , dla której zachodzi

$$p(R(h_S) \leq \varepsilon) \geq 1 - \delta.$$

Model PAC (*Probably Approximately Correct*)

Klasa pojęć $\mathcal{C}$ jest *PAC-nauczalna*, gdy istnieją algorytm A oraz funkcja wielomianowa $Q: \mathbb{R}^2 \rightarrow \mathbb{R}$ takie, że dla wszystkich $\varepsilon > 0$ i $\delta > 0$, dowolnego rozkładu $\mathcal{D}$ na $\mathcal{X}$ oraz dowolnego pojęcia $c \in \mathcal{C}$ jeżeli liczność m próbki S spełnia $m \geq Q(1/\varepsilon, 1/\delta)$, to algorytm A zwraca hipotezę h_S , dla której zachodzi

$$p(R(h_S) \leq \varepsilon) \geq 1 - \delta.$$

- Powyższa nierówność zachodzi niezależnie od rozkładu.
- Dane treningowe i testowe są wybierane niezależnie i zawsze z tym samym rozkładem.
- Algorytm zna klasę pojęć $\mathcal{C}$, nie zna natomiast docelowego pojęcia $c \in \mathcal{C}$.

Uwaga. Formalnie funkcja Q powinna być również wielomianowa względem rozmiaru reprezentacji dowolnego elementu $x \in \mathcal{X}$ oraz pojęcia c .

Przykład: prostokąty w $\mathbb{R}^2$

Niech $\mathcal{X} = \mathbb{R}^2$ oraz niech $\mathcal{C}$ będzie klasą prostokątów, których boki są równoległe do osi OX/OY. Klasa $\mathcal{C}$ jest PAC-nauczalna.

Udowodnimy ten fakt pokazując, że dla ustalonego prostokąta $P \in \mathcal{C}$ potrafimy na podstawie odpowiednio dużej próbki przewidywać z dużym prawdopodobieństwem, czy losowo wybrany punkt należy do P czy nie.

Przykład: prostokąty w $\mathbb{R}^2$

Niech $\mathcal{X} = \mathbb{R}^2$ oraz niech $\mathcal{C}$ będzie klasą prostokątów, których boki są równoległe do osi OX/OY. Klasa $\mathcal{C}$ jest PAC-nauczalna.

Udowodnimy ten fakt pokazując, że dla ustalonego prostokąta $P \in \mathcal{C}$ potrafimy na podstawie odpowiednio dużej próbki przewidywać z dużym prawdopodobieństwem, czy losowo wybrany punkt należy do P czy nie.

Ściślej rzecz biorąc, pokażemy, że dla ustalonych $\varepsilon, \delta > 0$ na podstawie próbki S o liczności m spełniającej nierówność


$$m \geq \frac{4}{\varepsilon} \ln \frac{4}{\delta}$$

istnieje algorytm zwracający hipotezę h_S , dla której zachodzi

$$p(R(h_S) \leq \varepsilon) \geq 1 - \delta,$$


czyli prawdopodobieństwo popełnienia błędu większego niż ε jest mniejsze od δ .

Przykład: prostokąty w $\mathbb{R}^2$



Niech $P \in \mathcal{C}$ będzie estymowanym prostokątem.

Przykład: prostokąty w $\mathbb{R}^2$




Niech $P \in \mathcal{C}$ będzie estymowanym prostokątem.

Definiujemy P' jako najmniejszy prostokąt zawierający $S \cap P$.

Ustalamy $\varepsilon > 0$.

Zakładamy, że $R(P') > \varepsilon$.

Przykład: prostokąty w $\mathbb{R}^2$



Niech $P \in \mathcal{C}$ będzie estymowanym prostokątem.


Definiujemy P' jako najmniejszy prostokąt zawierający $S \cap P$.

Ustalamy $\varepsilon > 0$.

Zakładamy, że $R(P') > \varepsilon$.

Wyznaczamy obszary P_1, P_2, P_3, P_4 takie, że $p(P_i) \geq \varepsilon/4$.

Przykład: prostokąty w $\mathbb{R}^2$



Niech $P \in \mathcal{C}$ będzie estymowanym prostokątem.

Definiujemy P' jako najmniejszy prostokąt zawierający $S \cap P$.

Ustalamy $\varepsilon > 0$.

Zakładamy, że $R(P') > \varepsilon$.

Wyznaczamy obszary P_1, P_2, P_3, P_4 takie, że $p(P_i) \geq \varepsilon/4$.

Ponieważ $R(P') > \varepsilon$, to żaden z boków P' nie może w całości należeć do każdego z prostokątów P_i .

Zatem istnieje $i \in \{1, \dots, 4\}$, dla którego $P' \cap P_i = \emptyset$.

Przykład: prostokąty w $\mathbb{R}^2$

Otrzymujemy zatem następujący ciąg nierówności:

$$\begin{aligned} p_{\mathcal{D}^m}(R(P') > \varepsilon) &\leq p_{\mathcal{D}^m}\left(\bigvee_{i=1}^4 (P' \cap P_i = \emptyset)\right) \\ &\leq \sum_{i=1}^4 p_{\mathcal{D}^m}(P' \cap P_i = \emptyset) \\ &\leq 4(1 - \varepsilon/4)^m \\ &\leq 4 \exp(-m\varepsilon/4). \end{aligned}$$

Ustalmy $\delta > 0$. Wtedy dla $m \geq \frac{4}{\varepsilon} \ln \frac{4}{\delta}$ zachodzi

$$p_{\mathcal{D}^m}(R(P') > \varepsilon) \leq 4 \exp(-m\varepsilon/4) \leq \delta.$$

Złożoność próbkowa: skończony zbiór spójnych hipotez

Dla pojęcia $c \in \mathcal{C}$ oraz próbki S hipotezę h_S nazywamy *spójną*, gdy błąd empiryczny h_S jest zerowy, czyli $h_S(x) = c(x)$ dla $x \in S$.

Twierdzenie

Niech $\mathcal{H} \subseteq \mathcal{Y}^{\mathcal{X}}$ będzie skończonym zbiorem hipotez. Niech A będzie algorytmem, który dla pojęcia $c \in \mathcal{H}$ oraz próbki S zwraca spójną hipotezę h_S . Wtedy dla dowolnych $\varepsilon, \delta > 0$ jeżeli liczność m próbki S spełnia

$$m \geq \frac{1}{\varepsilon} \left(\ln |\mathcal{H}| + \ln \frac{1}{\delta} \right),$$

to

$$p_{\mathcal{D}^m}(R(h_S) \leq \varepsilon) \geq 1 - \delta.$$

Równoważnie: dla dowolnych $\varepsilon, \delta > 0$ zachodzi

$$p_{\mathcal{D}^m} \left(R(h_S) \leq \frac{1}{m} \left(\ln |\mathcal{H}| + \ln \frac{1}{\delta} \right) \right) \geq 1 - \delta.$$

Przykład: koniunkcja literałów boolowskich

Dany jest zbiór zmiennych $x_1, \dots, x_n$. Niech klasa pojęć $\mathcal{C}_n$ składa się z koniunkcji co najwyżej n literałów boolowskich $x_1, \dots, x_n$.

Rozważmy $n = 4$ i niech docelowym pojęciem $c \in \mathcal{C}_4$ będzie $x_1 \wedge \bar{x}_2 \wedge x_4$. Wtedy $c(1, 0, 0, 1) = 1$, czyli $(1, 0, 0, 1)$ jest pozytywnym przykładem dla c , natomiast $c(1, 0, 0, 0) = 0$, czyli $(1, 0, 0, 0)$ jest przykładem negatywnym.

Przykłady pozytywne zapewniają sporo informacji: skoro $(1, 0, 0, 1)$ jest pozytywny dla c , to c nie zawiera ani literałów x_2 i x_3 , ani $\bar{x}_1$ i $\bar{x}_4$.

Przykłady negatywne nie dają aż tylu informacji: jeżeli $(1, 0, 0, 0)$ jest negatywnym przykładem, to wiemy tylko, że do c nie należy co najmniej jeden z literałów $\bar{x}_1, x_2, x_3, x_4$ – nie wiemy jednak który.

Przykład: koniunkcja literałów boolowskich

Niech dana będzie próbka S .

Algorytm bazuje na każdym pozytywnym przykładzie $(b_1, \dots, b_n) \in S$:

- jeżeli $b_i = 1$, to odrzucamy literał $\overline{x_i}$,
- jeżeli $b_i = 0$, to odrzucamy literał x_i .

Hipotezę h_S , spójną z docelowym pojęciem c , tworzymy jako koniunkcję wszystkich nieodrzuconych literałów.

W c każda zmienna albo ma wystąpienie pozytywne, albo negatywne, albo nie występuje wcale, zatem $|\mathcal{H}| = |\mathcal{C}_n| = 3^n$.

Przykład: koniunkcja literałów boolowskich

Korzystając z twierdzenia o złożoności próbkowej dla skończonego zbioru spójnych hipotez otrzymujemy dla zadanych $\varepsilon, \delta > 0$ następujące ograniczenie na licznosc próbki:

$$m \geq \frac{1}{\varepsilon} \left(n \ln 3 + \ln \frac{1}{\delta} \right).$$

Wtedy dla próbki S o liczności m mamy $p(R(h_S) \leq \varepsilon) \geq 1 - \delta$.

Na przykład dla $n = 10$ algorytm dla próbki z co najmniej 149 elementami nie popełni błędu większego niż $\varepsilon = 0.1$ z prawdopodobieństwem co najmniej 98% ($\delta = 0.02$).

Nierówność Hoeffdinga

Twierdzenie (Nierówność Hoeffdinga)

Niech $Z_1, \dots, Z_n$ będą niezależnymi zmiennymi losowymi o wartościach w przedziale $[a, b]$.

Wtedy

$$p\left(\frac{1}{n} \sum_{i=1}^n (Z_i - \mathbb{E}Z_i) \geq t\right) \leq \exp\left(-\frac{2nt^2}{(b-a)^2}\right)$$

oraz

$$p\left(\frac{1}{n} \sum_{i=1}^n (Z_i - \mathbb{E}Z_i) \leq -t\right) \leq \exp\left(-\frac{2nt^2}{(b-a)^2}\right)$$

dla każdego $t \geq 0$.

Ograniczenia ryzyka hipotezy

Twierdzenie

Niech $\varepsilon > 0$ oraz niech S będzie próbką rozmiaru m . Wtedy dla dowolnej hipotezy $h: \mathcal{X} \rightarrow \{0, 1\}$ zachodzą poniższe nierówności:

$$\begin{aligned} p_{\mathcal{D}^m}(\widehat{R}(h) - R(h) \geq \varepsilon) &\leq \exp(-2m\varepsilon^2), \\ p_{\mathcal{D}^m}(\widehat{R}(h) - R(h) \leq -\varepsilon) &\leq \exp(-2m\varepsilon^2). \end{aligned}$$

Zatem

$$p_{\mathcal{D}^m}(|\widehat{R}(h) - R(h)| \geq \varepsilon) \leq 2 \exp(-2m\varepsilon^2).$$

Wniosek

Dla dowolnej hipotezy $h: \mathcal{X} \rightarrow \{0, 1\}$ i dla $\delta > 0$ zachodzi

$$p_{\mathcal{D}^m}\left(\widehat{R}(h) \leq R(h) + \sqrt{\frac{1}{2m} \ln \frac{2}{\delta}}\right) \geq 1 - \delta.$$

Student i egzamin raz jeszcze

Założmy, że studenci zdają egzamin z prawdopodobieństwem ϕ . Rozważmy hipotezę $h \equiv 0$, która dla każdego studenta zakłada, że nie zda on egzaminu. Wtedy ryzyko dla hipotezy h wynosi $R(h) = \phi$.

Błąd empiryczny dla h po przeegzaminowaniu pewnej liczby m studentów wynosi $\hat{\phi}$. Wtedy dla $\delta > 0$ zachodzi

$$p\left(|\phi - \hat{\phi}| \leq \sqrt{\frac{1}{2m} \ln \frac{2}{\delta}}\right) \geq 1 - \delta.$$

Jeżeli $\delta = 0.02$ oraz $m = 500$, to z prawdopodobieństwem co najmniej 98% zachodzi

$$|\phi - \hat{\phi}| \leq \sqrt{\frac{\ln 100}{1000}} \approx 0.068.$$

Ograniczenie błędu: skończony zbiór hipotez

Twierdzenie

Niech $\mathcal{H}$ będzie skończonym zbiorem hipotez. Wtedy dla $\delta > 0$ zachodzi

$$p\left(\forall_{h \in \mathcal{H}} R(h) \leq \widehat{R}(h) + \sqrt{\frac{1}{2m} \left(\ln |\mathcal{H}| + \ln \frac{2}{\delta} \right)}\right) \geq 1 - \delta.$$

Dowód.

Niech $h_1, \dots, h_{|\mathcal{H}|}$ będą elementami $\mathcal{H}$. Wtedy

$$\begin{aligned} p\left(\exists_{h \in \mathcal{H}} |\widehat{R}(h) - R(h)| > \varepsilon\right) &\leq \sum_{h \in \mathcal{H}} p(|\widehat{R}(h) - R(h)| > \varepsilon) \\ &\leq 2|\mathcal{H}| \exp(-2m\varepsilon^2). \end{aligned}$$

Podstawienie $\delta = 2|\mathcal{H}| \exp(-2m\varepsilon^2)$ kończy dowód.



Ograniczenie błędu: skończony zbiór hipotez

Twierdzenie

Niech $\mathcal{H}$ będzie skończonym zbiorem hipotez. Wtedy dla $\delta > 0$ zachodzi

$$p\left(\forall_{h \in \mathcal{H}} R(h) \leq \widehat{R}(h) + \sqrt{\frac{1}{2m} \left(\ln |\mathcal{H}| + \ln \frac{2}{\delta} \right)}\right) \geq 1 - \delta.$$

Dowód.

Niech $h_1, \dots, h_{|\mathcal{H}|}$ będą elementami $\mathcal{H}$. Wtedy

$$\begin{aligned} p\left(\exists_{h \in \mathcal{H}} |\widehat{R}(h) - R(h)| > \varepsilon\right) &\leq \sum_{h \in \mathcal{H}} p(|\widehat{R}(h) - R(h)| > \varepsilon) \\ &\leq 2|\mathcal{H}| \exp(-2m\varepsilon^2). \end{aligned}$$

Podstawienie $\delta = 2|\mathcal{H}| \exp(-2m\varepsilon^2)$ kończy dowód. □

Czyli dla $m \geq \frac{1}{2\varepsilon^2} \left(\ln |\mathcal{H}| + \ln \frac{2}{\delta} \right)$ zachodzi $p(|R(h) - \widehat{R}(h)| \geq \varepsilon) \leq \delta$.

Istotne wnioski

Co właściwie oznacza

$$p\left(\forall_{h \in \mathcal{H}} R(h) \leq \widehat{R}(h) + \sqrt{\frac{1}{2m} \left(\ln |\mathcal{H}| + \ln \frac{2}{\delta} \right)}\right) \geq 1 - \delta?$$

Istotne wnioski

Co właściwie oznacza

$$p\left(\forall_{h \in \mathcal{H}} R(h) \leq \widehat{R}(h) + \sqrt{\frac{1}{2m} \left(\ln |\mathcal{H}| + \ln \frac{2}{\delta} \right)}\right) \geq 1 - \delta?$$

- Ryzyko możemy ograniczyć z góry przez sumę błędu empirycznego i pewnej funkcji złożoności zbioru hipotez.

Istotne wnioski

Co właściwie oznacza

$$p\left(\forall_{h \in \mathcal{H}} R(h) \leq \widehat{R}(h) + \sqrt{\frac{1}{2m} \left(\ln |\mathcal{H}| + \ln \frac{2}{\delta} \right)}\right) \geq 1 - \delta?$$

- Ryzyko możemy ograniczyć z góry przez sumę błędu empirycznego i pewnej funkcji złożoności zbioru hipotez.
- Im większy jest zbiór hipotez, tym słabsze jest ograniczenie.

Istotne wnioski

Co właściwie oznacza

$$p\left(\forall_{h \in \mathcal{H}} R(h) \leq \widehat{R}(h) + \sqrt{\frac{1}{2m} \left(\ln |\mathcal{H}| + \ln \frac{2}{\delta} \right)}\right) \geq 1 - \delta?$$

- Ryzyko możemy ograniczyć z góry przez sumę błędu empirycznego i pewnej funkcji złożoności zbioru hipotez.
- Im większy jest zbiór hipotez, tym słabsze jest ograniczenie.
- Gdy rozmiar zbioru hipotez jest odpowiednio mały w stosunku do rozmiaru próbki (czyli $\ln |\mathcal{H}|/2m$ jest małe), to ograniczenie ryzyka jest mocne.

Istotne wnioski

Co właściwie oznacza

$$p\left(\forall_{h \in \mathcal{H}} R(h) \leq \widehat{R}(h) + \sqrt{\frac{1}{2m} \left(\ln |\mathcal{H}| + \ln \frac{2}{\delta} \right)}\right) \geq 1 - \delta?$$

- Ryzyko możemy ograniczyć z góry przez sumę błędu empirycznego i pewnej funkcji złożoności zbioru hipotez.
- Im większy jest zbiór hipotez, tym słabsze jest ograniczenie.
- Gdy rozmiar zbioru hipotez jest odpowiednio mały w stosunku do rozmiaru próbki (czyli $\ln |\mathcal{H}|/2m$ jest małe), to ograniczenie ryzyka jest mocne.
- Ograniczenie jest spełnione z prawdopodobieństwem $1 - \delta$. Jeśli zmniejszymy wartość δ , to ograniczenie będzie słabsze.


Istotne wnioski

Co właściwie oznacza

$$p\left(\forall_{h \in \mathcal{H}} R(h) \leq \widehat{R}(h) + \sqrt{\frac{1}{2m} \left(\ln |\mathcal{H}| + \ln \frac{2}{\delta} \right)}\right) \geq 1 - \delta?$$

- Ryzyko możemy ograniczyć z góry przez sumę błędu empirycznego i pewnej funkcji złożoności zbioru hipotez.
- Im większy jest zbiór hipotez, tym słabsze jest ograniczenie.
- Gdy rozmiar zbioru hipotez jest odpowiednio mały w stosunku do rozmiaru próbki (czyli $\ln |\mathcal{H}|/2m$ jest małe), to ograniczenie ryzyka jest mocne.
- Ograniczenie jest spełnione z prawdopodobieństwem $1 - \delta$. Jeśli zmniejszymy wartość δ , to ograniczenie będzie słabsze.
- Dla ustalonego rozmiaru zbioru hipotez i współczynnika δ ryzyko empiryczne zbiega do ryzyka wraz ze wzrostem liczności próbki. Zbieżność jest rzędu $1/\sqrt{m}$.

Błąd empiryczny, złożoność zbioru hipotez, ryzyko



Funkcja wzrostu

Dla przestrzeni hipotez $\mathcal{H}$ definiujemy *funkcję wzrostu* $\Pi_{\mathcal{H}}: \mathbb{N} \rightarrow \mathbb{N}$ następująco:

$$\Pi_{\mathcal{H}}(m) = \max_{\{x^{(i)}: i=1,\dots,m\} \subseteq \mathcal{X}} \left| \{ (h(x^{(1)}), \dots, h(x^{(m)})) : h \in \mathcal{H} \} \right|.$$

czyli $\Pi_{\mathcal{H}}(m)$ określa maksymalną liczbę możliwych klasyfikacji m punktów za pomocą funkcji ze zbioru $\mathcal{H}$.

Funkcja wzrostu

Dla przestrzeni hipotez $\mathcal{H}$ definiujemy *funkcję wzrostu* $\Pi_{\mathcal{H}}: \mathbb{N} \rightarrow \mathbb{N}$ następująco:

$$\Pi_{\mathcal{H}}(m) = \max_{\{x^{(i)}: i=1,\dots,m\} \subseteq \mathcal{X}} \left| \{ (h(x^{(1)}), \dots, h(x^{(m)})) : h \in \mathcal{H} \} \right|.$$

czyli $\Pi_{\mathcal{H}}(m)$ określa maksymalną liczbę możliwych klasyfikacji m punktów za pomocą funkcji ze zbioru $\mathcal{H}$.

Funkcja wzrostu jest jedną z miar złożoności przestrzeni hipotez $\mathcal{H}$: czysto kombinatoryczną i niezależną od rozkładu danych wejściowych.

Funkcja wzrostu

Dla przestrzeni hipotez $\mathcal{H}$ definiujemy *funkcję wzrostu* $\Pi_{\mathcal{H}}: \mathbb{N} \rightarrow \mathbb{N}$ następująco:

$$\Pi_{\mathcal{H}}(m) = \max_{\{x^{(i)}: i=1,\dots,m\} \subseteq \mathcal{X}} \left| \{ (h(x^{(1)}), \dots, h(x^{(m)})) : h \in \mathcal{H} \} \right|.$$

czyli $\Pi_{\mathcal{H}}(m)$ określa maksymalną liczbę możliwych klasyfikacji m punktów za pomocą funkcji ze zbioru $\mathcal{H}$.

Funkcja wzrostu jest jedną z miar złożoności przestrzeni hipotez $\mathcal{H}$: czysto kombinatoryczną i niezależną od rozkładu danych wejściowych.

Intuicyjnie mówi nam, jak „skuteczny” jest zbiór hipotez, tj. jak wiele etykietowań można za jej pomocą zrealizować.

Funkcja wzrostu i ograniczenie ryzyka

Twierdzenie

Niech $\mathcal{H}$ będzie nieskończonym zbiorem hipotez o wartościach w $\{-1, 1\}$. Wtedy dla $\delta > 0$ zachodzi nierówność

$$p\left(\forall_{h \in \mathcal{H}} |R(h) - \hat{R}(h)| \leq \frac{4 + \sqrt{\ln \Pi_{\mathcal{H}}(2m)}}{\delta \sqrt{2m}}\right) \geq 1 - \delta.$$

Funkcja wzrostu i ograniczenie ryzyka

Twierdzenie

Niech $\mathcal{H}$ będzie nieskończonym zbiorem hipotez o wartościach w $\{-1, 1\}$. Wtedy dla $\delta > 0$ zachodzi nierówność

$$p\left(\forall_{h \in \mathcal{H}} |R(h) - \hat{R}(h)| \leq \frac{4 + \sqrt{\ln \Pi_{\mathcal{H}}(2m)}}{\delta \sqrt{2m}}\right) \geq 1 - \delta.$$

Powyższe ograniczenie jest bardzo podobne do ograniczenia otrzymanego dla skończonego zbioru hipotez. Moc zbioru hipotez została zastąpiona funkcją wzrostu.

Funkcja wzrostu i ograniczenie ryzyka

Twierdzenie

Niech $\mathcal{H}$ będzie nieskończonym zbiorem hipotez o wartościach w $\{-1, 1\}$. Wtedy dla $\delta > 0$ zachodzi nierówność

$$p\left(\forall_{h \in \mathcal{H}} |R(h) - \hat{R}(h)| \leq \frac{4 + \sqrt{\ln \Pi_{\mathcal{H}}(2m)}}{\delta \sqrt{2m}}\right) \geq 1 - \delta.$$

Powyższe ograniczenie jest bardzo podobne do ograniczenia otrzymanego dla skończonego zbioru hipotez. Moc zbioru hipotez została zastąpiona funkcją wzrostu.

Gdy zbiór hipotez jest duży, to możemy znaleźć w nim hipotezę, która bardzo dobrze dopasowuje się do danych. Wówczas ryzyko jest duże i dochodzi do przeuczenia.

Wymiar Wapnika–Czerwonienkisa

Rozważmy przestrzeń hipotez $\mathcal{H} \subseteq \{-1, 1\}^{\mathcal{X}}$.

Zbiór $\mathcal{H}$ *rozbija* niepusty m -elementowy zbiór $S \subseteq \mathcal{X}$, gdy $\Pi_{\mathcal{H}}(m) = 2^m$, czyli gdy przestrzeń $\mathcal{H}$ realizuje wszystkie możliwe klasyfikacje danych wejściowych z próbki S .

Wymiar Wapnika–Czerwonienkisa


Rozważmy przestrzeń hipotez $\mathcal{H} \subseteq \{-1, 1\}^{\mathcal{X}}$.

Zbiór $\mathcal{H}$ *rozbija* niepusty m -elementowy zbiór $S \subseteq \mathcal{X}$, gdy $\Pi_{\mathcal{H}}(m) = 2^m$, czyli gdy przestrzeń $\mathcal{H}$ realizuje wszystkie możliwe klasyfikacje danych wejściowych z próbki S .


Wymiarem Wapnika–Czerwonienkisa $VC(\mathcal{H})$ przestrzeni hipotez $\mathcal{H}$ nazywamy moc największego zbioru, który może być rozbity przez $\mathcal{H}$, czyli

$$VC(\mathcal{H}) = \max\{m: \Pi_{\mathcal{H}}(m) = 2^m\}.$$


Przykład: odcinki na prostej



Przykład: odcinki na prostej




Przykład: odcinki na prostej




$$VC(\{[a, b] \subseteq \mathbb{R} : a < b\}) = 2$$

Przykład: liniowe klasyfikatory w $\mathbb{R}^2$



Niech $\mathcal{H} = \{h: \mathbb{R}^2 \rightarrow \mathbb{R}: h(x_1, x_2) = \mathbf{1}[a + bx_1 + cx_2 > 0]\}$.

Przykład: liniowe klasyfikatory w $\mathbb{R}^2$



Niech $\mathcal{H} = \{h: \mathbb{R}^2 \rightarrow \mathbb{R}: h(x_1, x_2) = \mathbf{1}[a + bx_1 + cx_2 > 0]\}$.

Wtedy $\text{VC}(\mathcal{H}) \geq 3$. Czy zachodzi równość?

Przykład: liniowe klasyfikatory w $\mathbb{R}^d$

Niech

$$\mathcal{H} = \{h: \mathbb{R}^d \rightarrow \mathbb{R}: h(x) = \mathbf{1}[w^T x + b > 0], w \in \mathbb{R}^d, b \in \mathbb{R}\}.$$

Przykład: liniowe klasyfikatory w $\mathbb{R}^d$

Niech

$$\mathcal{H} = \{h: \mathbb{R}^d \rightarrow \mathbb{R}: h(x) = \mathbf{1}[w^T x + b > 0], w \in \mathbb{R}^d, b \in \mathbb{R}\}.$$

Rozważmy $d + 1$ punktów w przestrzeni $\mathbb{R}^d$. Niech $x_0 = (0, \dots, 0)$ oraz niech x_i dla $i = 1, \dots, d$ będą punktami o i -tej współrzędnej równej 1 i zerowych pozostałych współrzędnych.

Przykład: liniowe klasyfikatory w $\mathbb{R}^d$

Niech

$$\mathcal{H} = \{h: \mathbb{R}^d \rightarrow \mathbb{R}: h(x) = \mathbf{1}[w^T x + b > 0], w \in \mathbb{R}^d, b \in \mathbb{R}\}.$$

Rozważmy $d + 1$ punktów w przestrzeni $\mathbb{R}^d$. Niech $x_0 = (0, \dots, 0)$ oraz niech x_i dla $i = 1, \dots, d$ będą punktami o i -tej współrzędnej równej 1 i zerowych pozostałych współrzędnych.

Niech $y_0, y_1, \dots, y_d \in \{-1, 1\}$ będzie dowolnym etykietowaniem $x_0, x_1, \dots, x_d$.

Przykład: liniowe klasyfikatory w $\mathbb{R}^d$

Niech

$$\mathcal{H} = \{h: \mathbb{R}^d \rightarrow \mathbb{R}: h(x) = \mathbf{1}[w^T x + b > 0], w \in \mathbb{R}^d, b \in \mathbb{R}\}.$$

Rozważmy $d + 1$ punktów w przestrzeni $\mathbb{R}^d$. Niech $x_0 = (0, \dots, 0)$ oraz niech x_i dla $i = 1, \dots, d$ będą punktami o i -tej współrzędnej równej 1 i zerowych pozostałych współrzędnych.

Niech $y_0, y_1, \dots, y_d \in \{-1, 1\}$ będzie dowolnym etykietowaniem $x_0, x_1, \dots, x_d$.

Definiujemy wektor $w \in \mathbb{R}^d$ w ten sposób, że $w_i = y_i$.

Przykład: liniowe klasyfikatory w $\mathbb{R}^d$

Niech

$$\mathcal{H} = \{h: \mathbb{R}^d \rightarrow \mathbb{R}: h(x) = \mathbf{1}[w^T x + b > 0], w \in \mathbb{R}^d, b \in \mathbb{R}\}.$$

Rozważmy $d + 1$ punktów w przestrzeni $\mathbb{R}^d$. Niech $x_0 = (0, \dots, 0)$ oraz niech x_i dla $i = 1, \dots, d$ będą punktami o i -tej współrzędnej równej 1 i zerowych pozostałych współrzędnych.

Niech $y_0, y_1, \dots, y_d \in \{-1, 1\}$ będzie dowolnym etykietowaniem $x_0, x_1, \dots, x_d$.

Definiujemy wektor $w \in \mathbb{R}^d$ w ten sposób, że $w_i = y_i$.

Wtedy hiperpłaszczyzna $w^T x + y_0/2 = 0$ separuje punkty $x_0, x_1, \dots, x_d$ ze względu na klasy:

$$\operatorname{sgn}(w^T x + y_0/2) = \operatorname{sgn}(y_i + y_0/2) = y_i.$$

Zatem $\operatorname{VC}(\mathcal{H}) \geq d + 1$.

Przykład: liniowe klasyfikatory w $\mathbb{R}^d$

Twierdzenie Radona

Dowolny zbiór $A \subseteq \mathbb{R}^d$ o $d + 2$ elementach można przedstawić jako sumę dwóch rozłącznych podzbiorów A_1 i A_2 takich, że $\text{Conv}(A_1) \cap \text{Conv}(A_2) \neq \emptyset$.

Przykład: liniowe klasyfikatory w $\mathbb{R}^d$

Twierdzenie Radona

Dowolny zbiór $A \subseteq \mathbb{R}^d$ o $d + 2$ elementach można przedstawić jako sumę dwóch rozłącznych podzbiorów A_1 i A_2 takich, że $\text{Conv}(A_1) \cap \text{Conv}(A_2) \neq \emptyset$.

Niech A , A_1 i A_2 będą zbiorami jak w twierdzeniu.

Oznacza to, że A_1 i A_2 nie dają się rozdzielić hiperpłaszczyzną w $\mathbb{R}^d$, a zatem A nie jest rozbitý przez zbiór $\mathcal{H}$.

Przykład: liniowe klasyfikatory w $\mathbb{R}^d$

Twierdzenie Radona

Dowolny zbiór $A \subseteq \mathbb{R}^d$ o $d + 2$ elementach można przedstawić jako sumę dwóch rozłącznych podzbiorów A_1 i A_2 takich, że $\text{Conv}(A_1) \cap \text{Conv}(A_2) \neq \emptyset$.

Niech A , A_1 i A_2 będą zbiorami jak w twierdzeniu.

Oznacza to, że A_1 i A_2 nie dają się rozdzielić hiperpłaszczyzną w $\mathbb{R}^d$, a zatem A nie jest rozbitý przez zbiór $\mathcal{H}$.

Stąd $\text{VC}(\mathcal{H}) = d + 1$.

Przykład: liniowe klasyfikatory w $\mathbb{R}^d$

Twierdzenie Radona

Dowolny zbiór $A \subseteq \mathbb{R}^d$ o $d + 2$ elementach można przedstawić jako sumę dwóch rozłącznych podzbiorów A_1 i A_2 takich, że $\text{Conv}(A_1) \cap \text{Conv}(A_2) \neq \emptyset$.

Niech A , A_1 i A_2 będą zbiorami jak w twierdzeniu.

Oznacza to, że A_1 i A_2 nie dają się rozdzielić hiperpłaszczyzną w $\mathbb{R}^d$, a zatem A nie jest rozbitý przez zbiór $\mathcal{H}$.

Stąd $\text{VC}(\mathcal{H}) = d + 1$.

Można pokazać, że dla liniowych hipotez $\mathcal{H}$ w $\mathbb{R}^d$ rozdzielaających z marginesem co najmniej $\rho > 0$ dane, które są zawarte w kuli o promieniu $R > 0$, zachodzi

$$\text{VC}(\mathcal{H}) = \min \left\{ d, \frac{2R^2}{\rho^2} \right\} + 1.$$

Wymiar VC a funkcja wzrostu

Lemat Sauera

Niech $\mathcal{H}$ będzie zbiorem hipotez takim, że $\text{VC}(\mathcal{H}) = d$. Wtedy dla dowolnego $m \in \mathbb{N}$ zachodzi nierówność

$$\Pi_{\mathcal{H}}(m) \leq \sum_{i=0}^d \binom{m}{i}.$$

Wymiar VC a funkcja wzrostu

Lemat Sauera

Niech $\mathcal{H}$ będzie zbiorem hipotez takim, że $\text{VC}(\mathcal{H}) = d$. Wtedy dla dowolnego $m \in \mathbb{N}$ zachodzi nierówność

$$\Pi_{\mathcal{H}}(m) \leq \sum_{i=0}^d \binom{m}{i}.$$

Wniosek

Niech $\mathcal{H}$ będzie zbiorem hipotez takim, że $\text{VC}(\mathcal{H}) = d$. Wtedy dla dowolnego $m \geq d$ zachodzi nierówność

$$\Pi_{\mathcal{H}}(m) \leq \left(\frac{em}{d}\right)^d = \mathcal{O}(m^d).$$

Wymiar VC a funkcja wzrostu

Lemat Sauera

Niech $\mathcal{H}$ będzie zbiorem hipotez takim, że $\text{VC}(\mathcal{H}) = d$. Wtedy dla dowolnego $m \in \mathbb{N}$ zachodzi nierówność

$$\Pi_{\mathcal{H}}(m) \leq \sum_{i=0}^d \binom{m}{i}.$$

Wniosek

Niech $\mathcal{H}$ będzie zbiorem hipotez takim, że $\text{VC}(\mathcal{H}) = d$. Wtedy dla dowolnego $m \geq d$ zachodzi nierówność

$$\Pi_{\mathcal{H}}(m) \leq \left(\frac{em}{d}\right)^d = \mathcal{O}(m^d).$$

Wynika stąd, że:

- albo $\text{VC}(\mathcal{H}) = d < \infty$ i wtedy $\Pi_{\mathcal{H}}(m) = \mathcal{O}(m^d)$,
- albo $\text{VC}(\mathcal{H}) = \infty$ i wtedy $\Pi_{\mathcal{H}}(m) = 2^m$.

Wymiar VC i ograniczenie ryzyka

Twierdzenie

Niech $\mathcal{H}$ będzie nieskończonym zbiorem hipotez o wartościach w zbiorze $\{-1, 1\}$ i wymiarze $\text{VC}(\mathcal{H}) = d$. Wtedy dla $\delta > 0$ zachodzi

$$p\left(\forall_{h \in \mathcal{H}} R(h) \leq \widehat{R}(h) + 2\sqrt{\frac{d \ln(2em/d) + \frac{1}{\delta}}{m}}\right) \geq 1 - \delta.$$

Wymiar VC i ograniczenie ryzyka

Twierdzenie

Niech $\mathcal{H}$ będzie nieskończonym zbiorem hipotez o wartościach w zbiorze $\{-1, 1\}$ i wymiarze $VC(\mathcal{H}) = d$. Wtedy dla $\delta > 0$ zachodzi

$$p\left(\forall_{h \in \mathcal{H}} R(h) \leq \widehat{R}(h) + 2\sqrt{\frac{d \ln(2em/d) + \frac{1}{\delta}}{m}}\right) \geq 1 - \delta.$$

Wniosek

Dla dowolnych $\delta, \varepsilon > 0$ gdy próbka S jest liczności m takiej, że

$$m \geq \frac{8d}{(\delta\varepsilon)^2} \ln \frac{2d}{(\delta\varepsilon)^2} + \frac{4d \ln(2e/d)}{(\delta\varepsilon)^2},$$

to zachodzi nierówność

$$p\left(\forall_{h \in \mathcal{H}} |R(h) - \widehat{R}_S(h)| \leq \varepsilon\right) \geq 1 - \delta.$$

Dolne ograniczenie ryzyka (spójna hipoteza)

Twierdzenie

Niech $\mathcal{H}$ będzie przestrzenią hipotez, dla której $VC(\mathcal{H}) = d > 1$. Wtedy dla dowolnego algorytmu uczącego A istnieją rozkład $\mathcal{D}$ na przestrzeni wejściowej $\mathcal{X}$ oraz docelowe pojęcie $c \in \mathcal{H}$ takie, że

$$p_{\mathcal{D}^m} \left(R(h_S) > \frac{d-1}{32m} \right) \geq \frac{1}{100}.$$

Dolne ograniczenie ryzyka (spójna hipoteza)

Twierdzenie

Niech $\mathcal{H}$ będzie przestrzenią hipotez, dla której $VC(\mathcal{H}) = d > 1$. Wtedy dla dowolnego algorytmu uczącego A istnieją rozkład $\mathcal{D}$ na przestrzeni wejściowej $\mathcal{X}$ oraz docelowe pojęcie $c \in \mathcal{H}$ takie, że

$$p_{\mathcal{D}^m} \left(R(h_S) > \frac{d-1}{32m} \right) \geq \frac{1}{100}.$$

Oznacza to, że dla każdego algorytmu istnieją taki rozkład na przestrzeni $\mathcal{X}$ oraz taka funkcja klasyfikująca, że z pewnym dodatnim prawdopodobieństwem ryzyko hipotezy zwróconej przez algorytm jest rzędu $\Omega(d/m)$.

Dolne ograniczenie ryzyka (spójna hipoteza)

Twierdzenie

Niech $\mathcal{H}$ będzie przestrzenią hipotez, dla której $VC(\mathcal{H}) = d > 1$. Wtedy dla dowolnego algorytmu uczącego A istnieją rozkład $\mathcal{D}$ na przestrzeni wejściowej $\mathcal{X}$ oraz docelowe pojęcie $c \in \mathcal{H}$ takie, że

$$p_{\mathcal{D}^m} \left(R(h_S) > \frac{d-1}{32m} \right) \geq \frac{1}{100}.$$

Oznacza to, że dla każdego algorytmu istnieją taki rozkład na przestrzeni $\mathcal{X}$ oraz taka funkcja klasyfikująca, że z pewnym dodatnim prawdopodobieństwem ryzyko hipotezy zwróconej przez algorytm jest rzędu $\Omega(d/m)$.

Co więcej, jeżeli wymiar VC klasy pojęć jest nieskończony, to klasa ta nie jest PAC-nauczalna.

Dolne ograniczenie ryzyka (przypadek ogólny)

Twierdzenie

Niech $\mathcal{H}$ będzie przestrzenią hipotez, dla której $VC(\mathcal{H}) = d > 1$. Wtedy dla dowolnego algorytmu uczącego A istnieje rozkład $\mathcal{D}$ na $\mathcal{X} \times \{0, 1\}$ taki, że

$$p_{\mathcal{D}^m} \left(R(h_S) - \inf_{h \in \mathcal{H}} R(h) > \sqrt{\frac{d}{320m}} \right) \geq \frac{1}{64}.$$