


Metody probabilistyczne w uczeniu maszynowym

Wykład 12: mieszane modele gaussowskie,
algorytm maksymalizacji wartości oczekiwanej


Katarzyna Grygiel

Semestr letni 2025/2026


Mieszany model gaussowski




Mieszany model gaussowski



Mieszany model gaussowski



Mieszany model gaussowski



Gaussowski model mieszany

Model generatywny

Mamy K klastrów i znamy rozkład prawdopodobieństwa w każdym z nich. Wybieramy jeden z klastrów i z niego losujemy punkt.

Gaussowski model mieszany

Model generatywny

Mamy K klastrów i znamy rozkład prawdopodobieństwa w każdym z nich. Wybieramy jeden z klastrów i z niego losujemy punkt.

Gdy rozkłady są normalne, to model jest postaci:

$$p(x|\theta) = \sum_{c=1}^K \pi_c \mathcal{N}(x|\mu_c, \Sigma_c),$$

z parametrem $\theta = (\pi_1, \dots, \pi_K, \mu_1, \dots, \mu_K, \Sigma_1, \dots, \Sigma_K)$.

Gaussowski model mieszany

Model generatywny

Mamy K klastrów i znamy rozkład prawdopodobieństwa w każdym z nich. Wybieramy jeden z klastrów i z niego losujemy punkt.

Gdy rozkłady są normalne, to model jest postaci:

$$p(x|\theta) = \sum_{c=1}^K \pi_c \mathcal{N}(x|\mu_c, \Sigma_c),$$

z parametrem $\theta = (\pi_1, \dots, \pi_K, \mu_1, \dots, \mu_K, \Sigma_1, \dots, \Sigma_K)$.

Jeśli znamy te parametry, to możemy łatwo wyznaczyć łączne prawdopodobieństwo:

$$p(x, z) = p(z)p(x|z) = \pi_z \mathcal{N}(x|\mu_z, \Sigma_z).$$

Gaussowski model mieszany

Model generatywny

Mamy K klastrów i znamy rozkład prawdopodobieństwa w każdym z nich. Wybieramy jeden z klastrów i z niego losujemy punkt.

Gdy rozkłady są normalne, to model jest postaci:

$$p(x|\theta) = \sum_{c=1}^K \pi_c \mathcal{N}(x|\mu_c, \Sigma_c),$$


z parametrem $\theta = (\pi_1, \dots, \pi_K, \mu_1, \dots, \mu_K, \Sigma_1, \dots, \Sigma_K)$.

Jeśli znamy te parametry, to możemy łatwo wyznaczyć łączne prawdopodobieństwo:

$$p(x, z) = p(z)p(x|z) = \pi_z \mathcal{N}(x|\mu_z, \Sigma_z).$$


Co jednak zrobić, jeśli nie wiemy, z którego klastra pochodzi zmienna x ? Przypisanie zmiennej x klastra nazywamy *zmienną ukrytą*.

Przykład: klasteryzacja miękka




Prawdziwy podział danych na klastry

Przykład: klasteryzacja miękka




Dane przed klasteryzacją

Przykład: klasteryzacja miękka



Klasteryzacja miękka po dopasowaniu rozkładów normalnych

Hiperparametry modelu dla GMM i K -średnich



Na niebiesko zaznaczone są wyniki dla danych treningowych, natomiast na pomarańczowo wyniki dla danych walidacyjnych.

Uczenie i wnioskowanie

Na podstawie wejścia x chcemy stwierdzić, z którego klastra z pochodzi.

Możemy wyróżnić dwie fazy:

- uczenie (estymacja parametrów),
- wnioskowanie (przypisanie klastra).

Uczenie i wnioskowanie

Na podstawie wejścia x chcemy stwierdzić, z którego klastra z pochodzi.

Możemy wyróżnić dwie fazy:

- uczenie (estymacja parametrów),
- wnioskowanie (przypisanie klastra).

Gdy znamy parametry, to możemy policzyć prawdopodobieństwo warunkowe

$$p(z|x) = p(x, z)/p(x),$$

a następnie wybrać najbardziej prawdopodobny klaster:

$$z^* = \arg \max_{z \in \{1, \dots, K\}} p(z|x).$$

Wnioskowanie jest proste, znacznie trudniejsza jest faza uczenia.

Modele mieszane

W modelu gaussowskim mamy

$$p(x) = \sum_{z=1}^K \pi_z \mathcal{N}(x | \mu_z, \Sigma_z),$$

gdzie $z \sim \text{Mult}(\pi)$ dla $\pi = (\pi_1, \dots, \pi_K)$ takiego, że $\sum_{z=1}^K \pi_z = 1$.

Zauważmy, że $p(x)$ jest wypukłą kombinacją funkcji gęstości prawdopodobieństwa.

W ogólności *model mieszany* definiujemy jako wypukłą kombinację rozkładów/gęstości.

Modele mieszane

W modelu gaussowskim mamy

$$p(x) = \sum_{z=1}^K \pi_z \mathcal{N}(x | \mu_z, \Sigma_z),$$

gdzie $z \sim \text{Mult}(\pi)$ dla $\pi = (\pi_1, \dots, \pi_K)$ takiego, że $\sum_{z=1}^K \pi_z = 1$.

Zauważmy, że $p(x)$ jest wypukłą kombinacją funkcji gęstości prawdopodobieństwa.

W ogólności *model mieszany* definiujemy jako wypukłą kombinację rozkładów/gęstości.

Powiemy, że zmienna x ma rozkład mieszany, gdy najpierw wybierany jest losowo (według ustalonego rozkładu) jeden z rozkładów, a następnie zgodnie z tym rozkładem wybierany jest punkt.

MLE dla mieszanych modeli gaussowskich

Mamy dane $x^{(1)}, \dots, x^{(m)}$ wybrane z mieszanego modelu gaussowskiego, dla którego

$$p(z = c|\theta) = \pi_c,$$

$$p(x|z = c, \theta) = \mathcal{N}(x|\mu_c, \Sigma_c),$$

MLE dla mieszanych modeli gaussowskich

Mamy dane $x^{(1)}, \dots, x^{(m)}$ wybrane z mieszanego modelu gaussowskiego, dla którego

$$p(z = c|\theta) = \pi_c,$$

$$p(x|z = c, \theta) = \mathcal{N}(x|\mu_c, \Sigma_c),$$

Chcemy estymować parametry:

$$\pi = (\pi_1, \dots, \pi_K),$$

$$\mu = (\mu_1, \dots, \mu_K),$$

$$\Sigma = (\Sigma_1, \dots, \Sigma_K).$$

MLE dla mieszanych modeli gaussowskich

Mamy dane $x^{(1)}, \dots, x^{(m)}$ wybrane z mieszanego modelu gaussowskiego, dla którego

$$\begin{aligned}p(z = c|\theta) &= \pi_c, \\p(x|z = c, \theta) &= \mathcal{N}(x|\mu_c, \Sigma_c),\end{aligned}$$

Chcemy estymować parametry:

$$\begin{aligned}\pi &= (\pi_1, \dots, \pi_K), \\ \mu &= (\mu_1, \dots, \mu_K), \\ \Sigma &= (\Sigma_1, \dots, \Sigma_K).\end{aligned}$$

Funkcja wiarygodności zadana jest przez

$$L(\pi, \mu, \Sigma) = \prod_{i=1}^m \sum_{c=1}^K p(z = c|\theta) \cdot p(x^{(i)}|z = c, \theta).$$

Problemy z MLE dla GMM

Stosując MLE chcielibyśmy zmaksymalizować log-wiarygodność:

$$\ell(\pi, \mu, \Sigma) = \sum_{i=1}^m \ln \left(\sum_{z=1}^K \pi_z \mathcal{N}(x^{(i)} | \mu_z, \Sigma_z) \right).$$

Pojawia się jednak kilka problemów.

Problemy z MLE dla GMM

Stosując MLE chcielibyśmy zmaksymalizować log-wiarygodność:

$$\ell(\pi, \mu, \Sigma) = \sum_{i=1}^m \ln \left(\sum_{z=1}^K \pi_z \mathcal{N}(x^{(i)} | \mu_z, \Sigma_z) \right).$$


Pojawia się jednak kilka problemów.

Pierwszy, który od razu się narzuca, to brak możliwości wejścia z logarytmem pod sumę. Skutek: nie dostaniemy rozwiązania w postaci jawnej.

Problemy z MLE dla GMM

Pojawiają się osobliwości.


Przykład w $\mathbb{R}$: gdy wariancja zbiega do zera, to wiarygodność zbiega do nieskończoności.



Problemy z MLE dla GMM

Pojawiają się osobliwości.

Przykład w $\mathbb{R}$: gdy wariancja zbiega do zera, to wiarygodność zbiega do nieskończoności.



Rozważana funkcja nie jest wypukła. Co więcej, istnieje wiele maksimum lokalnych.

Gdy w punkcie (π, μ, Σ) jest maksimum lokalne, to jest ono również w każdym punkcie utworzonym przez dowolną permutację π , μ i Σ .

Problemy z MLE dla GMM

Problem optymalizacji ma ograniczenia.

Problemy z MLE dla GMM

Problem optymalizacji ma ograniczenia.

- Wartości wektora π nie są dowolne:

$$\forall_{c=1,\dots,K} \pi_c > 0 \quad \text{oraz} \quad \sum_{c=1}^K \pi_c = 1.$$

Problemy z MLE dla GMM

Problem optymalizacji ma ograniczenia.

- Wartości wektora π nie są dowolne:

$$\forall_{c=1,\dots,K} \pi_c > 0 \quad \text{oraz} \quad \sum_{c=1}^K \pi_c = 1.$$

- Wszystkie macierze Σ_c (jako macierze kowariancji) są symetryczne i dodatnio półokreślone.

Problemy z MLE dla GMM

Problem optymalizacji ma ograniczenia.

- Wartości wektora π nie są dowolne:

$$\forall_{c=1,\dots,K} \pi_c > 0 \quad \text{oraz} \quad \sum_{c=1}^K \pi_c = 1.$$

- Wszystkie macierze Σ_c (jako macierze kowariancji) są symetryczne i dodatnio półokreślone.

Możliwe rozwiązanie: każdą macierz symetryczną i dodatnio półokreśloną możemy przedstawić w postaci MM^T dla pewnej macierzy M . Dzięki temu możemy zmienić parametry modelu i zamiast macierzy Σ_c szukać optymalnych macierzy M_c (już bez ograniczeń).

Gdy coś już wiemy, to jest łatwo

Gdy wiemy, z których rozkładów pochodzą dane, to MLE daje nam

$$\pi_c = \frac{\sum_{i=1}^m \mathbf{1}[z^{(i)} = c]}{m}, \quad \mu_c = \frac{\sum_{i=1}^m \mathbf{1}[z^{(i)} = c] x^{(i)}}{\sum_{i=1}^m \mathbf{1}[z^{(i)} = c]},$$

$$\Sigma_c = \frac{\sum_{i=1}^m \mathbf{1}[z^{(i)} = c] (x^{(i)} - \mu_c)^T (x^{(i)} - \mu_c)}{\sum_{i=1}^m \mathbf{1}[z^{(i)} = c]}.$$

Gdy coś już wiemy, to jest łatwo

Gdy wiemy, z których rozkładów pochodzą dane, to MLE daje nam

$$\pi_c = \frac{\sum_{i=1}^m \mathbf{1}[z^{(i)} = c]}{m}, \quad \mu_c = \frac{\sum_{i=1}^m \mathbf{1}[z^{(i)} = c] x^{(i)}}{\sum_{i=1}^m \mathbf{1}[z^{(i)} = c]},$$
$$\Sigma_c = \frac{\sum_{i=1}^m \mathbf{1}[z^{(i)} = c] (x^{(i)} - \mu_c)^T (x^{(i)} - \mu_c)}{\sum_{i=1}^m \mathbf{1}[z^{(i)} = c]}.$$

Natomiast w przypadku klasteryzacji miękkiej jeśli znamy wartości $\gamma_c^{(i)} := p(z^{(i)} = c | x^{(i)}, \theta)$, to

$$\pi_c = \frac{\sum_{i=1}^m \gamma_c^{(i)}}{m}, \quad \mu_c = \frac{\sum_{i=1}^m \gamma_c^{(i)} x^{(i)}}{\sum_{i=1}^m \gamma_c^{(i)}},$$
$$\Sigma_c = \frac{\sum_{i=1}^m \gamma_c^{(i)} (x^{(i)} - \mu_c)^T (x^{(i)} - \mu_c)}{\sum_{i=1}^m \gamma_c^{(i)}}.$$

Gdy coś już wiemy, to jest łatwo

Jak oszacować, z którego klastra pochodzi dana obserwacja, jeśli znamy parametr θ ?

Innymi słowy, jak mając $p(x|z = c, \theta)$ estymować $p(z = c|x, \theta)$?

Gdy coś już wiemy, to jest łatwo

Jak oszacować, z którego klastra pochodzi dana obserwacja, jeśli znamy parametr θ ?

Innymi słowy, jak mając $p(x|z = c, \theta)$ estymować $p(z = c|x, \theta)$?

Korzystamy po prostu ze wzoru Bayesa

$$p(z = c|x, \theta) = \frac{p(x|z = c, \theta)p(z = c|\theta)}{p(x|\theta)}.$$

Wiemy, że $p(x|z = c, \theta) = \mathcal{N}(x|\mu_c, \Sigma_c)$ oraz $p(z = c|\theta) = \pi_c$.

Stała $p(x|\theta)$ jest łatwa do wyznaczenia, wystarczy skorzystać z faktu, że $\sum_{c=1}^K p(z = c|x, \theta) = 1$.

Jajko czy kura? Idea EM dla GMM

- Jeśli znamy parametry rozkładów normalnych, to potrafimy oszacować prawdopodobieństwa źródeł.
- Jeśli znamy źródła, to potrafimy oszacować parametry rozkładów normalnych.

Jajko czy kura? Idea EM dla GMM

- Jeśli znamy parametry rozkładów normalnych, to potrafimy oszacować prawdopodobieństwa źródeł.
- Jeśli znamy źródła, to potrafimy oszacować parametry rozkładów normalnych.

Co było pierwsze: parametr czy źródło?

Jajko czy kura? Idea EM dla GMM

- Jeśli znamy parametry rozkładów normalnych, to potrafimy oszacować prawdopodobieństwa źródeł.
- Jeśli znamy źródła, to potrafimy oszacować parametry rozkładów normalnych.

Co było pierwsze: parametr czy źródło?



Algorytm maksymalizacji wartości oczekiwanej dla GMM

1. Losowo zainicjalizuj wartości parametrów π, μ, Σ .
2. Aż do zbieżności powtarzaj sekwencję:
 - 2.1 krok **E**:
dla każdego punktu $x^{(i)}$ wyznacz $p(z^{(i)} = c | x^{(i)}, \theta)$,
 - 2.2 krok **M**:
uaktualnij wartości parametru π, μ, Σ .

Przykład



Przykład z inną inicjalizacją

Porównywanie rozkładów



Jak porównywać ze sobą dwa rozkłady? Możemy np. badać różnice ich parametrów.

Porównywanie rozkładów



Jak porównywać ze sobą dwa rozkłady? Możemy np. badać różnice ich parametrów.

Lepszym kryterium podobieństwa będzie *dywergencja Kullbacka–Leiblera*.

Dywergencja Kullbacka–Leiblera

Dla dwóch funkcji gęstości prawdopodobieństwa p i q definiujemy dywergencję Kullbacka–Leiblera następująco:

$$\text{KL}(q\|p) = \int q(x) \ln \frac{q(x)}{p(x)} dx$$

(lub $\text{KL}(q\|p) = \sum_x q(x) \ln \frac{q(x)}{p(x)}$ dla rozkładów dyskretnych).

Dywergencja Kullbacka–Leiblera

Dla dwóch funkcji gęstości prawdopodobieństwa p i q definiujemy dywergencję Kullbacka–Leiblera następująco:

$$\text{KL}(q\|p) = \int q(x) \ln \frac{q(x)}{p(x)} dx$$

(lub $\text{KL}(q\|p) = \sum_x q(x) \ln \frac{q(x)}{p(x)}$ dla rozkładów dyskretnych).

Ponieważ $\int q(x) dx = 1$, to na wartość $\text{KL}(q\|p)$ możemy patrzeć jak na wartość oczekiwaną (względem q) różnicy pomiędzy rozkładami q i p w skali logarytmicznej, tzn.

$$\text{KL}(q\|p) = \mathbb{E}_q \left[\ln \frac{q}{p} \right].$$

Własności dywergencji Kullbacka–Leiblera

Dla dowolnych rozkładów p i q zachodzi

$$KL(q\|p) \geq 0,$$

przy czym równość ma miejsce tylko w przypadku $p = q$.

W ogólności dywergencja nie jest symetryczna, tj.

$$KL(p\|q) \neq KL(q\|p),$$

zatem nie jest metryką.

Algorytm maksymalizacji wartości oczekiwanej

Zakładamy, że dane pochodzą z mieszanego modelu o pewnym zestawie parametrów θ :

$$p(x^{(i)}|\theta) = \sum_{c=1}^K p(x^{(i)}|z^{(i)} = c, \theta)p(z^{(i)} = c|\theta).$$

Chcemy teraz znaleźć θ maksymalizującą funkcję wiarygodności $\prod_{i=1}^m p(x^{(i)}|\theta)$, czyli szukamy

$$\arg \max_{\theta} \sum_{i=1}^m \ln \sum_{c=1}^K p(x^{(i)}, z^{(i)} = c|\theta).$$

Idea algorytmu polega na znalezieniu rodziny ograniczeń dolnych powyższej funkcji w ten sposób, aby każde kolejne było lepsze od poprzedniego.

W poszukiwaniu ograniczenia dolnego


$$\begin{aligned}\ln p(X|\theta) &= \sum_{i=1}^m \ln \sum_{c=1}^K p(x^{(i)}, z^{(i)} = c|\theta) \\ &= \sum_{i=1}^m \ln \sum_{c=1}^K \frac{q(z^{(i)} = c)}{q(z^{(i)} = c)} p(x^{(i)}, z^{(i)} = c|\theta) \\ &\geq \sum_{i=1}^m \sum_{c=1}^K q(z^{(i)} = c) \ln \frac{p(x^{(i)}, z^{(i)} = c|\theta)}{q(z^{(i)} = c)} \\ &=: \mathcal{L}(\theta, q).\end{aligned}$$

Nierówność wynika z nierówności Jensena dla funkcji wklęsłych:

$$\ln \left(\sum_{i=1}^s \lambda_i x_i \right) \geq \sum_{i=1}^s \lambda_i \ln x_i, \quad \sum_{i=1}^s \lambda_i = 1.$$

Ograniczenia dolne a poszukiwanie maksimum

Wiemy, że dla dowolnego q zachodzi $\ln p(X|\theta) \geq \mathcal{L}(\theta, q)$. Jakie q wybrać?



Ograniczenia dolne a poszukiwanie maksimum

Wiemy, że dla dowolnego q zachodzi $\ln p(X|\theta) \geq \mathcal{L}(\theta, q)$. Jakie q wybrać?

Założmy, że mamy wybrany pewien punkt θ_k . Z rodziny ograniczeń wybierzmy funkcję $\mathcal{L}(\theta, q)$, która daje największą wartość w punkcie θ_k . W ten sposób wybieramy

$$q_{k+1} = \arg \max_q \mathcal{L}(\theta_k, q). \quad (\text{krok E})$$

Ograniczenia dolne a poszukiwanie maksimum

Wiemy, że dla dowolnego q zachodzi $\ln p(X|\theta) \geq \mathcal{L}(\theta, q)$. Jakie q wybrać?


Założmy, że mamy wybrany pewien punkt θ_k . Z rodziny ograniczeń wybierzmy funkcję $\mathcal{L}(\theta, q)$, która daje największą wartość w punkcie θ_k . W ten sposób wybieramy

$$q_{k+1} = \arg \max_q \mathcal{L}(\theta_k, q). \quad (\text{krok E})$$


Teraz możemy zaktualizować wartość θ tak, aby otrzymać jeszcze lepsze ograniczenie:

$$\theta_{k+1} = \arg \max_{\theta} \mathcal{L}(\theta, q_{k+1}). \quad (\text{krok M})$$


EM na rysunku



EM na rysunku



EM na rysunku



Analiza kroku E

W kroku **E** chcemy wyznaczyć najlepsze ograniczenie dolne $\mathcal{L}(\theta, q)$ funkcji $\ln p(X|\theta)$ w pewnym punkcie θ_k :

$$q_{k+1} = \arg \max_q \mathcal{L}(\theta_k, q). \quad (\text{krok E})$$

Analiza kroku E

W kroku **E** chcemy wyznaczyć najlepsze ograniczenie dolne $\mathcal{L}(\theta, q)$ funkcji $\ln p(X|\theta)$ w pewnym punkcie θ_k :

$$q_{k+1} = \arg \max_q \mathcal{L}(\theta_k, q). \quad (\text{krok E})$$

Zależy nam zatem, aby zminimalizować różnicę

$$\ln p(X|\theta) - \mathcal{L}(\theta, q).$$

Analiza kroku E

W kroku E chcemy wyznaczyć najlepsze ograniczenie dolne $\mathcal{L}(\theta, q)$ funkcji $\ln p(X|\theta)$ w pewnym punkcie θ_k :

$$q_{k+1} = \arg \max_q \mathcal{L}(\theta_k, q). \quad (\text{krok E})$$

Zależy nam zatem, aby zminimalizować różnicę

$$\ln p(X|\theta) - \mathcal{L}(\theta, q).$$

Z własności dywergencji Kullbacka–Leiblera powyższa różnica zeruje się, gdy

$$q(z^{(i)}) = p(z^{(i)}|x^{(i)}, \theta).$$

Analiza kroku E: obliczenia

$$\begin{aligned}\ln p(X|\theta) - \mathcal{L}(\theta, q) &= \sum_{i=1}^m \ln p(x^{(i)}|\theta) - \sum_{i=1}^m \sum_{c=1}^K q(z^{(i)} = c) \ln \frac{p(x^{(i)}, z^{(i)} = c|\theta)}{q(z^{(i)} = c)} \\&= \sum_{i=1}^m \sum_{c=1}^K q(z^{(i)} = c) \left(\ln p(x^{(i)}|\theta) - \ln \frac{p(x^{(i)}, z^{(i)} = c|\theta)}{q(z^{(i)} = c)} \right) \\&= \sum_{i=1}^m \sum_{c=1}^K q(z^{(i)} = c) \ln \frac{p(x^{(i)}|\theta) q(z^{(i)} = c)}{p(x^{(i)}, z^{(i)} = c|\theta)} \\&= \sum_{i=1}^m \sum_{c=1}^K q(z^{(i)} = c) \ln \frac{q(z^{(i)} = c)}{p(z^{(i)} = c|x^{(i)}, \theta)} \\&= \sum_{i=1}^m \text{KL} (q(z^{(i)}) \parallel p(z^{(i)}|x^{(i)}, \theta)).\end{aligned}$$

Analiza kroku **M**

W kroku **M** zależy nam na maksymalizacji funkcji $\mathcal{L}(\theta, q)$ ze względu na θ , czyli chcemy wyznaczyć

$$\theta_{k+1} = \arg \max_{\theta} \mathcal{L}(\theta, q_{k+1}). \quad (\text{krok } \mathbf{M})$$

Ponieważ

$$\mathcal{L}(\theta, q) = \sum_{i=1}^m \sum_{c=1}^K q(z^{(i)} = c) \ln \frac{p(x^{(i)}, z^{(i)} = c | \theta)}{q(z^{(i)} = c)},$$

to wystarczy zmaksymalizować

$$\sum_{i=1}^m \sum_{c=1}^K q(z^{(i)} = c) \ln p(x^{(i)}, z^{(i)} = c | \theta) = \mathbb{E}_q \ln p(X, Z | \theta).$$

Powyższa funkcja najczęściej jest wklęsła, czyli łatwa do optymalizacji.

Algorytm EM w ogólności

Algorytm maksymalizacji wartości oczekiwanej

Losowo zainicjalizuj wartości parametru θ_0 ;

$k \leftarrow 0$;

while *warunek zbieżności* **do**

 krok **E**

$$q_{k+1}(z^{(i)}) \leftarrow p(z^{(i)} | x^{(i)}, \theta_k);$$

 krok **M**

$$\theta_{k+1} \leftarrow \arg \max_{\theta} \mathbb{E}_{q_{k+1}} \ln p(X, Z | \theta);$$

$k \leftarrow k + 1$;

end

Ale czy to na pewno działa?

Po żadnej iteracji algorytmu wartość funkcji log-wiarygodności nie zmniejsza się:

$$\begin{aligned}\ln p(X|\theta_{k+1}) &\geq \mathcal{L}(\theta_{k+1}, q_{k+1}) \\ &\geq \mathcal{L}(\theta_k, q_{k+1}) = \ln p(X|\theta_k).\end{aligned}$$

Ale czy to na pewno działa?

Po żadnej iteracji algorytmu wartość funkcji log-wiarygodności nie zmniejsza się:

$$\begin{aligned}\ln p(X|\theta_{k+1}) &\geq \mathcal{L}(\theta_{k+1}, q_{k+1}) \\ &\geq \mathcal{L}(\theta_k, q_{k+1}) = \ln p(X|\theta_k).\end{aligned}$$

Twierdzenie (Vaida 2005)

Przy pewnych technicznych założeniach dla dowolnego punktu startowego θ_0 :

- *ciąg $(\theta_k)_{k \geq 0}$ zbiega do punktu stacjonarnego θ^* (czyli $\nabla_{\theta} \ln p(X|\theta) = 0$),*
- *θ^* jest punktem stałym algorytmu EM,*
- *ciąg $(\ln p(X|\theta_k))_{k \geq 0}$ jest silnie rosnący (o ile $\theta_k \neq \theta^*$).*

Przykład działania

Zaobserwowane dane o możliwych wartościach 1, 2, 3 podlegają rozkładowi mieszanemu

$$p(x^{(i)}|\alpha, \beta) = \gamma \cdot p_1(x^{(i)}|\alpha, \beta) + (1 - \gamma) \cdot p_2(x^{(i)}|\alpha, \beta),$$

dla którego rozkłady p_1 i p_2 , określające, z którego z klastrów pochodzą dane, zadane są następująco:

	1	2	3
p_1	α	$1 - \alpha$	0
p_2	0	$1 - \beta$	β

Przykład działania

Zaobserwowane dane o możliwych wartościach 1, 2, 3 podlegają rozkładowi mieszanemu

$$p(x^{(i)}|\alpha, \beta) = \gamma \cdot p_1(x^{(i)}|\alpha, \beta) + (1 - \gamma) \cdot p_2(x^{(i)}|\alpha, \beta),$$

dla którego rozkłady p_1 i p_2 , określające, z którego z klastrów pochodzą dane, zadane są następująco:

	1	2	3
p_1	α	$1 - \alpha$	0
p_2	0	$1 - \beta$	β

Wprowadzamy zmienną ukrytą z opisującą, z którego rozkładu wybrane są dane:

$$p(z = 1) = \gamma \quad \text{oraz} \quad p(z = 2) = 1 - \gamma.$$

Ustalmy na początku $\alpha_0 = \beta_0 = \gamma_0 = 1/2$.

Przykład działania: krok E

Zgodnie z algorytmem definiujemy

$$q(z^{(i)} = c) = p(z^{(i)} = c | x^{(i)}).$$

Dla $c = 1$ mamy

$$p(z^{(i)} = 1 | x^{(i)} = 1) = \frac{\alpha\gamma}{\alpha\gamma + 0 \cdot (1 - \gamma)} = 1,$$

$$p(z^{(i)} = 1 | x^{(i)} = 2) = \frac{(1 - \alpha)\gamma}{(1 - \alpha)\gamma + (1 - \beta)(1 - \gamma)} = 1/2,$$

$$p(z^{(i)} = 1 | x^{(i)} = 3) = 0.$$

Natomiast dla $c = 2$ otrzymujemy od razu

$$q(z^{(i)} = 2) = p(z^{(i)} = 2 | x^{(i)} = j) = 1 - p(z^{(i)} = 1 | x^{(i)} = j).$$

Przykład działania: krok **M**

(Zaobserwowaliśmy 30 razy $x = 1$, 20 razy $x = 2$ i 60 razy $x = 3$).

W kroku **M** chcemy znaleźć wartości parametrów α, β, γ maksymalizujące funkcję

$$\begin{aligned}\sum_{i=1}^m \mathbb{E}_q \ln p(x^{(i)}|z^{(i)})p(z^{(i)}) &= \sum_{i=1}^m q(z^{(i)} = 1) \ln \gamma p(x^{(i)}|z^{(i)} = 1) \\ &\quad + \sum_{i=1}^m q(z^{(i)} = 2) \ln(1 - \gamma) p(x^{(i)}|z^{(i)} = 2) \\ &= 30 \ln \gamma \alpha + 10 \ln \gamma (1 - \alpha) + 10 \ln(1 - \gamma) (1 - \beta) + 60 \ln(1 - \gamma) \beta.\end{aligned}$$

Licząc pochodne cząstkowe, dostajemy

$$\alpha = 3/4, \quad \beta = 6/7, \quad \gamma = 4/11.$$

Algorytm EM dla GMM raz jeszcze

Krok E:

- dla mieszanego modelu gaussowskiego

$$\gamma_c^{(i)} = p(z^{(i)} = c | x^{(i)}, \theta),$$

- dla ogólnej wersji EM

$$q(z^{(i)}) = p(z^{(i)} | x^{(i)}, \theta).$$

Algorytm EM dla GMM raz jeszcze

Krok **E**:

- dla mieszanego modelu gaussowskiego

$$\gamma_c^{(i)} = p(z^{(i)} = c | x^{(i)}, \theta),$$

- dla ogólnej wersji EM

$$q(z^{(i)}) = p(z^{(i)} | x^{(i)}, \theta).$$

Krok **M**:

- dla mieszanego modelu gaussowskiego

$$\mu_c = \frac{\sum_{i=1}^m \gamma_c^{(i)} x^{(i)}}{\sum_{i=1}^m \gamma_c^{(i)}}, \quad \Sigma_c = \dots, \quad \pi_c = \dots$$

- dla ogólnej wersji EM

$$\theta = \arg \max_{\theta} \mathbb{E}_q \ln p(X, Z | \theta).$$

Czy kroki **M** są sobie równoważne?

Zacznijmy od

$$\theta = \arg \max_{\theta} \mathbb{E}_q \ln p(X, Z|\theta).$$

Wartość oczekiwaną możemy zapisać następująco:

$$\sum_{i=1}^m \sum_{c=1}^K q(z^{(i)} = c) \ln \left(\frac{\pi_c}{C} \exp \left(-\frac{1}{2} (x^{(i)} - \mu_c) \Sigma_c^{-1} (x^{(i)} - \mu_c) \right) \right)$$

Licząc pochodne cząstkowe i przyrównując do zera dostajemy oczekiwane wyniki:

$$\pi_c = \frac{\sum_{i=1}^m \gamma_c^{(i)}}{m}, \quad \mu_c = \frac{\sum_{i=1}^m \gamma_c^{(i)} x^{(i)}}{\sum_{i=1}^m \gamma_c^{(i)}},$$

$$\Sigma_c = \frac{\sum_{i=1}^m \gamma_c^{(i)} (x^{(i)} - \mu_c)^T (x^{(i)} - \mu_c)}{\sum_{i=1}^m \gamma_c^{(i)}}.$$

Algorytm k -średnich jako szczególny przypadek EM

Algorytm k -średnich

1. Zainicjalizuj losowo początkowe centroidy $\theta = (\mu_1, \dots, \mu_K)$.
2. Powtarzaj do zbieżności:
 - 2.1 dla każdego punktu znajdź najbliższy centroid

$$z^{(i)} = \arg \min_{c \in \{1, \dots, K\}} d(x^{(i)}, \mu_c),$$

- 2.2 uaktualnij wartości centroidów

$$\mu_c = \frac{\sum_{i=1}^m \mathbf{1}[z^{(i)} = c] x^{(i)}}{\sum_{i=1}^m \mathbf{1}[z^{(i)} = c]}.$$

Algorytm k -średnich jako szczególny przypadek EM

Algorytm k -średnich

1. Zainicjalizuj losowo początkowe centroidy $\theta = (\mu_1, \dots, \mu_K)$.
2. Powtarzaj do zbieżności:
 - 2.1 dla każdego punktu znajdź najbliższy centroid

$$z^{(i)} = \arg \min_{c \in \{1, \dots, K\}} d(x^{(i)}, \mu_c),$$

- 2.2 uaktualnij wartości centroidów

$$\mu_c = \frac{\sum_{i=1}^m \mathbf{1}[z^{(i)} = c] x^{(i)}}{\sum_{i=1}^m \mathbf{1}[z^{(i)} = c]}.$$

Z punktu widzenia GMM:

- macierze kowariancji są jednostkowe: $\Sigma_c = \mathbf{I}$,
- wartości wag π_c są takie same: $\pi_c = 1/K$.

Algorytm k -średnich jako szczególny przypadek EM

Krok **E**:

$$q_{k+1} = \arg \min_{q \in \Delta} \text{KL} \left(q(Z) \| p(Z|X, \theta_{k+1}) \right),$$

Algorytm k -średnich jako szczególny przypadek EM

Krok **E**:

$$q_{k+1} = \arg \min_{q \in \Delta} \text{KL} \left(q(Z) \| p(Z|X, \theta_{k+1}) \right),$$

gdzie Δ jest zbiorem funkcji

$$\delta_c(z) = \mathbf{1}[z = c].$$

Algorytm k -średnich jako szczególny przypadek EM

Krok E:

$$q_{k+1} = \arg \min_{q \in \Delta} \text{KL} \left(q(Z) \| p(Z|X, \theta_{k+1}) \right),$$

gdzie Δ jest zbiorem funkcji

$$\delta_c(z) = \mathbf{1}[z = c].$$

Stąd dostajemy

$$q_{k+1}(z^{(i)}) = \mathbf{1} \left[z^{(i)} = \arg \max_{c \in \{1, \dots, K\}} p(z^{(i)} = c | x^{(i)}, \theta) \right],$$

przy czym

$$p(z^{(i)} | x^{(i)}, \theta) = \frac{1}{C} p(x^{(i)} | z^{(i)}, \theta) p(z^{(i)} | \theta) = \frac{\pi_c}{C} \exp \left(-\frac{1}{2} d(x^{(i)}, \mu_c)^2 \right).$$

Algorytm k -średnich jako szczególny przypadek EM

Krok E:

$$q_{k+1} = \arg \min_{q \in \Delta} \text{KL} (q(Z) \| p(Z|X, \theta_{k+1})),$$

gdzie Δ jest zbiorem funkcji

$$\delta_c(z) = \mathbf{1}[z = c].$$

Stąd dostajemy

$$q_{k+1}(z^{(i)}) = \mathbf{1} \left[z^{(i)} = \arg \max_{c \in \{1, \dots, K\}} p(z^{(i)} = c | x^{(i)}, \theta) \right],$$

przy czym

$$p(z^{(i)} | x^{(i)}, \theta) = \frac{1}{C} p(x^{(i)} | z^{(i)}, \theta) p(z^{(i)} | \theta) = \frac{\pi_c}{C} \exp \left(-\frac{1}{2} d(x^{(i)}, \mu_c)^2 \right).$$

Ostatecznie dla $x^{(i)}$ wybieramy $c_*^{(i)} = \arg \min_c d(x^{(i)}, \mu_c)$.

Algorytm k -średnich jako szczególny przypadek EM

Krok **M**:

$$\arg \max_{\mu} \sum_{i=1}^m \mathbb{E}_q \ln p(x^{(i)}, z^{(i)} | \mu).$$

W GMM otrzymujemy

$$\mu_c = \frac{\sum_{i=1}^m q(z^{(i)} = c) x^{(i)}}{\sum_{i=1}^m q(z^{(i)} = c)}.$$

Algorytm k -średnich jako szczególny przypadek EM

Krok **M**:

$$\arg \max_{\mu} \sum_{i=1}^m \mathbb{E}_q \ln p(x^{(i)}, z^{(i)} | \mu).$$

W GMM otrzymujemy

$$\mu_c = \frac{\sum_{i=1}^m q(z^{(i)} = c) x^{(i)}}{\sum_{i=1}^m q(z^{(i)} = c)}.$$

Ponieważ ograniczyliśmy się do zbioru funkcji Δ , otrzymujemy

$$\mu_c = \frac{\sum_{i=1}^m \mathbf{1}[z^{(i)} = c_*^{(i)}] x^{(i)}}{\sum_{i=1}^m \mathbf{1}[z^{(i)} = c_*^{(i)}]}.$$

Podsumowanie EM

Zalety:

- wartość funkcji wiarygodności rośnie w każdej iteracji,
- zazwyczaj działa szybko,
- w przeciwieństwie do metod gradientowych nie wymaga doboru długości kroku.

Wady:

- nie daje gwarancji otrzymania globalnego maksimum,
- istotnie zależy od wartości zainicjalizowanych parametrów.