

# Metody probabilistyczne w uczeniu maszynowym

Wykład 13: rozkład według wartości osobliwych (SVD),  
analiza składowych głównych (PCA), jądrowa wersja PCA

Katarzyna Grygiel


Semestr letni 2025/2026

# Kompresja danych

Zarówno w przypadku uczenia nadzorowanego, jak i bez nadzoru zdarza się, że dane, z którymi pracujemy, mają bardzo wiele cech.

W takiej sytuacji można (a czasami nawet trzeba) dokonać kompresji:

$$\mathbb{R}^d \ni x^{(i)} \mapsto z^{(i)} \in \mathbb{R}^\ell, \quad \ell < d.$$




Dzięki temu nie tylko wymagania pamięciowe są mniejsze, ale również opracowywane algorytmy działają szybciej.

# Kompresja danych

Zarówno w przypadku uczenia nadzorowanego, jak i bez nadzoru zdarza się, że dane, z którymi pracujemy, mają bardzo wiele cech.

W takiej sytuacji można (a czasami nawet trzeba) dokonać kompresji:

$$\mathbb{R}^d \ni x^{(i)} \mapsto z^{(i)} \in \mathbb{R}^\ell, \quad \ell < d.$$




Dzięki temu nie tylko wymagania pamięciowe są mniejsze, ale również opracowywane algorytmy działają szybciej.

Oczywiście zależy nam na takiej kompresji, po zastosowaniu której tracimy jak najmniej informacji.

# Wizualizacja danych


| Kraj     | PKB    | PKB per capita | Wskaźnik rozwoju | Średnia dł. życia | Wskaźnik ubóstwa | Średni dochód | ... |
|----------|--------|----------------|------------------|-------------------|------------------|---------------|-----|
| Kanada   | 1.577  | 39.17          | 0.908            | 80.7              | 32.6             | 67.293        | ... |
| Chiny    | 5.878  | 7.54           | 0.687            | 73                | 46.9             | 10.22         | ... |
| Indie    | 1.632  | 3.41           | 0.547            | 64.7              | 36.8             | 0.735         | ... |
| Rosja    | 1.48   | 19.84          | 0.755            | 65.5              | 39.9             | 0.72          | ... |
| Singapur | 0.223  | 56.69          | 0.866            | 80                | 42.5             | 67.1          | ... |
| USA      | 14.527 | 46.86          | 0.91             | 78.3              | 40.8             | 84.3          | ... |



## Działanie macierzy na wektorze

Niech  $A = \begin{bmatrix} 2 & 1 \\ -2 & 3 \end{bmatrix}$  oraz  $v = \begin{bmatrix} 1 \\ 1 \end{bmatrix}$ .

Wtedy  $Av = \begin{bmatrix} 3 \\ 1 \end{bmatrix}$ .




## Działanie macierzy na wektorze

Niech  $A = \begin{bmatrix} 2 & 1 \\ -2 & 3 \end{bmatrix}$  oraz  $v = \begin{bmatrix} 1 \\ 1 \end{bmatrix}$ .

Wtedy  $Av = \begin{bmatrix} 3 \\ 1 \end{bmatrix}$ .

Działanie macierzy  $A$  na wektor  $v$  możemy rozłożyć na dwa etapy


- obrót o pewien kąt  $\varphi$ ,
- przeskalowanie obróconego wektora.



## Działanie macierzy na wektorze

Niech  $A = \begin{bmatrix} 2 & 1 \\ -2 & 3 \end{bmatrix}$  oraz  $v = \begin{bmatrix} 1 \\ 1 \end{bmatrix}$ .

Wtedy  $Av = \begin{bmatrix} 3 \\ 1 \end{bmatrix}$ .



Działanie macierzy  $A$  na wektor  $v$  możemy rozłożyć na dwa etapy

- obrót o pewien kąt  $\varphi$ ,
- przeskalowanie obróconego wektora.

Macierz obrotu o kąt  $\varphi$  ma postać

$$\begin{bmatrix} \cos \varphi & -\sin \varphi \\ \sin \varphi & \cos \varphi \end{bmatrix}.$$

Przeskalowanie o czynnik  $\alpha$  można wykonać przy pomocy macierzy diagonalnej

$$\begin{bmatrix} \alpha & 0 \\ 0 & \alpha \end{bmatrix}.$$

## Sfera przechodzi w elipsę

Obrazem okręgu przez macierz o wymiarach  $2 \times 2$  jest elipsa.



## Sfera przechodzi w elipsę

Obrazem okręgu przez macierz o wymiarach  $2 \times 2$  jest elipsa. Niech  $A = \begin{bmatrix} 2 & -1 \\ 2 & 2 \end{bmatrix}$ .

Na sferze istnieją dwa prostopadłe do siebie wektory długości 1:

$$v_1 = \frac{1}{\sqrt{5}} \begin{bmatrix} 1 \\ 2 \end{bmatrix} \quad \text{oraz} \quad v_2 = \frac{1}{\sqrt{5}} \begin{bmatrix} -2 \\ 1 \end{bmatrix}$$

takie, że  $Av_1$  oraz  $Av_2$  są do siebie prostopadłe.

## Sfera przechodzi w elipsę

Obrazem okręgu przez macierz o wymiarach  $2 \times 2$  jest elipsa. Niech  $A = \begin{bmatrix} 2 & -1 \\ 2 & 2 \end{bmatrix}$ .


Na sferze istnieją dwa prostopadłe do siebie wektory długości 1:

$$v_1 = \frac{1}{\sqrt{5}} \begin{bmatrix} 1 \\ 2 \end{bmatrix} \quad \text{oraz} \quad v_2 = \frac{1}{\sqrt{5}} \begin{bmatrix} -2 \\ 1 \end{bmatrix}$$

takie, że  $Av_1$  oraz  $Av_2$  są do siebie prostopadłe. Możemy zapisać, że

$$Av_1 = \sigma_1 u_1, \quad Av_2 = \sigma_2 u_2,$$

gdzie  $\sigma_1, \sigma_2 > 0$  oraz  $u_1, u_2$  są wektorami jednostkowymi prostopadłymi do siebie.



## Dowolny wymiar

Niech teraz  $A$  będzie macierzą o wymiarach  $m \times n$ . Dla wygody załóżmy, że  $m \geq n$ . Jako odwzorowanie liniowe prowadzi ono z  $\mathbb{R}^n$  w  $\mathbb{R}^m$ , a obrazem sfery w  $\mathbb{R}^n$  jest wielowymiarowa elipsa w  $\mathbb{R}^m$ .

## Dowolny wymiar

Niech teraz  $A$  będzie macierzą o wymiarach  $m \times n$ . Dla wygody załóżmy, że  $m \geq n$ . Jako odwzorowanie liniowe prowadzi ono z  $\mathbb{R}^n$  w  $\mathbb{R}^m$ , a obrazem sfery w  $\mathbb{R}^n$  jest wielowymiarowa elipsa w  $\mathbb{R}^m$ .

Szukamy:

- wektorów ortonormalnych

$$v_1, \dots, v_n \in \mathbb{R}^n,$$

- wektorów ortonormalnych

$$u_1, \dots, u_m \in \mathbb{R}^m,$$

- wartości osobliwych

$$\sigma_1, \dots, \sigma_m \in \mathbb{R}_{\geq 0}$$

takich, że

$$Av_j = \sigma_j u_j, \quad j \in \{1, \dots, n\}.$$

## Postać macierzowa

Powyższe równania przypominają równania dla wartości własnych macierzy. Możemy zapisać je w postaci macierzowej:

$$A \begin{bmatrix} v_1 & \dots & v_n \end{bmatrix} = \begin{bmatrix} u_1 & \dots & u_n \end{bmatrix} \begin{bmatrix} \sigma_1 & \dots & 0 \\ 0 & \ddots & 0 \\ 0 & \dots & \sigma_n \end{bmatrix}.$$

## Postać macierzowa

Powyższe równania przypominają równania dla wartości własnych macierzy. Możemy zapisać je w postaci macierzowej:

$$A \begin{bmatrix} v_1 & \dots & v_n \end{bmatrix} = \begin{bmatrix} u_1 & \dots & u_n \end{bmatrix} \begin{bmatrix} \sigma_1 & \dots & 0 \\ 0 & \ddots & 0 \\ 0 & \dots & \sigma_n \end{bmatrix}.$$

Wprowadzamy następujące oznaczenia:

- $V$  – macierz  $n \times n$  złożona z wektorów  $v_i$ ,
- $\hat{U}$  – macierz  $m \times n$  złożoną z wektorów  $u_i$ ,
- $\hat{\Sigma}$  – macierz wartości osobliwych  $\sigma_i$ .

## Prostsza postać macierzowa

Nasze równanie ma postać

$$AV = \hat{U}\hat{\Sigma}.$$

Macierz  $V$  składa się z ortonormalnych kolumn. Wynika z tego, że jest to macierz unitarna, czyli spełniająca równość

$$VV^T = V^T V = \mathbf{I}_{n \times n}.$$

Macierz kwadratowa  $V$  jest unitarna wtedy i tylko wtedy, gdy spełnione są dwa warunki:

- $V$  jest izometrią, tzn.  $\|Vx\| = \|x\|$  dla dowolnego  $x$ ,
- $V$  jest suriekcją, czyli  $\det V \neq 0$ .

Macierzą odwrotną do rzeczywistej macierzy unitarnej jest macierz do niej transponowana. Stąd otrzymujemy równość

$$A = \hat{U}\hat{\Sigma}V^T.$$

## Rozszerzenie macierzy

Zredukowany rozkład na wartości osobliwe ma postać:

$$\begin{matrix} m \\ \left[ \begin{array}{c} A \end{array} \right] \\ n \end{matrix} = \begin{matrix} \left[ \begin{array}{c} \hat{U} \end{array} \right] \end{matrix} \begin{matrix} \left[ \begin{array}{c} \hat{\Sigma} \end{array} \right] \end{matrix} \begin{matrix} \left[ \begin{array}{c} V^T \end{array} \right] \end{matrix}$$

Zawsze możemy:

- rozszerzyć  $\hat{U}$  do unitarnej macierzy  $U$  o wymiarach  $m \times m$ ,
- uzupełnić  $\hat{\Sigma}$  zerami do macierzy o wymiarach  $m \times n$  w ten sposób, aby spełniona była równość

$$\begin{matrix} m \\ \left[ \begin{array}{c} A \end{array} \right] \\ n \end{matrix} = \begin{matrix} \left[ \begin{array}{c} U \end{array} \right] \end{matrix} \begin{matrix} \left[ \begin{array}{c} \Sigma \end{array} \right] \end{matrix} \begin{matrix} \left[ \begin{array}{c} V^T \end{array} \right] \end{matrix}$$

Powyższy rozkład nazywamy *rozkładem na wartości osobliwe* (SVD).



# Twierdzenie o SVD

## Twierdzenie

*Dla każdej macierzy  $A \in M_{m \times n}$  istnieje jej rozkład  $A = U\Sigma V^T$  na wartości osobliwe. Ponadto:*

- *wartości osobliwe  $\sigma_1, \dots, \sigma_n$  są nieujemne i są wyznaczone jednoznacznie,*
- *możemy uszeregować wartości osobliwe w ciągu malejącym, czyli  $\sigma_1 \geq \dots \geq \sigma_n$ ,*
- *jeśli macierz  $A$  jest kwadratowa oraz wartości osobliwe są parami różne, to każdy z wektorów  $u_1, \dots, u_n$  oraz  $v_1, \dots, v_n$  jest wyznaczony jednoznacznie z dokładnością do znaku.*

## Jak wyznaczyć macierze $U$ , $\Sigma$ i $V$ ?

Jeśli rozłożymy macierz  $A \in M_{m \times n}$  na wartości osobliwe, to

$$A^T A = (U \Sigma V^T)^T U \Sigma V^T = V \Sigma^T U^T U \Sigma V^T = V \Sigma^T \Sigma V^T.$$

Spełniona jest więc równość

$$A^T A V = V \Sigma^T \Sigma.$$

W szczególności dla każdego  $i = 1, \dots, n$  zachodzi

$$A^T A v_i = \sigma_i^2 v_i.$$

Oznacza to, że każda z kolumn macierzy  $V$  jest wektorem własnym macierzy  $A^T A$ . Analogicznie możemy znaleźć macierz  $U$ . Mamy

$$A A^T = U \Sigma V^T (U \Sigma V^T)^T = U \Sigma V^T V \Sigma^T U^T = U \Sigma \Sigma^T U^T,$$

zatem kolumny macierzy  $U$  są wektorami własnymi macierzy  $A A^T$ .

## Przykład: rozkład SVD

Macierz

$$A = \begin{bmatrix} 1 & 1 & 0 \\ 0 & 1 & 1 \\ 0 & 0 & 4 \end{bmatrix}$$

ma następujący rozkład na wartości osobliwe:

$$U = \begin{bmatrix} 0.0170987 & -0.860139 & 0.509772 \\ 0.257621 & -0.488842 & -0.833466 \\ 0.966095 & 0.145579 & 0.213231 \end{bmatrix}$$

$$\Sigma = \begin{bmatrix} 4.13118 & 0 & 0 \\ 0 & 1.6026 & 0 \\ 0 & 0 & 0.604172 \end{bmatrix}$$

$$V = \begin{bmatrix} 0.00413895 & -0.536715 & 0.843754 \\ 0.066499 & -0.841745 & -0.535764 \\ 0.997778 & 0.0583263 & 0.0322071 \end{bmatrix}$$

## Przykład: brak diagonalizacji

Macierzy  $A$  nie można zdiagonalizować za pomocą macierzy unitarnej  $U$ , czyli przedstawić w postaci  $UDU^{-1}$  dla pewnej diagonalnej macierzy  $D$ .

Warunkiem równoważnym na taką diagonalizację jest równość  $AA^T = A^T A$ , jednak w przypadku macierzy  $A$  mamy

$$AA^T = \begin{bmatrix} 2 & 1 & 0 \\ 1 & 2 & 4 \\ 0 & 4 & 16 \end{bmatrix} \quad \text{oraz} \quad A^T A = \begin{bmatrix} 1 & 1 & 0 \\ 1 & 2 & 1 \\ 0 & 1 & 17 \end{bmatrix}.$$

## Przykład: brak diagonalizacji

Macierzy  $A$  nie można zdiagonalizować za pomocą macierzy unitarnej  $U$ , czyli przedstawić w postaci  $UDU^{-1}$  dla pewnej diagonalnej macierzy  $D$ .


Warunkiem równoważnym na taką diagonalizację jest równość  $AA^T = A^T A$ , jednak w przypadku macierzy  $A$  mamy

$$AA^T = \begin{bmatrix} 2 & 1 & 0 \\ 1 & 2 & 4 \\ 0 & 4 & 16 \end{bmatrix} \quad \text{oraz} \quad A^T A = \begin{bmatrix} 1 & 1 & 0 \\ 1 & 2 & 1 \\ 0 & 1 & 17 \end{bmatrix}.$$

Co więcej, macierz  $A$  ma tylko dwa liniowo niezależne wektory własne,  $[1, 0, 0]^T$  i  $[1, 3, 9]^T$ , zatem nie da się jej w ogóle zdiagonalizować (czyli przedstawić w postaci  $PDP^{-1}$  dla diagonalnej macierzy  $D$ ).


## Analiza składowych głównych (PCA)

Średnia z czerwonych punktów wypada w początku układu współrzędnych. Szukamy takiej prostej, aby suma kwadratów długości rzutów punktów na tę prostą była jak najmniejsza.




## Analiza składowych głównych (PCA)

Średnia z czerwonych punktów wypada w początku układu współrzędnych. Szukamy takiej prostej, aby suma kwadratów długości rzutów punktów na tę prostą była jak najmniejsza.



## Analiza składowych głównych (PCA)

Średnia z czerwonych punktów wypada w początku układu współrzędnych. Szukamy takiej prostej, aby suma kwadratów długości rzutów punktów na tę prostą była jak najmniejsza.





## Równoważne warunki


Minimalizacja sumy kwadratów odległości punktów od prostej jest równoważna maksymalizacji sumy kwadratów odległości rzutów punktów od początku układu współrzędnych.

Interesuje nas zatem *maksymalizacja wariancji*.

## Równoważne warunki

Minimalizacja sumy kwadratów odległości punktów od prostej jest równoważna maksymalizacji sumy kwadratów odległości rzutów punktów od początku układu współrzędnych.

Interesuje nas zatem *maksymalizacja wariancji*.



## Sformułowanie problemu

Aby uprościć obliczenia, zaczniemy od wyśrodkowania punktów:

$$\mathbf{x}^{(i)} \leftarrow \mathbf{x}^{(i)} - \bar{\mathbf{x}},$$

gdzie  $\bar{\mathbf{x}} = \frac{1}{m} \sum_{i=1}^m \mathbf{x}^{(i)}$ .

## Sformułowanie problemu

Aby uprościć obliczenia, zaczniemy od wyśrodkowania punktów:

$$\mathbf{x}^{(i)} \leftarrow \mathbf{x}^{(i)} - \bar{\mathbf{x}},$$

gdzie  $\bar{\mathbf{x}} = \frac{1}{m} \sum_{i=1}^m \mathbf{x}^{(i)}$ .

Zdefiniujmy  $X$  jako macierz wyśrodkowanych danych  $\mathbf{x}^{(i)}$ :

$$X = \begin{bmatrix} -\mathbf{x}^{(1)T} - \\ \vdots \\ -\mathbf{x}^{(m)T} - \end{bmatrix}.$$

Macierz kowariancji jest postaci

$$\text{cov}X = \frac{1}{m} \sum_{i=1}^m \mathbf{x}^{(i)} \mathbf{x}^{(i)T} = \frac{1}{m} X^T X.$$

## Sformułowanie problemu

Szukamy wektora  $u \in \mathbb{R}^d$  takiego, aby wariancja  $\text{var}(u^T X)$  była jak największa.  
Ponieważ

$$\text{var}(\lambda u^T X) = \lambda^2 \text{var}(u^T X),$$

ograniczamy się tylko do wektorów  $u$  o normie 1.

## Sformułowanie problemu

Szukamy wektora  $u \in \mathbb{R}^d$  takiego, aby wariancja  $\text{var}(u^T X)$  była jak największa.  
Ponieważ

$$\text{var}(\lambda u^T X) = \lambda^2 \text{var}(u^T X),$$

ograniczamy się tylko do wektorów  $u$  o normie 1.

Odnotujmy, że zachodzi równość

$$\text{var}(u^T X) = u^T \text{cov} X u.$$

Dla uproszczenia oznaczeń zdefiniujmy  $C := X^T X$ .

# Sformułowanie problemu

Szukamy wektora  $u \in \mathbb{R}^d$  takiego, aby wariancja  $\text{var}(u^T X)$  była jak największa.  
Ponieważ

$$\text{var}(\lambda u^T X) = \lambda^2 \text{var}(u^T X),$$

ograniczamy się tylko do wektorów  $u$  o normie 1.

Odnotujmy, że zachodzi równość

$$\text{var}(u^T X) = u^T \text{cov} X u.$$

Dla uproszczenia oznaczeń zdefiniujmy  $C := X^T X$ .

Zatem poszukujemy wektora

$$\arg \max_{u \in \mathbb{R}^d: \|u\|=1} u^T C u.$$

## Problem optymalizacyjny

Aby wyznaczyć argument maksymalizujący powyższe wyrażenie, skorzystamy z mnożników Lagrange'a. Definiujemy funkcję Lagrange'a wzorem

$$L(u, \lambda) = u^T C u - \lambda(u^T u - 1).$$



## Problem optymalizacyjny

Aby wyznaczyć argument maksymalizujący powyższe wyrażenie, skorzystamy z mnożników Lagrange'a. Definiujemy funkcję Lagrange'a wzorem

$$L(u, \lambda) = u^T C u - \lambda(u^T u - 1).$$

Liczmy gradient po  $u$ :

$$\nabla_u L = 2Cu - 2\lambda u$$

i przyrównujemy go do wektora zerowego.

Otrzymujemy  $Cu = \lambda u$ , a zatem wektor  $u$  musi być wektorem własnym macierzy  $C$ .

# Problem optymalizacyjny

Ponadto zachodzi

$$u^T C u = u^T \lambda u = \lambda,$$

czyli wyrażenie  $u^T C u$  jest największe dla wektora  $u$  odpowiadającego największej wartości własnej macierzy  $C$ .

# Problem optymalizacyjny

Ponadto zachodzi

$$u^T C u = u^T \lambda u = \lambda,$$

czyli wyrażenie  $u^T C u$  jest największe dla wektora  $u$  odpowiadającego największej wartości własnej macierzy  $C$ .

Stąd wynika, że w przypadku  $\ell = 1$  rzutujemy (wyśrodkowane) wejściowe punkty na wektor własny macierzy  $X^T X$  dla największej wartości własnej.

# Problem optymalizacyjny

Ponadto zachodzi

$$u^T C u = u^T \lambda u = \lambda,$$

czyli wyrażenie  $u^T C u$  jest największe dla wektora  $u$  odpowiadającego największej wartości własnej macierzy  $C$ .

Stąd wynika, że w przypadku  $\ell = 1$  rzutujemy (wyśrodkowane) wejściowe punkty na wektor własny macierzy  $X^T X$  dla największej wartości własnej.

W przypadku  $\ell > 1$  szukamy przestrzeni rozpiętej na  $\ell$  wektorach.

Analogicznie jak dla  $\ell = 1$  pokazujemy, że należy wybrać wektory własne macierzy  $X^T X$  odpowiadające  $\ell$  największym wartościom własnym.

## SVD w akcji

Otrzymujemy wektory

$$v_1, \dots, v_d$$

odpowiadające wartościom własnym macierzy  $X^T X$

$$\lambda_1 \geq \dots \geq \lambda_d \geq 0.$$

Dokonujemy rozkładu SVD dla macierzy  $X$ :

$$X = U \Sigma V^T.$$

Macierz  $U$  odpowiada wektorom własnym macierzy  $XX^T$ , macierz  $V$  wektorom własnym macierzy  $X^T X$ , natomiast  $\Sigma$  to macierz diagonalna złożona z wartości własnych macierzy  $XX^T$ .

# Analiza głównych składowych (PCA)

Na wejściu mamy punkty  $x^{(1)}, \dots, x^{(m)} \in \mathbb{R}^d$  oraz parametr  $\ell$ .

1. Wyśrodkuj dane:

$$x^{(i)} \leftarrow x^{(i)} - \bar{x}.$$

2. Wyznacz rozkład SVD macierzy  $X$ :

$$X = U\Sigma V^T.$$

3. Zdefiniuj macierz  $V_r$ :

$$V_r \leftarrow \begin{bmatrix} | & & | \\ v_1 & \cdots & v_\ell \\ | & & | \end{bmatrix}.$$

4. Wyznacz projekcje na przestrzeń rozpiętą na wektorach z  $V_r$ :

$$z^{(i)} \leftarrow V_r^T x^{(i)}.$$

## Ile głównych składowych wybrać?


Najczęściej wybieramy najmniejsze  $\ell$  takie, że wartość  $\frac{\sum_{j=1}^{\ell} \lambda_j}{\sum_{j=1}^d \lambda_j}$  przekracza pewien próg, np. 90%, 95% lub 99%.

## Ile głównych składowych wybrać?

Najczęściej wybieramy najmniejsze  $\ell$  takie, że wartość  $\frac{\sum_{j=1}^{\ell} \lambda_j}{\sum_{j=1}^d \lambda_j}$  przekracza pewien próg, np. 90%, 95% lub 99%.


Ewentualnie można zastosować metodę łokciową dla wykresu osypiska (*scree plot*).

Wykres osypiska





## Przykład zastosowania




Wprawiamy w ruch sprężynę z przyczepionym odważnikiem.

Nie wiemy, w jaki sposób porusza się sprężyna. Aby się tego dowiedzieć ustawiamy trzy kamery nagrywające ruch sprężyny.

Na obrazie każdej z nich sprężyna porusza się w dwóch wymiarach. Macierz danych będzie macierzą o wymiarach  $m \times 6$ .


Po zastosowaniu PCA zredukujemy liczbę wymiarów do jednego.

## Przykład dla bazy MNIST




Oryginalne obrazki

## Jeszcze jeden przykład



Pierwsze główne składowe

## Jeszcze jeden przykład



Rekonstrukcja pierwszego elementu ze zbioru

## Jeszcze raz kompresja obrazów



Oryginalne zdjęcia mają 10 000, natomiast po kompresji 100 pikseli.


## Kiedy (nie) warto stosować PCA?

Obserwacje odstające mają duży wpływ na wynik PCA. Jeśli będzie ich dużo, to otrzymamy mało wiarygodne główne składowe.

## Kiedy (nie) warto stosować PCA?

Obserwacje odstające mają duży wpływ na wynik PCA. Jeśli będzie ich dużo, to otrzymamy mało wiarygodne główne składowe.


Warto stosować PCA jeśli dane pochodzą z rozkładu normalnego





## Kiedy (nie) warto stosować PCA?

Obserwacje odstające mają duży wpływ na wynik PCA. Jeśli będzie ich dużo, to otrzymamy mało wiarygodne główne składowe.

Warto stosować PCA jeśli dane pochodzą z rozkładu normalnego




Jeśli natomiast rozkłady, z których pochodzą dane, są dalekie od normalnego, to PCA może się nie sprawdzić.







## Wersja jądrowa PCA

Tak jak w przypadku klasyfikacji zależy nam nieraz na nieliniowych hipotezach, tak w przypadku PCA chcielibyśmy mieć możliwość otrzymania nieliniowych głównych składowych.



## Wersja jądrowa PCA

Tak jak w przypadku klasyfikacji zależy nam nieraz na nieliniowych hipotezach, tak w przypadku PCA chcielibyśmy mieć możliwość otrzymania nieliniowych głównych składowych.



Jest to możliwe dzięki związkowi pomiędzy macierzą kowariancji dla wyśrodkowanych obserwacji:



$$C = X^T X, \quad C_{kn} = m \operatorname{cov}(X_k, X_n),$$

a macierzą Grama

$$K = XX^T, \quad K_{ij} = \langle x^{(i)}, x^{(j)} \rangle.$$

## Wersja jądrowa PCA

Tak jak w przypadku klasyfikacji zależy nam nieraz na nieliniowych hipotezach, tak w przypadku PCA chcielibyśmy mieć możliwość otrzymania nieliniowych głównych składowych.



Jest to możliwe dzięki związkowi pomiędzy macierzą kowariancji dla wyśrodkowanych obserwacji:

$$C = X^T X, \quad C_{kn} = m \operatorname{cov}(X_k, X_n),$$

a macierzą Grama

$$K = XX^T, \quad K_{ij} = \langle x^{(i)}, x^{(j)} \rangle.$$

Jaki może być związek między tymi macierzami, skoro pierwsza z nich jest rozmiaru  $d \times d$ , natomiast druga  $m \times m$ ?

# Wektory własne $K$ determinują wektory własne $C$

## Lemat

Niech  $x^{(1)}, \dots, x^{(m)} \in \mathbb{R}^d$  oraz niech  $\lambda \in \mathbb{R}$  i  $a \in \mathbb{R}^m$  będą takie, że  $Ka = \lambda a$ . Zdefiniujmy

$$v = X^T a = \sum_{i=1}^m a_i x^{(i)} \in \mathbb{R}^d.$$

Wtedy:

- (i) jeżeli  $v \neq \vec{0}$ , to  $v$  jest wektorem własnym macierzy  $C = X^T X$  dla wartości własnej  $\lambda$ , tj.  $Cv = \lambda v$ ;
- (ii) jeżeli  $\|a\| = 1$ , to  $\|v\| = \sqrt{\lambda}$ .

# Wektory własne $K$ determinują wektory własne $C$

## Lemat

Niech  $x^{(1)}, \dots, x^{(m)} \in \mathbb{R}^d$  oraz niech  $\lambda \in \mathbb{R}$  i  $a \in \mathbb{R}^m$  będą takie, że  $Ka = \lambda a$ . Zdefiniujmy

$$v = X^T a = \sum_{i=1}^m a_i x^{(i)} \in \mathbb{R}^d.$$

Wtedy:

- (i) jeżeli  $v \neq \vec{0}$ , to  $v$  jest wektorem własnym macierzy  $C = X^T X$  dla wartości własnej  $\lambda$ , tj.  $Cv = \lambda v$ ;
- (ii) jeżeli  $\|a\| = 1$ , to  $\|v\| = \sqrt{\lambda}$ .

## Dowód.

- (i)  $Ka = \lambda a \Leftrightarrow XX^T a = \lambda a \Rightarrow X^T XX^T a = \lambda X^T a \Leftrightarrow Cv = \lambda v$ .
- (ii)  $\|v\|^2 = \left\| \sum_{i=1}^m a_i x^{(i)} \right\|^2 = \left\langle \sum_{i=1}^m a_i x^{(i)}, \sum_{j=1}^m a_j x^{(j)} \right\rangle = \sum_{i,j=1}^m a_i a_j \langle x^{(i)}, x^{(j)} \rangle = a^T K a = a^T \lambda a = \lambda$ . □

# Wektory własne $C$ determinują wektory własne $K$

## Lemat

Niech  $x^{(1)}, \dots, x^{(m)} \in \mathbb{R}^d$  będą punktami o średniej 0. Niech  $\lambda \in \mathbb{R}$  oraz  $v \in \mathbb{R}^d$  będą takie, że  $Cv = \lambda v$ . Zdefiniujmy

$$a = \frac{1}{\lambda} Xv \in \mathbb{R}^m.$$

Wtedy  $a$  jest wektorem własnym  $K = XX^T$  dla wartości własnej  $\lambda$ , tj.  $Ka = \lambda a$ .

# Wektory własne $C$ determinują wektory własne $K$

## Lemat

Niech  $x^{(1)}, \dots, x^{(m)} \in \mathbb{R}^d$  będą punktami o średniej 0. Niech  $\lambda \in \mathbb{R}$  oraz  $v \in \mathbb{R}^d$  będą takie, że  $Cv = \lambda v$ . Zdefiniujmy

$$a = \frac{1}{\lambda} Xv \in \mathbb{R}^m.$$

Wtedy  $a$  jest wektorem własnym  $K = XX^T$  dla wartości własnej  $\lambda$ , tj.  $Ka = \lambda a$ .

## Dowód.

Pokażemy najpierw, że niezerowe wektory własne macierzy  $C$  są liniowymi kombinacjami danych wejściowych. Z założenia mamy

$$v = \frac{1}{\lambda} Cv = \frac{1}{\lambda} \sum_{i=1}^m x^{(i)} x^{(i)T} v = \frac{1}{\lambda} \sum_{i=1}^m x^{(i)} \langle x^{(i)}, v \rangle.$$

Zatem definiując  $a := \frac{1}{\lambda} Xv \in \mathbb{R}^m$  dostajemy  $v = \sum_{i=1}^m a_i x^{(i)}$ .

# Wektory własne $C$ determinują wektory własne $K$

## Dowód (cd.)

Teraz pokażemy jak wyrazić wektory własne  $C$  za pomocą wektorów własnych  $K$ :

$$\begin{aligned} Cv = \lambda v &\Leftrightarrow \left( \sum_{i=1}^m x^{(i)} x^{(i)T} \right) \left( \sum_{i=1}^m a_i x^{(i)} \right) = \lambda \sum_{i=1}^m a_i x^{(i)} \\ &\Leftrightarrow \sum_{i,j=1}^m x^{(j)} x^{(j)T} a_i x^{(i)} = \lambda \sum_{i=1}^m a_i x^{(i)} \\ (\forall_{n=1,\dots,m}) \quad &\Rightarrow x^{(n)T} \left( \sum_{i,j=1}^m a_i x^{(j)} \langle x^{(j)}, x^{(i)} \rangle \right) = \lambda \sum_{i=1}^m a_i x^{(n)T} x^{(i)} \\ &\Leftrightarrow \sum_{i,j=1}^m a_i \langle x^{(n)}, x^{(j)} \rangle \langle x^{(j)}, x^{(i)} \rangle = \lambda \sum_{i=1}^m a_i \langle x^{(i)}, x^{(n)} \rangle \\ &\Leftrightarrow (K^2 a)_n = \lambda (Ka)_n \Leftrightarrow Ka = \lambda a. \end{aligned}$$





## Pierwsze podejście

Rozważmy wyśrodkowany zbiór danych  $x^{(1)}, \dots, x^{(m)} \in \mathbb{R}^d$ .

Aby wyznaczyć  $\ell$ -ty wektor własny macierzy  $C$  możemy postąpić następująco:

- wyznaczamy macierz Grama  $K$  i jej  $\ell$ -ty wektor własny  $a$ ,
- normalizujemy  $a$ , tj. chcemy  $\|a\| = 1$ ,
- obliczamy  $v = \frac{1}{\sqrt{\lambda}} \sum_{i=1}^m a_i x^{(i)}$ .

## Pierwsze podejście

Rozważmy wyśrodkowany zbiór danych  $x^{(1)}, \dots, x^{(m)} \in \mathbb{R}^d$ .

Aby wyznaczyć  $\ell$ -ty wektor własny macierzy  $C$  możemy postąpić następująco:

- wyznaczamy macierz Grama  $K$  i jej  $\ell$ -ty wektor własny  $a$ ,
- normalizujemy  $a$ , tj. chcemy  $\|a\| = 1$ ,
- obliczamy  $v = \frac{1}{\sqrt{\lambda}} \sum_{i=1}^m a_i x^{(i)}$ .

Powyższe postępowanie wymaga od nas wykorzystania oryginalnych danych  $x^{(i)}$ .

W praktyce jednak nie zależy nam na obliczeniu wektorów własnych per se, a na wyznaczeniu projekcji punktów  $x^{(i)}$  na przestrzeń rozpiętą na tych wektorach.

## Projekcje na wektory własne macierzy $C$

Jeżeli chcemy rzutować punkt na pewien wektor własny  $v \in \mathbb{R}^d$  macierzy  $C$ , to korzystamy z faktu, że

$$v = \sum_{i=1}^m a_i x^{(i)}.$$

Stąd

$$\pi_v(x^{(i)}) = v^T x^{(i)} = \sum_{j=1}^m a_j \langle x^{(j)}, x^{(i)} \rangle.$$

## Projekcje na wektory własne macierzy $C$

Jeżeli chcemy rzutować punkt na pewien wektor własny  $v \in \mathbb{R}^d$  macierzy  $C$ , to korzystamy z faktu, że

$$v = \sum_{i=1}^m a_i x^{(i)}.$$

Stąd

$$\pi_v(x^{(i)}) = v^T x^{(i)} = \sum_{j=1}^m a_j \langle x^{(j)}, x^{(i)} \rangle.$$

Gdy chcemy rzutować punkt na przestrzeń generowaną przez  $\ell$  wektorów własnych  $v_1, \dots, v_\ell \in \mathbb{R}^d$ , wyznaczamy

$$\pi_{\text{span}\{v_1, \dots, v_\ell\}}(x^{(i)}) = [\pi_{v_1}(x^{(i)}), \dots, \pi_{v_\ell}(x^{(i)})]^T.$$

Jak widać wystarczy znajomość iloczynów skalarnych, czyli macierzy  $K$ .

# Jądrowy algorytm PCA

Na wejściu mamy macierz Grama  $K$  oraz parametr  $\ell$ .

1. Wyśrodkuj dane w przestrzeni cech obliczając wyśrodkowaną macierz Grama ( $\frac{1}{\mathbf{m}}$  to macierz z samymi  $1/m$ ):

$$K \leftarrow K - \frac{\mathbf{1}}{\mathbf{m}}K - K\frac{\mathbf{1}}{\mathbf{m}} + \frac{\mathbf{1}}{\mathbf{m}}K\frac{\mathbf{1}}{\mathbf{m}}.$$


2. Wyznacz rozkład SVD macierzy Grama:  $K = U\Sigma V^T$ .
3. Zdefiniuj macierz  $V_r$ :

$$V_r \leftarrow \begin{bmatrix} \left| \frac{1}{\sqrt{\lambda_1}} v_1 \right| & \cdots & \left| \frac{1}{\sqrt{\lambda_\ell}} v_\ell \right| \end{bmatrix}.$$


4. Wyznacz projekcje na przestrzeń rozpiętą na wektorach z  $V_r$ :

$$z^{(i)} \leftarrow V_r^T K_i.$$


# Co tu się właściwie dzieje?



## Przykład



## Przykład



Po zastosowaniu jądrowej wersji PCA z jądrem gaussowskim z parametrem  $\tau = 2$